



DÉCODER L'IA EN 2025

ACTUALITÉS D'UNE TECHNOLOGIE
EN VOIE DE BANALISATION

Conférence

23 JANVIER 2025

La collection **Actes** propose
un témoignage écrit des événements
(colloques, séminaires, ateliers, etc.)
organisés par l'Institut Robert Badinter
anciennement Institut des études et de
la recherche sur le droit et la justice.

Elle restitue la richesse des échanges
entre intervenants et participants
sur des thèmes où se croisent les
perspectives des mondes professionnel
et de la recherche.

Chaque publication de la collection
constitue un document important
de diffusion et de valorisation des
savoirs pratiques et scientifiques sur
le droit et la justice.

3	Avant-propos
5	Mots de bienvenue des organisateurs
8	Mais où va l'IA ?
15	Parler la langue des IA génératives
20	L'IA transformera-t-elle la liberté en destin ?
36	IA et professionnels du droit, le grand malentendu ?
58	L'IA, arme de destruction massive ?
64	Programme de la conférence
66	Références

Avant-propos

La conférence « Décoder l'IA en 2025 » a réuni des avocats, des magistrats, des universitaires et des chercheurs en intelligence artificielle, afin d'éclairer, par une approche pluridisciplinaire, ces questions complexes. Les discussions ont confirmé le bénéfice d'une approche réfléchie et informée vis-à-vis de l'IA, mettant l'accent sur l'éthique, la responsabilité et la nécessité de formation. Alors que l'IA continue d'évoluer, le rôle des juristes et des institutions juridiques devra également s'adapter afin de garantir que cette technologie soit utilisée pour le bien commun.

La conférence « Décoder l'IA en 2025 », organisée par l'Institut des études et de la recherche sur le droit et la justice (IERDJ, devenu Institut Robert Badinter au 1^{er} juillet 2025) et la faculté de droit, de sciences politiques et de gestion de l'université de Strasbourg en collaboration avec le Centre de culture numérique de l'université de Strasbourg, a été l'occasion de dresser le décor d'une réflexion nécessaire sur les usages institutionnels et professionnels de l'IA dans le champ du droit et de la justice, à travers un rappel de quelques bases techniques vulgarisées, une revue des enjeux politiques et sociétaux de l'IA en début d'année 2025 et un état actualisé, concret et pratique de l'emploi de l'IA dans les métiers juridiques et judiciaires.

La conférence a débuté par une allocution du doyen de la faculté de droit, de sciences politiques et de gestion qui a exprimé l'importance croissante de l'IA dans divers domaines, notamment le droit. Elle a souligné que l'IA n'est pas simplement un phénomène technologique, mais une révolution qui influence notre mode de vie, nos relations sociales, et même notre conception de l'identité humaine. La nécessité de « décoder » l'IA est ainsi devenue primordiale pour en comprendre les implications éthiques et sociales.

Les enjeux de l'intelligence artificielle pour les juristes

Les intervenants ont principalement abordé les défis et les opportunités que présente l'introduction de l'IA dans les pratiques professionnelles des juristes. Ils ont mis en évidence le besoin d'une compréhension approfondie des technologies sous-jacentes et des algorithmes, afin de mieux appréhender leurs impacts sur le système judiciaire.

Un point important discuté fut le cadre réglementaire entourant les développements de l'IA, avec un accent particulier sur le règlement européen sur l'IA. Les intervenants ont exprimé des préoccupations quant aux définitions vagues et à la difficulté d'appliquer des normes juridiques à des technologies en constante évolution. L'importance de la formation et de l'éducation a également été soulignée, car il est essentiel que les professionnels du droit soient équipés pour interagir avec ces nouvelles technologies.



Les applications de l'IA dans le domaine juridique

Au cours de la conférence, des cas d'utilisation concrets de l'IA dans le domaine juridique ont été présentés. Les avocats et magistrats ont partagé leurs expériences concernant l'intégration de l'IA dans leurs pratiques. Par exemple, certains ont commencé à utiliser des outils d'IA pour la recherche juridique, la gestion des dossiers, et même pour la rédaction de documents. Cependant, ils ont également souligné les limites et les risques associés à ces outils, notamment en matière de responsabilité et de fiabilité.

La question de l'usage de l'IA générative dans le processus judiciaire a également été abordée. Les intervenants ont discuté des implications éthiques de l'utilisation d'algorithmes pour influencer des décisions judiciaires. L'importance de la transparence et de la responsabilité a été mise en avant, avec l'idée que les juges doivent rester vigilants quant aux outils qu'ils utilisent.

Les perspectives d'évolution

Les participants ont discuté des tendances émergentes et des développements potentiels dans le domaine de l'IA. La nécessité d'une collaboration interdisciplinaire entre juristes, techniciens, et chercheurs a été soulignée comme un facteur clé pour naviguer dans ce paysage complexe. L'importance de rester informé sur les évolutions technologiques a été mise en avant, tout comme la nécessité d'adopter une approche proactive pour intégrer l'IA dans le domaine juridique de manière éthique et responsable.

Les intervenants ont également exprimé des préoccupations concernant l'impact de l'IA sur l'emploi dans le secteur juridique. Alors que certaines tâches peuvent être automatisées, il est crucial de préserver le rôle humain dans le processus judiciaire. Une attention particulière a été portée à la formation des futurs juristes, afin qu'ils soient en mesure de travailler efficacement aux côtés de systèmes d'IA.



Pour aller plus loin

Les enregistrements audiovisuels des différentes séquences sont disponibles en ligne sur YouTube :

<http://bit.ly/3JswtyJ>

Mots de bienvenue des organisateurs

Jeanne-Marie TUFFERY-ANDRIEU

Doyen de la faculté de droit, de sciences politiques et de gestion de Strasbourg

Yannick MENECEUR

Magistrat et maître de conférences associé à la faculté de droit, de sciences politiques et de gestion de Strasbourg, responsable d'études et de recherche associé à l'IERDJ

Harold ÉPINEUSE

Directeur adjoint de l'IERDJ

Jeanne-Marie TUFFERY-ANDRIEU : Monsieur le directeur adjoint de l'IERDJ, Monsieur le président du tribunal judiciaire de Strasbourg, Madame la présidente du tribunal judiciaire de Colmar, Monsieur le vice-président délégué en charge de la formation. La faculté de droit, de sciences politiques et de gestion est heureuse de participer à cette très belle manifestation « Décoder l'IA en 2025 : actualités d'une technologie en voie de banalisation », sur invitation de Monsieur Yannick MENECEUR, magistrat spécialiste des questions du numérique et maître de conférences associé à la faculté. Aussi, je souhaite lui exprimer ma très profonde gratitude, à laquelle je suis honorée d'associer l'IERDJ, en particulier Madame Valérie SAGANT et Monsieur Harold ÉPINEUSE.

Il m'est également agréable d'adresser la bienvenue aux collègues venant d'autres universités et de saluer les experts praticiens qui se sont aujourd'hui rendus disponibles. Cette manifestation et la présence des étudiantes et étudiants inscrits dans la mention « Droit » et plus spécifiquement dans les parcours « Cyberjustice » dirigé par le Professeur Emmanuel NETTER, « Droit de l'Economie numérique » dirigé par Madame Catherine LEDIG, « Droit et gestion des énergies et du développement durable » codirigé par les professeurs Anne ROZAN, Bruno TRESCHER et Madame Catherine LEDIG, ainsi que « Droit et gouvernance des données de santé » dirigé par les professeurs Frédérique BERROD,

Jean-Yves BAPST¹ et Madame Catherine LEDIG, révèlent l'importance pour la faculté de ces questions suscitées par l'émergence de l'IA, du numérique, dans les domaines du droit, de la justice, ou encore dans celui des chiffres.

Loin de vouloir suivre un phénomène de mode, la faculté veut résolument s'enraciner dans cette dimension qui lui est déjà familière. Les formations qu'elle propose depuis près de trente ans maintenant – et je souhaite saluer ici l'engagement constant de Madame Catherine LEDIG, professeure associée à la faculté dans ce domaine – soulignent l'importance que les technologies et le numérique ont toujours eue à la faculté. La présence de Monsieur le vice-président délégué dit aussi sans doute l'attention que l'université porte à ces questions. Monsieur le vice-président délégué, au lendemain de la journée consacrée à l'utilisation de l'intelligence artificielle que vous avez organisée, vous voir ici soutient notre projet et encourage notre ambition. Une dotation spécifiquement fléchée par l'université, des moyens complémentaires accordés, renforceront la détermination de la faculté. Qu'il nous soit permis de compter sur vous, Monsieur le vice-président délégué, et, à travers votre personne, sur l'université, pour permettre à la faculté de demeurer active, dynamique et novatrice dans ce domaine. La faculté, selon la mission qui est la sienne, souhaite contribuer, elle aussi, au décodage de l'IA grâce, outre son expertise reconnue, aux valeurs qui la fondent. Ce sont celles de cet humanisme rhénan qui forme d'ailleurs son berceau et qui la conduit aujourd'hui encore à affirmer la prééminence des libertés publiques et le respect de la dignité de la personne humaine.

Soutenue par les experts universitaires et professionnels qui animent la formation et la recherche, la faculté a conscience de sa responsabilité dans la cité. L'intelligence artificielle est un outil extrêmement puissant utilisé dans de nombreux domaines de l'activité humaine,

1. Notre collègue Jean-Yves Bapst, professeur de Pharmacie, est décédé le 10 mai 2025. En relation avec les autres codirecteurs du diplôme, il a créé et déployé ce parcours mutualisé avec la faculté de pharmacie afin de promouvoir, par une formation offerte en apprentissage, une insertion professionnelle réussie des étudiants.



et l'on peut désormais supposer que son utilisation influencera de plus en plus notre mode de vie, nos relations sociales et même, à l'avenir, la manière dont nous concevons notre identité en tant qu'être humain. Vouloir décoder l'IA, c'est reconnaître que l'avènement de l'intelligence artificielle représente une véritable évolution et sans doute même une révolution qui annonce la création d'un nouveau système social. Mais vouloir décoder, c'est aussi affirmer la volonté de découvrir la clé de codage afin de rendre ce code compréhensible.

Poser ainsi la problématique lors d'une manifestation scientifique signifierait-il que l'outil a échappé à son créateur ? Cela voudrait-il dire, par extension, que nous assistons à une disparition ou du moins à une éclipse du sens de l'humain ? Cela conduirait-il les programmes d'intelligence artificielle à remettre en question l'être humain et son agir ? Décoder l'IA, c'est donc encore soulever la question de la dimension éthique de la décision, question qui prend en compte non seulement les résultats d'une action, mais aussi les valeurs en jeu et les devoirs qui en découlent. Aussi, vous disant à nouveau toute la fierté de la faculté d'être engagée dans cette réflexion qui contribue à la formation scientifique et humaine des étudiantes et étudiants, qui participe à la mise en place d'une politique vraiment sociale et qui œuvre à l'élaboration d'une cité plus juste, je vous souhaite de très fructueux échanges.

Yannick MENECEUR : C'est avec un grand plaisir et un honneur immense que je me trouve aujourd'hui dans cet amphithéâtre en votre présence, après plusieurs années de réflexion sur la manière la plus adéquate de partager mes réflexions sur cette technologie. Je tiens à exprimer ma profonde gratitude à Madame le doyen pour sa confiance et pour m'avoir permis d'exercer les fonctions de maître de conférences associé au sein de la faculté de droit. Cela a été un véritable combat, mais nous y sommes parvenus.

Je souhaite également saluer la présence de Monsieur le vice-président délégué, qui a fait preuve d'une grande délicatesse. Nos agendas n'étaient pas totalement alignés, mais nous avons su réorganiser nos journées en conséquence, et je le remercie pour cette attention.

Je tiens à saluer mes collègues présents dans la salle, ainsi que ceux qui se connectent en ligne. Je me suis fait connaître au sein du réseau de l'École nationale de la magistrature, et j'ai informé mes collègues de l'existence de cette conférence. Je n'oublie pas non plus l'IERDJ, en particulier Valérie SAGANT et Harold ÉPINEUSE.

Enfin, je souhaite saluer mes étudiantes et étudiants ; je m'approprie un peu votre présence, même si d'autres enseignants sont également présents pour veiller sur vous.

Avec l'IERDJ, j'ai conçu et organisé cette conférence pour vous. Il est impératif aujourd'hui de vulgariser l'intelligence artificielle. L'article 4 du règlement sur l'intelligence artificielle, le « AI Act », impose des obligations de formation et de connaissances particulières en matière d'intelligence artificielle pour l'ensemble des professionnels. Ainsi, que vous soyez en formation ou que vous exerciez, il est essentiel de maîtriser les bases de cette technologie. Tout comme nous faisons la distinction entre le diesel et l'essence d'un véhicule à moteur pour choisir la meilleure solution technologique, nous devons également comprendre l'essence de cette technologie.

Nous ne prétendons pas faire de vous des ingénieurs informatiques ou des spécialistes, et saluons les chercheurs en intelligence artificielle présents aujourd'hui, qui construiront des ponts entre nos savoirs. Nous voulons dépasser les discours convenus et les récits biaisés sur l'intelligence artificielle, pour ancrer cette technologie dans la réalité. C'est l'objectif de cette journée et je me réjouis de votre présence parmi nous.

Harold ÉPINEUSE : C'est également un plaisir et un honneur de me retrouver ici, dans le cadre d'une nouvelle collaboration entre l'IERDJ et la faculté de droit, des sciences politiques et de gestion de l'université de Strasbourg. Je tiens à exprimer ma gratitude à Madame le doyen pour sa confiance, ainsi qu'à toi, cher Yannick, et à Catherine LEDIG pour leur soutien indéfectible.

Je remercie également le Centre de culture numérique qui nous accueille aujourd'hui dans ses locaux, nous fournissant toutes les ressources nécessaires pour organiser cet événement ici, en présentiel et en ligne, afin d'atteindre une audience plus large. Cette conférence publique marque le lancement d'un cycle d'ateliers avec les représentants de nos membres intéressés par ces questions, des ateliers fermés durant lesquels nous réfléchirons ensemble aux questions concernant l'intelligence artificielle dans le domaine du droit et de la justice.

Qui sont nos membres ? Ce sont le ministère de la Justice, les juridictions judiciaires et administratives, ainsi que les différentes professions juridiques et judiciaires pour ne citer que ceux-là. Car nous comptons également parmi nos membres le ministère de l'Enseignement supérieur et de la Recherche, le CNRS, France Université, entre autres.



En mentionnant cela, je souhaite illustrer que notre Institut, constitué sous la forme de groupement d'intérêt public, se positionne à la croisée des institutions, des professions du droit et de la justice, ainsi que du monde de la recherche. L'IERDJ est en quelque sorte la maison commune des chercheurs et des praticiens du droit et de la justice, avec pour mission de produire des études dans ces domaines, ainsi que soutenir et promouvoir une recherche pluridisciplinaire.

Nous organisons ainsi la rencontre entre juristes, en provenance des institutions et des professions, avec le vaste champ des sciences humaines et sociales, afin de mieux comprendre les phénomènes qui touchent le droit, la justice, nos institutions et l'évolution de nos pratiques. Le sujet du numérique se trouve au cœur de nos travaux depuis près de quinze ans.

La question de l'IA qui nous occupe aujourd'hui est une thématique que nous avons commencé à explorer à l'Institut depuis 2016, en collaboration avec le Conseil de l'Europe et l'université. À l'issue d'un travail sur la conduite du changement vers la cyberjustice que nous avait commandé la Commission européenne pour l'efficacité de la justice (CEPEJ), nous avons organisé ici à Strasbourg, au Palais de l'Europe, une conférence en clôture de laquelle nous avons posé une question qui semblait à mille lieux des réflexions en cours sur le numérique à l'époque et s'est révélée parfaitement pertinente pour anticiper le monde de l'IA qui s'apprêtait déjà en réalité à déferler sur nous : « L'intelligence artificielle : alliée ou ennemie du droit ? ».



Conférence Cyberjustice Europe 2016 - Intelligence artificielle : alliée ou ennemie du droit ?

<http://bit.ly/3LbQFFs>



Se poser cette question aujourd'hui peut sembler moins pertinent, mais elle prend un sens renouvelé face aux récents développements de l'intelligence artificielle. Beaucoup de questions soulevées à l'époque étaient liées à la doctrine et à la politique des données ouvertes qui commençaient à s'imposer dans le champ du droit et de la justice. Cela a généré des débats autour de la notion de justice prédictive ou prévisionnelle, un champ de réflexion d'ailleurs très bien documenté par Yannick MENECEUR.

Il y a environ deux ans, un outil de consommation de masse a émergé, fondé sur des modèles génératifs d'IA, qui ont donné un nouvel élan et de nouvelles perspectives à ces technologies. L'IA générative s'est déployée à une vitesse qu'aucune technologie n'avait atteint jusque-là, rendant urgent d'actualiser notre regard sur le rôle donné ou laissé à l'intelligence artificielle.

Nous n'allons pas aborder d'emblée l'impact de l'intelligence artificielle sur le travail des praticiens du droit, mais nous prendrons ce matin le temps d'un détour pour explorer l'IA dans son ensemble et ses développements les plus récents, en tenant compte de l'actualité de cette technologie en janvier 2025. Qu'elle semble loin l'IA de 2016. Reconnaissons que nous sommes aujourd'hui inondés d'informations sur l'IA : saturés d'informations qui se contredisent. Nous avons ainsi récemment entendu parler d'investissements colossaux de l'autre côté de l'Atlantique pour développer une IA encore plus performante et généraliste... jusqu'à la prochaine annonce.

Cette conférence s'inscrit évidemment dans un contexte où de nombreux événements sont organisés à ce sujet, partout en France et dans le monde. J'espère que celui-ci vous apportera une réelle valeur ajoutée mêlant réflexion exigeante et pédagogie, confrontation des idées et ouverture aux points de vue différents, complémentarité des regards et des témoignages.

Avant d'entrer dans les travaux en ateliers avec nos membres institutionnels et professionnels, où nous examinerons ensemble les cas d'usages de l'IA dans nos métiers, ainsi que les opportunités et les limites qu'ils présentent, il nous semble essentiel de commencer par faire le point sur les derniers développements et les réflexions suscitées par cette technologie auprès des experts et des chercheurs que nous avons conviés aujourd'hui.

Je vous remercie toutes et tous pour votre présence. Vous êtes nombreuses et nombreux ici dans cet amphithéâtre du Centre de culture numérique, mais aussi en ligne. Il est donc temps de céder la parole à notre premier invité pour une conférence inaugurale très attendue. ■



Conférence d'ouverture

Mais où va l'IA ?

- Comprendre les fondements et les implications éthiques de l'intelligence artificielle.
- Prendre de la distance avec les idées reçues sur l'intelligence artificielle.
- Une réflexion critique sur les motivations des grands acteurs technologiques est à conduire.



Jean-Gabriel GANASCIA

Professeur d'informatique à la faculté des sciences de Sorbonne Université, membre senior de l'Institut universitaire de France (IUF) et président du comité d'éthique du CNRS.

Tout d'abord, je tiens à vous remercier pour m'avoir invité à faire cette conférence inaugurale devant des juristes, ce qu'il faut avouer, est quelque peu intimidant. Le but, bien sûr, est de dire où va l'IA. Néanmoins, pour savoir où va l'IA, il faut avant tout comprendre d'où vient l'IA. C'est donc le sujet que je souhaite aborder sans plus tarder lors de cette conférence d'ouverture, en introduisant les concepts clés présents dans cette discipline scientifique.

Mon ouvrage², comme cela a déjà été dit, vise à donner des clés de compréhension de l'intelligence artificielle à un large public, collégiens comme enseignants. À mon sens, cela devrait faire partie de la culture générale commune. Pourtant, lorsqu'on écoute les médias, même si l'on parle beaucoup d'intelligence artificielle, on a souvent l'impression que la confusion ne fait que s'accroître. Le sujet étant très discuté, des intervenants d'horizons variés sont invités, mais certains ne sont pas experts : ils n'ont parfois qu'une pratique limitée de l'intelligence artificielle, voire

seulement des idées générales, sans réelle connaissance du sujet.

Ce petit ouvrage présente un scénario, celui de quatre collégiens qui viennent me voir pour rédiger un numéro spécial de la feuille de chou de leur établissement – le collège Raymond Queneau – intitulée *Les Querelles de Queneau*, sur demande de leur professeur de français. Sans parler du contenu de l'ouvrage en lui-même, je souhaite simplement en évoquer l'intrigue, qui est complètement imaginaire. Ces collégiens ont été inventés, tout comme la professeure de français.

Dans cet ouvrage, j'explique d'abord ce qu'est l'intelligence artificielle. Qu'entend-on par là ? Certains affirment que le terme est mal choisi ou mal traduit de l'anglais, ou même impossible. Pourtant, ce n'est pas le cas : il a un sens précis, que je vais m'efforcer de clarifier dans ces propos introductifs. Deuxièmement, j'aborde ce qui existait avant l'intelligence artificielle : depuis longtemps, on réfléchit à la manière de concevoir des machines capables de simuler nos raisonnements. Je donnerai donc quelques repères historiques après avoir présenté la définition de l'intelligence artificielle. Enfin, je retracerai l'histoire récente et je parlerai de l'IA générative pour conclure sur une question très complexe, source de nombreuses interrogations : où va l'IA ?

Première question : que représente l'intelligence de l'intelligence artificielle ? Savez-vous ce que signifie réellement ce terme ? Il est important de le préciser, car « intelligence » est

2. *L'IA. expliquée aux humains*, Jean-Gabriel Ganascia, Seuil, 2024.

polysémique et possède au moins quatre sens. Le premier est l'esprit. Faut-il donc imaginer une machine douée d'esprit ? Je vous rassure tout de suite : en tant que scientifique, la réponse est non.

La deuxième question concerne l'ingéniosité. Les machines que nous fabriquons sont-elles astucieuses ? Comme on dit parfois d'un élève qu'il est intelligent car il est bon en maths ou qu'il trouve des solutions originales. Est-ce cela, l'intelligence ? On n'en sait rien. Les machines ne sont pas toujours très astucieuses, tout comme les humains. C'est une question complexe. On pourrait évoquer le QI, mais ce dernier est scientifiquement très problématique. Un médecin très connu en France affirme que les machines auront un QI phénoménal, supérieur à celui des humains, mais c'est absurde. En effet, le QI est une mesure arbitraire qui évalue les performances des individus à un certain nombre de tests. On la normalise pour que la moyenne sur la population soit de 100. Mais, on ne sait pas très bien à quoi cela équivaut.

Troisième point : certains demi-savants affirment que l'expression « intelligence artificielle » serait une mauvaise traduction de l'anglais, comme dans « Intelligence Service » ou « Central Intelligence Agency » (CIA), et que l'IA ne serait qu'un traitement de flux d'informations ou du codage. Je vous rassure : le terme existe aussi en français. Quand vous dites que vous êtes en bonne intelligence avec quelqu'un, cela signifie que vous êtes en connivence avec cette personne. De même, en tant que juristes, vous savez que « crime d'intelligence avec l'ennemi » signifie faire fuiter des informations. Le sens existe donc bien en français, et l'intelligence de l'intelligence artificielle n'est pas une mauvaise traduction de l'anglais.

Le vrai sens de l'intelligence dans l'expression « intelligence artificielle » renvoie à la capacité de connaître et, plus largement, à l'ensemble des fonctions cognitives. Quelle est son origine ? À la fin du XIX^e siècle, les philosophes positivistes ont essayé de naturaliser les problématiques philosophiques, et en particulier l'étude de l'esprit. Pour cela, ils ont tenté d'utiliser les méthodes empiriques des sciences physiques et les expérimentations afin d'examiner les différentes facultés mentales. En France, un philosophe, que certains d'entre vous connaissent peut-être pour son ouvrage *Voyage en Italie*, Hippolyte Taine, a écrit un imposant livre en deux tomes intitulé *De l'intelligence* dans lequel il aborde les différentes facultés mentales. Je vous le recommande : même si l'ouvrage est aujourd'hui

daté, il est merveilleusement écrit et traite de la mémoire, du raisonnement et de toutes nos facultés cognitives. C'est précisément ce sens-là qui est utilisé en intelligence artificielle.

Cela me conduit à une remarque : l'intelligence n'est assurément pas générale, contrairement à ce que certains nous racontent. Dans le discours populaire, on entend souvent que l'intelligence des machines va s'accroître avec l'augmentation de leur puissance de calcul au point qu'elles vont nous dépasser soudainement, comme si l'on pouvait accumuler les capacités mentales. Ce n'est pas le cas. L'intelligence n'est pas une substance ; c'est un ensemble de facultés cognitives variées et incommensurables, différentes selon les espèces, mais aussi selon les individus.



L'intelligence n'est pas une substance ; c'est un ensemble de facultés cognitives variées et incommensurables, différentes selon les espèces, mais aussi selon les individus.

Pour s'en convaincre, les techniques d'imagerie fonctionnelle cérébrale sont d'un grand secours, car elles permettent de visualiser l'activité du cerveau. Par exemple, si l'on compare l'image d'un cerveau de musicien écoutant une pièce musicale avec celle d'un cerveau de non-musicien écoutant la même pièce, on constate que les zones activées sont complètement différentes. Ainsi, selon que vous êtes familier ou non avec la musique, votre activité cérébrale ne sera pas la même. Cela montre que l'idée d'une intelligence artificielle générale ne repose sur rien. J'insiste : l'intelligence n'est pas une substance.

Nous arrivons maintenant à la deuxième question : quand tout cela a-t-il commencé ? Il y a très longtemps. Au XVII^e siècle, Pascal invente une machine à calculer. Ce n'est pas un ordinateur, juste une calculette. Pourtant, il remarque que cette machine produit des effets qui s'approchent davantage de la pensée que tout ce que font les animaux. Une intuition incroyable. Pour autant, il comprend bien qu'elle ne possède pas de volonté propre, contrairement

aux animaux. En une phrase, il formule brillamment la question que nous nous posons encore aujourd'hui, et à laquelle nous reviendrons à la fin de cette présentation.

Depuis lors, de nombreuses tentatives ont été faites pour créer des machines capables de simuler nos raisonnements. Un autre philosophe du XVII^e siècle, Leibniz, a arithmétisé la logique, c'est-à-dire les lois de la pensée. Il a ensuite conçu une machine pour calculer cette arithmétique de la logique, toujours dans cette idée de stimuler le raisonnement. Le projet n'a pas abouti, mais l'idée était là. Plus tard, au début du XIX^e siècle, Charles Babbage a imaginé une machine capable d'exécuter des algorithmes, à savoir un ordinateur. Son assistante, Ada Lovelace, avait alors envisagé que cette machine pourrait servir non seulement à des calculs mathématiques, mais aussi au traitement de textes et de musique. On se rapproche ainsi nettement de l'intelligence artificielle. Toujours au XIX^e siècle, Stanley Jevons a réalisé un « piano logique³ » reprenant l'algèbre de Boole pour simuler des raisonnements. En 1912, l'ingénieur espagnol Leonardo Torres Quevedo a construit une machine électromécanique capable de jouer des finales d'échecs, roi contre roi. Ces tentatives se sont ainsi multipliées au fil du temps.

Plus proche de nous, en 1943, deux articles fondamentaux ont marqué l'histoire. Le premier de Norbert Wiener, Arturo Rosenblueth et Julian Bigelow, porte sur les machines téléologiques⁴. Le préfixe « téléo » vient du grec *téléos* qui signifie finalité, ici la finalité des machines asservies à la satisfaction d'un but. Cet article est à l'origine de ce que l'on appelle la rétroaction ou *feedback* en anglais, et de la cybernétique. Le second article⁵, central et extrêmement influent, est celui de McCulloch et Pitts sur les neurones formels. L'idée était de simuler, à l'aide d'automates, l'activité du cerveau.

Le premier ordinateur électronique a été construit en 1946. Avant cela, il existait des calculateurs qui utilisaient des relais téléphoniques. On a alors tenté, avec ces dispositifs, de simuler ce que l'on connaissait de notre cerveau. Dès 1906, on savait en effet que le cerveau était composé de nombreuses cellules reliées entre elles par des connexions, appelées « connexions synaptiques ». Ces connexions sont plastiques,

c'est-à-dire qu'elles évoluent avec le temps, ce qui permet la mémoire et l'apprentissage. On a donc essayé de simuler ces évolutions, et nous y reviendrons plus tard, car aujourd'hui ces modèles prennent une importance considérable.

La traduction automatique a commencé dès l'apparition des premiers ordinateurs, en 1949, avec des tentatives comme celle de Warren Weaver, fondateur avec Claude Shannon de la théorie de l'information. C'est alors que naît le premier projet de machine à traduire. Que faisait-on à l'époque ? On procédait comme un mauvais élève : on prenait un mot, on cherchait son équivalent dans le dictionnaire, puis on passait au mot suivant... sans succès. Les chercheurs ont alors compris qu'il fallait tenir compte du contexte. Par exemple, le mot « manche » précédé d'un article masculin se traduit par « handle », correspondant à un manche de marteau. Mais pas toujours : il peut aussi s'agir du manche d'un gigot. Il faut donc analyser un contexte plus large. La difficulté est encore plus grande avec le féminin : « la manche » peut désigner la manche d'une chemise, l'action de mendier, ou encore la manche au bridge. »



Le premier ordinateur électronique a été construit en 1946. Avant cela, il existait des calculateurs qui utilisaient des relais téléphoniques. On a alors tenté, avec ces dispositifs, de simuler ce que l'on connaissait de notre cerveau.

La traduction est une opération complexe, qui doit surmonter de nombreux obstacles, sans que je rentre ici dans tous les détails. À titre d'illustration, considérons les ambiguïtés pronominales. Prenons la phrase : « Prenez les poissons et enlevez les écailles, mettez-les dans les plats ». Comment déterminer à quoi se réfère le pronom « les » ? Si l'on prend le nom pluriel le plus proche, on obtient « les écailles ». Mais ce n'est pas ce que l'on met dans le plat. Comment la machine pourrait-elle le savoir ? Ces difficultés ont conduit des linguistes, en 1966, à affirmer qu'il était impossible de faire de la traduction automatique avec cette approche. Pour réussir, il faut des connaissances linguistiques, un lexique, une grammaire et des connaissances pragmatiques,

3. « *The logical piano* », plus connu sous le nom de piano de Jevons en français.

4. « Behavior, Purpose and Teleology », Norbert Wiener, Arturo Rosenblueth et Julian Bigelow, *Philosophy of Science*, Volume 10, Issue 1, 1943.

5. « A Logical Calculus of the Ideas Immanent in Nervous Activity », Warren McCulloch et Walter Pitts, *Bulletin of Mathematical Biophysics*, Volume 5, 1943.

par exemple savoir que les écailles de poisson se jettent. En réalité, ces linguistes s'étaient complètement trompés, mais on ne l'a découvert qu'avec quarante ans de retard. C'est ce qui fait que l'histoire de l'intelligence artificielle est parsemée d'erreurs et d'échecs. Alors, quand on me demande où va l'intelligence artificielle, je réponds qu'on ne sait pas et qu'on ne peut pas le savoir. À chaque fois, on se fait des romans sur l'avenir, et la réalité ne correspond jamais à ce que l'on avait imaginé.

Que s'est-il passé ensuite ? L'intelligence artificielle naît en 1956 avec John McCarthy, alors âgé de 28 ans, brillant mathématicien. Avec trois autres personnes, Marvin Minsky, Nathaniel Rochester, directeur scientifique d'IBM, et surtout Claude Shannon, le grand théoricien de l'information, il décide de fonder une discipline scientifique dont l'objectif est de simuler les différentes facultés cognitives. Voici la définition. C'est une discipline fondée sur la conjecture que toutes les caractéristiques de l'apprentissage et les autres composantes de l'intelligence peuvent, en principe, être décomposées et décrites avec suffisamment de précision pour être modélisées par une machine. Il s'agit donc de décomposer l'intelligence en facultés cognitives que l'on peut simuler. Cela n'a rien à voir avec l'idée qu'une machine puisse être véritablement intelligente ou judicieuse : il s'agit simplement de mieux comprendre nos propres facultés cognitives en les reproduisant.

En tant qu'Américains, ils étaient pragmatiques et pensaient à l'utilité, notamment à la possibilité d'intégrer cette technique dans des technologies comme la voiture autonome. À l'époque, les idées foisonnaient. Les premiers modèles de robots existaient déjà en 1956 : on peut trouver des archives montrant Albert Ducrot présentant un petit robot équipé de capteurs qui envoient des signaux modulant son activité. Cela le distingue d'un simple automate, qui exécute des séquences sans tenir compte du monde extérieur. Avec l'intelligence artificielle, ils espéraient aller plus loin et simuler toutes les facultés mentales : le raisonnement – par exemple la démonstration de théorèmes ou les déductions logiques –, la perception, comme la reconnaissance des visages et de la parole, la communication, la mémoire, l'apprentissage, etc.

L'intelligence artificielle est une discipline extrêmement large qui a fait des progrès considérables ces soixante-dix dernières années. Pour vous en rendre compte, voici un résumé très rapide de son histoire. Comme vous allez vous en rendre compte, tout n'est pas né il y a deux ans.

L'intelligence artificielle naît donc en 1956, rapidement suivie par les premières réalisations, notamment les premiers programmes de démonstration automatique de théorèmes, avec des succès indéniables. Peu après, l'apprentissage machine apparaît – et j'insiste : il n'a pas été inventé il y a dix ans, mais dès les débuts de l'IA – grâce à un pionnier, Arthur Samuel, ingénieur chez IBM. Il a créé une machine capable de jouer au jeu de dames et a cherché à améliorer son programme en modélisant les théories de l'apprentissage issues de la psychologie comportementaliste. Pour illustrer, pensez à la boîte de Skinner : une souris est placée dans une boîte et reçoit une récompense si elle touche une certaine manette ou va à un endroit précis, ou une punition si elle agit autrement. On observe ainsi le temps nécessaire pour apprendre à associer action et récompense. Pour simuler ce processus d'apprentissage, on utilise des « cailloux virtuels » qui balisent les chemins, une méthode toujours utilisée aujourd'hui. Par exemple, ChatGPT repose sur des modèles de langage, mais pour éviter les dérives, il utilise également l'apprentissage par renforcement avec retour humain : au lieu de souris, ce sont des modérateurs vivant au Kenya que l'on simule, mais le principe reste le même.

On s'enthousiasme pour les premiers résultats. En particulier, un pionnier de l'intelligence artificielle et spécialiste de sciences sociales, Herbert Simon, qui deviendra prix Nobel d'économie, déclare en 1958, que d'ici dix ans, si les machines ne sont pas exclues des compétitions d'échecs, elles pourraient devenir championnes du monde. Selon lui, elles devraient également être capables de démontrer des théorèmes mathématiques et de générer de la musique avec une valeur esthétique indéniable. Dès cette époque, on pressentait donc déjà que l'IA pouvait être générative.

Néanmoins, après quelques années, deux problèmes apparaissent. D'abord, la traduction automatique : comme nous l'avons vu, certains linguistes affirmaient que cela ne pouvait pas fonctionner, du moins avec les techniques mobilisées. Ensuite, en 1965, un programme de jeu d'échecs a été battu par un enfant de dix ans. On comprend alors que la prédiction selon laquelle un programme deviendrait champion du monde en dix ans ne serait jamais réalisée. Cela conduit à ce que l'on a appelé l'« hiver de l'intelligence artificielle ». Cette expression est souvent reprise. Vous avez par exemple évoqué 1992 comme un hiver de l'IA, mais ces périodes n'ont pas été si froides que cela : mon premier livre,

*L'âme-machine*⁶, publié en 1990, montre que le sujet était encore très chaud à l'époque.

Les premiers chatbots datent de 1965, au début de ce prétendu hiver de l'intelligence artificielle. Pourtant, on les utilise toujours aujourd'hui. Juste après, dans les années 1970, apparaît SHRDLU, un premier programme capable de comprendre le langage naturel : il interprète des phrases simples comme « prends le cube vert derrière la pyramide rouge » et les fait exécuter par un robot. Cela montre que le programme peut comprendre « prends le cube de verre derrière la pyramide ». En France, un très grand mathématicien, Alain Colmerauer, conçoit en 1972, donc au cœur de ce prétendu hiver de l'intelligence artificielle, le langage PROLOG qui permet d'écrire des programmes informatiques avec de la logique mathématique et de les exécuter avec un démonstrateur automatique de théorèmes. Bref, malgré l'hiver annoncé, on continue à travailler et on obtient des résultats extraordinaires.

En 1979, on assiste à une renaissance de l'intelligence artificielle. Les pionniers constatent que l'une des raisons des échecs précédents est que le raisonnement, et donc l'intelligence, avait été réduit à de simples formules mathématiques. On décide alors de s'intéresser à l'intelligence humaine. Des échanges entre psychologues, informaticiens et linguistes donnent naissance aux sciences cognitives. Cela conduit à étudier l'organisation de la connaissance dans la mémoire humaine afin de la modéliser : c'est ce que l'on appelle la représentation des connaissances.

S'ensuit la création de systèmes capables de modéliser le savoir des professionnels afin d'être plus efficaces. Ces systèmes, dits « experts », ont obtenu des performances remarquables en chimie, en médecine, en géologie et dans de nombreux savoirs pratiques, ce que l'on n'imaginait pas au départ. Initialement, on pensait qu'il serait facile de faire faire des mathématiques aux machines, mais on doutait de leur capacité à réussir dans des disciplines nécessitant de l'intuition. Finalement, ces systèmes ont montré d'excellents résultats dans ces domaines.

Cette connaissance qu'on cherchait à modéliser avec les systèmes experts, il fallait ensuite l'acquérir et cela a été compliqué. Un nouveau métier est né à ce moment-là : la maïeutique cognitive, qui consiste à aider des experts à expliciter le savoir qu'ils mobilisent dans leur

pratique professionnelle. La difficulté est que les experts, en général, ne savent pas ce qu'ils font. Ils le font bien, mais quand on leur demande comment, ils ne sont pas toujours capables de l'expliquer. Ils omettent certaines étapes et, parfois, décrivent ce qu'ils devraient faire selon l'enseignement théorique, alors qu'en réalité, ils ne procèdent pas ainsi.

Cela a conduit plusieurs spécialistes, dont moi-même, à tenter d'acquérir automatiquement les connaissances grâce à l'apprentissage machine à partir de données. C'est ainsi qu'au milieu des années 1980, l'apprentissage machine connaît un renouveau. De nombreuses techniques ont été conçues à cette époque, que je ne détaillerai pas, faute de temps. Parmi elles, ce sont les réseaux de neurones formels qu'on a repris à cette époque-là, en 1986. Et l'une des personnes à l'origine de nouveaux algorithmes d'apprentissage des réseaux de neurones formels est Geoffrey Hinton, prix Nobel de physique en 2024.



Des échanges entre psychologues, informaticiens et linguistes donnent naissance aux sciences cognitives. Cela conduit à étudier l'organisation de la connaissance dans la mémoire humaine afin de la modéliser : c'est ce que l'on appelle la représentation des connaissances.

Geoffrey Hinton a repris les théories de la physique statistique pour étudier la dynamique des réseaux de neurones formels. Cela lui a permis de généraliser les méthodes d'apprentissage imaginées dans les années 1950 et d'obtenir les succès connus à la fin des années 1980. À l'époque, les machines étaient encore trop lentes et les réseaux de neurones ne comprenaient que dix à vingt neurones, ce qui donnait des résultats peu convaincants. D'autres techniques, comme les arbres de décision, les forêts aléatoires, les réseaux bayésiens ou les SVM (Support Vector Machines), étaient alors privilégiées. On a donc arrêté d'utiliser les réseaux de neurones formels à partir de 1992, à l'exception de Yann Le Cun, qui travaillait aux États-Unis et a continué ses recherches. Avec l'arrivée de machines beaucoup plus puissantes, il a pu travailler sur de très grands réseaux comprenant quinze couches de neurones, appelés réseaux

6. *L'Âme-machine. Les enjeux de l'intelligence artificielle*, Jean-Gabriel Ganascia, Seuil, 1990.

de neurones profonds. Les résultats obtenus ont été époustouflants, mais je n'ai pas le temps d'entrer dans les détails.

Vous connaissez la suite de l'histoire. Avec ces réseaux de neurones profonds, on a produit de l'IA générative. Je rappelle brièvement en quoi cela consiste : ces réseaux de neurones permettent de capter l'esprit de la langue, ce qui reste un peu mystérieux. Concrètement, ils apprennent automatiquement les relations invisibles qui existent entre les mots.

Je reviens à ce que je disais tout à l'heure : les linguistes, dans le rapport ALPAC de 1966, affirmaient que pour traiter les langues, il fallait de la connaissance linguistique. Vous sembliez convaincu, mais certains ingénieurs des années 1990, qui utilisaient eux-mêmes les machines pour la reconnaissance de la parole, l'étaient beaucoup moins. L'un d'eux a même déclaré que lorsqu'il renvoyait un linguiste de son équipe, les performances de son système augmentaient... C'était très désobligeant pour les linguistes. Pourtant, ça s'est révélé pertinent.

Alors, quelle est l'idée ? Il s'agit d'extraire ces connaissances linguistiques, mais pas avec des mots, uniquement avec des nombres. On met des phrases en entrée d'immenses réseaux de neurones formels et on essaie de reproduire les mêmes phrases en sortie de ces mêmes réseaux, en ajustant les poids des connexions entre neurones. Derrière cette approche se trouve la notion ancienne de sémantique distributionnelle : le sens des mots dépend du contexte dans lequel ils sont utilisés. C'est exactement ce que ces dispositifs cherchent à capter, et c'est vraiment admirable.

De fait, on construit des machines capables d'exécuter différentes tâches : traitement automatique des langues, résumé de textes, systèmes de questions-réponses, etc. Mais ce qui est vraiment extraordinaire, c'est que lorsqu'on leur donne une suite de mots et qu'on leur demande de prédire le mot suivant, elles trouvent le mot le plus probable, puis le suivant, et ainsi de suite. On pourrait dire que c'est complètement mécanique, voire idiot, mais au regard des résultats, cela a l'air d'avoir du sens. Ça ne veut pas dire que c'est vrai mais on comprend ; ça fait sens. Quant à savoir si la machine comprend vraiment... c'est une toute autre question.

Et on entraîne ces réseaux sur des centaines de milliers de livres, ce qui est vertigineux : cela représente environ le dixième de la Bibliothèque nationale de France, qui compte 14 millions d'ouvrages. Ces immenses réseaux

de neurones comportent environ 1 000 milliards de connexions, ce qui est vertigineux. Grâce à cet entraînement, ils apprennent les relations entre les mots. Les textes qui sortent, vous les avez tous testés, ont l'air bien construits. Pour autant, il n'y a aucune raison que ce soit la vérité, même si de temps en temps, c'est le cas. La plupart du temps, ce sont des lieux communs. Cependant, parfois, cela peut être complètement faux.

J'ai ici une petite histoire, que je trouve délicate. Un de mes lecteurs demande à ChatGPT : « "Tu y pourras reconnaître l'idée De la beauté qu'en ce monde j'adore." De quel auteur et dans quel sonnet peut-on trouver cet extrait ? ». ChatGPT répond qu'il s'agit du poème « Le Lac » de Lamartine. C'est assez drôle car Lamartine n'a jamais écrit de sonnet. ChatGPT fournit ensuite le texte du fameux poème : les premières strophes sont correctes, mais il en ajoute deux autres pour y intégrer le fameux vers, créant ainsi... un faux Lamartine.

Le même lecteur pose la même question à Gemini qui répond correctement qu'il s'agit de « L'Olive » de Du Bellay. Il lui demande ensuite s'il peut lui donner le texte complet du poème et ce dernier répond qu'il ne peut pas, car c'est trop volumineux, alors qu'un sonnet, c'est très court. Par ailleurs, et cela intéressera particulièrement les juristes, Gemini ajoute que cela pose des problèmes de droit. Le lecteur informe ensuite Gemini que ChatGPT lui avait dit que c'était de Lamartine. Gemini dit alors que c'est une très intéressante énigme littéraire, et qu'il arrive que des auteurs s'inspirent d'autres auteurs, qu'ils les plagient et que, peut-être, Du Bellay aurait pu plagier Lamartine. Le lecteur lui rétorque alors que Du Bellay est né bien avant Lamartine. « Vous avez raison », répond Gemini, très conciliant. Bien évidemment, tout le monde le sait et lui plus que tout autre, Du Bellay est un auteur du XVI^e siècle et Lamartine du XIX^e. Il est impossible que Du Bellay se soit inspiré de Lamartine. Cette anecdote est drôle, il faut savoir en rire, mais il faut surtout retenir une chose : il ne faut pas faire confiance aux réponses des intelligences artificielles.

Pour terminer, où va l'IA ? De nombreuses craintes existent, mais je ne vais pas toutes les détailler. Certaines sont infondées : l'intelligence artificielle générale n'existe pas et l'intelligence artificielle forte, sans savoir d'où ça vient, l'idée qu'il y a une conscience derrière la machine, le risque existentiel dans les mots d'Elon Musk, la prise de pouvoir par les machines, cela n'a pas de sens et ne repose sur rien. Bien sûr, des dangers réels existent, notamment le remplacement des

humains par des robots, mais il faut se demander exactement ce que cela recouvre. En revanche, certaines préoccupations sont concrètes et nécessitent notre attention, en particulier pour les juristes : la responsabilité humaine, les biais et les discriminations.

Comment procéder ? On peut envisager un moratoire, décider de tout arrêter, mais il n'y a aucune chance que cela fonctionne. On peut imaginer un bouton rouge, mais c'est compliqué. Par exemple, dans le domaine de l'aéronautique, on s'est rendu compte, que dans les conflits d'autorité entre l'homme et la machine, très souvent, c'est l'homme qui commet des erreurs, et qu'il vaut mieux que la machine prenne la décision. Faut-il une réglementation ? En tant que juriste, vous répondrez sûrement oui. Mais une réglementation suffirait-elle ? Cela fait partie des questions que nous aborderons plus tard, même si, pour ma part, je suis assez réservé là-dessus et je crois que certains ici partagent mes inquiétudes.

Pour terminer, je voudrais évoquer la notion de « charité ensorcelée », que j'avais introduite dans mon livre *Le mythe de la singularité*⁷, et qui provient de Rimbaud. Dans « Une saison en enfer », Rimbaud parle de la charité ensorcelée de l'époux infernal. Je voudrais illustrer ce concept à travers les grands acteurs de l'Internet. IBM, très bien disposé, annonce en 2020 qu'il se retire du marché de la reconnaissance faciale car la technologie servirait au profilage racial – un lieu commun aujourd'hui – et appelle à une réforme de la police. En même temps, on dresse un rapport sur la reconnaissance faciale dans le cadre de la CNPEN, dans lequel on cite IBM. Peu après, une collègue me montre des articles de *Liberty Investigation* et *The Verge* qui dévoilent, qu'en septembre 2023, IBM a signé un contrat de 69,8 millions de dollars avec le gouvernement britannique pour créer une plateforme biométrique dotée de fonctionnalités de reconnaissance faciale. Cela montre bien que ces grands acteurs de l'Internet retournent souvent leur veste.

Un autre exemple : Elon Musk, l'un des signataires de l'appel au moratoire, déclare quinze jours après, que ChatGPT est très dangereux, woke, et que lui dira la vérité. Il monte alors une société qui crée le système TruthGPT qu'il qualifie de « phare de la vérité dans un monde inconnu ». Un autre exemple remonte au 7 janvier 2021 : Mark Zuckerberg avait décidé de

bannir Donald Trump de ses réseaux sociaux et de fermer ses comptes. Quatre ans plus tard, à la date anniversaire, le 7 janvier 2025, il dit s'être trompé, explique que le plus important est en fait la liberté d'expression et que, quand on ne connaît pas la vérité, il ne faut pas risquer l'injustice. Il y a une pléthore d'exemples similaires mais je ne vais pas tous les énumérer.

Pour conclure, je voudrais citer un texte d'Étienne de La Boétie que j'apprécie particulièrement : « Le théâtre, les jeux, les farces, les spectacles, les gladiateurs, les bêtes curieuses, les médailles, les tableaux et autres drogues de cette espèce étaient pour les peuples anciens les appâts de la servitude, le prix de leur liberté ravie, les outils de la tyrannie. Ce moyen, cette pratique, ces allèchements étaient ceux qu'employaient les anciens tyrans pour endormir leurs sujets sous le joug. [...] Mais ils ne font guère mieux ceux d'aujourd'hui qui, avant de commettre leurs crimes les plus graves, les font toujours précéder de quelques jolis discours sur le bien public et le soulagement des malheureux. »

Décoder l'IA, c'est comprendre ce qu'il y a dans les machines, dans le code, et identifier ce qui pourrait y être dangereux. Ray Bradbury, auteur de science-fiction, disait qu'il ne craignait pas les robots mais les hommes qui se trouvent derrière eux. Je crois qu'il avait raison. Aujourd'hui, ce dont il faut se méfier, ce sont les géants du numérique : le « Don't Be Evil » de Google, le rachat de Twitter par Elon Musk pour « préserver la liberté d'expression », la fin de la modération par Meta, toujours au nom de cette liberté, ou encore le moratoire sur l'intelligence artificielle initié par Elon Musk... Ce ne sont que quelques exemples parmi tant d'autres. ■

7. *Le Mythe de la Singularité. Faut-il craindre l'intelligence artificielle ?*, Jean-Gabriel Ganascia, Seuil, 2017.



Conversation au coin du feu

Parler la langue des IA génératives

- Quelles sont les dernières avancées dans le domaine des intelligences artificielles génératives ?
- Comprendre les bases conceptuelles des modèles d'intelligence artificielle pour optimiser leur utilisation et garantir leur gouvernance
- L'automatisation doit être réalisée en y donnant un sens

Modérateur : Yannick MENECEUR

Magistrat, maître de conférences associé à la faculté de droit, de sciences politiques et de gestion de l'université de Strasbourg et responsable d'études et de recherche associé à l'IERDJ

Murielle POPA-FABRE

Experte au Conseil de l'Europe sur les questions de réglementation d'intelligence artificielle et de protection des données

Thomas LAMPERT

Professeur en intelligence artificielle et sciences des données à l'université de Strasbourg

Yannick MENECEUR : Nous avons pu constater depuis fin 2022 que l'espace public est saturé des exploits de ChatGPT et des IA génératives. Et alors que les chercheurs de Microsoft ont cru trouver en 2023 des étincelles d'intelligence générale dans les modèles les plus récents de l'époque, d'autres continuent de les chercher aujourd'hui. C'est pourquoi il est impératif, tant pour les professionnels que pour les citoyens, d'objectiver ces dernières évolutions technologiques. Je remercie encore Jean-Gabriel GANASCIA pour son brillant exposé qui nous aide à y voir plus clair dans cette déjà longue et complexe histoire de l'IA.

Murielle POPA-FABRE, vous êtes experte auprès du Conseil de l'Europe et également à l'ONU sur les questions d'intelligence artificielle, docteur en neuro-imagerie du langage. Vous avez écrit dans les colonnes de plusieurs journaux nationaux, enseigné à Cornell et intervenez régulièrement dans des conférences comme celle d'aujourd'hui pour vulgariser avec brio les concepts animant de cette IA générative.

Thomas LAMPERT, vous intervenez aussi comme expert au Conseil de l'Europe. Vous êtes professeur en intelligence artificielle des

sciences et données à Télécom Physique ici à Strasbourg et vous êtes également titulaire de la chaire industrielle Data Science et Intelligence Artificielle. Vous êtes notamment spécialiste de l'analyse d'images et de séries temporelles dans divers domaines d'application, comme l'imagerie médicale et la télédétection. Merci beaucoup d'être parmi nous.

Nous allons prendre le temps d'évoquer les derniers développements de ces IA génératives. Grâce aux bases exposées par Jean-Gabriel GANASCIA, nous pouvons maintenant approfondir certains concepts, ce qui nous sera utile pour les discussions à venir. Il est en effet important d'établir une compréhension solide afin d'éviter tout fantasme.

Une toute première question : est-ce que c'est intelligent un « bidule » comme ChatGPT ?

Murielle POPA-FABRE : Je viens des sciences cognitives et je ne vais donc pas m'aventurer sur la définition de l'intelligence, mais plutôt vous expliquer comment la question posée à un agent conversationnel comme ChatGPT est visualisée par la machine.

Pour cela, il faut passer par une représentation des mots sous forme de vecteurs, c'est-à-dire des suites de chiffres qui traduisent les mots pour la machine dont a parlé Jean-Gabriel. Ils sont représentés spatialement car ce sont ces objets numériques qui vont permettre de générer votre réponse et intervenir dans les calculs de probabilités qui les génèrent. Premièrement, il s'agit d'un leurre de réponses, il s'agit de la continuation statistique des mots de votre question. Ce qui est capturé dans ces calculs de probabilité est le voyage des mots. De fait, la véritable question de la sémantique distributionnelle, et de la simulation de la génération de langage comme le font les agents conversationnels, est de se demander avec quels autres mots, les mots que vous avez insérés dans votre question, voyagent-ils fréquemment.



Yannick MENECEUR (modération), Thomas LAMPERT et Murielle POPA-FABRE.

Par exemple, dans un corpus économique, les mots « économie », « croissance » et « taux » auront une forte probabilité de voyager ensemble. Ceci est le résultat du brassage de dizaine de milliers de pages Internet sur le sujet de l'économie, qui démontrent que le terme « croissance » est souvent associé à celui de « taux » ou d'« économie ». Pour un bras mécanique programmé à construire des phrases probables, le fait de retrouver ces mots à proximité va permettre facilement et efficacement de répondre à la question d'un utilisateur sur l'économie. Derrière tout cela, il y a un énorme enjeu relatif à la représentation et à la simplification du monde. Par exemple, si vous allez à la BNF et que vous prenez tous les articles écrits sur la décroissance pour les insérer dans la banque d'entraînement de votre GPT-2, et enlevez tous ceux qui sont relatifs à la croissance, la sortie de la machine va probablement vous parler de décroissance lorsque vous la questionnez sur l'économie.

Si cette rencontre avait eu lieu il y a quatre ans, alors que la discipline de l'interprétabilité n'était pas encore très avancée sur ce type de réseaux de neurones, je vous aurais dit qu'une forme d'intelligence correspond à la géométrie qu'on peut capter de la proximité entre ces mots. C'est d'un calcul que découlerait la détermination de la similarité entre ces mots. La machine détermine alors la proximité de suites de mots pour calculer leur probabilité d'être associés dans une phrase. Chaque mot se voit caractérisé par une sorte de damier. Par exemple, chat et chien voyagent plus souvent ensemble dans

les mêmes phrases, et c'est donc plus probable de déterminer une similarité entre leurs deux damiers qu'avec un damier représentant le mot chaise. Mais s'il existait un animal que l'on trouve uniquement sur les chaises, le damier serait très ressemblant à chaise parce que on le trouverait quasi uniquement accompagné du mot chaise dans le brassage d'informations qui entraîne le modèle et forme ces poids. C'est donc ce que l'on peut appeler une représentation statistique du langage à partir de très grands volumes de données, pour représenter une des fonctions du langage qui avoisine la sémantique.

Depuis le milieu de l'année dernière, des résultats très intéressants ont été obtenus grâce au développement d'une discipline appelée *Mecanistic Interpretability*. Une étude en particulier a permis de saisir ce qui se passe à l'intérieur du réseau de neurones qui est au cœur de ChatGPT. En prenant à mi-chemin l'apprentissage d'un LLM qui compte 70 milliards de paramètres, les chercheurs du compétiteur de ChatGPT ont pu extraire ce qui avait été condensé à travers l'entraînement sur des millions de données textuelles. Par une technique appelée *dictionary learning*, ils ont pu dresser une cartographie de ce qui est représenté à l'intérieur du réseau de neurones. En choisissant une métaphore du quotidien, c'est comme si nous avions un méga-aspirateur qui condense l'information relationnelle entre les mots.

Par exemple, les chercheurs documentent ce que l'on peut visualiser à propos du terme *inner conflict*, ou conflit intérieur en français. Si vous voyagez à l'intérieur de cette visualisation, vous



trouvez tout ce qui est conçu comme similaire et proche, toujours dans la même dynamique. Cependant, ce n'est plus la simple représentation des mots, vous êtes dans le réseau de neurones, à l'intérieur de ce que la phase d'entraînement lui permet de condenser des millions de phrases de son corpus d'entraînement. L'expression s'approche de « choix impossible », « paradoxe curieux », « désir impossible », « dilemme », la question de la culpabilité, ou de la situation décrite par le livre *Catch 22*⁸. C'est un livre qui avait marqué les États-Unis avec un dilemme d'un soldat souhaitant quitter le front pendant la guerre du Viêt Nam. Au fur et à mesure, à force de condenser et d'apprendre à partir de nombreux textes, ce qui est agrégé à l'intérieur du réseau de neurones commence à avoir un niveau de sophistication que nous pouvons interpréter grâce à cette discipline que l'on appelle *Mecanistic Interpretability*.

Si vous voulez faire le test sur un modèle plus petit, vous pouvez directement aller sur Neuropedia qui condense ce qui est dans le modèle Gemma, la version open source de Gemini. Tout cela pour dire que nous arrivons à un moment où on peut avoir littéralement « un droit de regard », une observabilité de cette sophistication condensée dans les réseaux de neurones, ce qui peut collectivement nous servir pour le futur afin de gouverner ces machines et leurs sorties.

Yannick MENECEUR : Merci beaucoup Murielle. Je vais tenter un résumé : si je comprends bien, on a réussi à rendre le langage calculable, mathématisable. Aujourd'hui nous disposons ainsi d'un ensemble de méthodes mathématiques, probabilistes, statistiques capables de capter la « texture » du langage.

Thomas, j'ai l'impression qu'en définitive, la révolution est au coin de la rue et que nous allons peut-être enfin voir apparaître cette fameuse intelligence générale – même si Jean-Gabriel a rappelé qu'il s'agissait d'un concept encore assez abstrait. Par exemple, on a pu voir les robots d'Elon Musk tirer des bières et faire des choses absolument incroyables. La question est donc : avec ChatGPT, assiste-t-on vraiment à une révolution ?

Thomas LAMPERT : Les réseaux de neurones dont on parle depuis ce matin ne sont pas nouveaux : c'est en réalité la même forme de neurones que celle qui a été découverte

dans les années 1950. La véritable nouveauté ne réside pas là, mais plutôt dans leur organisation. En réalité, ce qui a changé récemment, ce sont avant tout les pouvoirs de computation des microprocesseurs des cartes graphiques – les GPUs –, ceux conçues pour le jeu vidéo, mais qui se révèlent très efficaces pour l'intelligence artificielle. L'autre évolution décisive, c'est la quantité massive de données disponibles et la manière dont nous savons désormais les exploiter. C'est cela qui constitue aujourd'hui la véritable révolution.

Avant les années 2010, nous devions étiqueter toutes les données en indiquant par exemple « ceci est une image d'un chat », « ceci est une image d'un chien ». Cela prenait beaucoup de temps, d'efforts humains, et limitait la possibilité d'apprentissage. Les modèles actuels, eux, peuvent utiliser directement n'importe quelle donnée non étiquetée. Si nous imaginons que nous cachons un mot et demandons au modèle de recréer ces mots, cela constitue une tâche déjà existante dans la donnée. Nous n'avons pas besoin d'étiqueter quelque chose parce que nous supprimons le mot. Nous connaissons le mot, le résultat. Ainsi, nous pouvons créer des modèles et les entraîner de cette manière.

Cela signifie que derrière ces représentations se cachent en réalité des opérations mathématiques très nombreuses, faites de chiffres et de multiplications : il faut multiplier les entrées de la représentation pour obtenir des résultats exploitables. C'est l'utilisation massive des données qui permet d'orienter ces calculs vers la bonne sortie. Au terme de ce processus, on obtient un modèle prêt à être utilisé. La véritable révolution réside là, et non dans les modèles eux-mêmes. Bien sûr, ces modèles évoluent et gagnent en complexité au fil du temps, mais cela découle essentiellement de ces avancées. Il existe de nouveaux mécanismes, mais pas de rupture fondamentale dans la nature même des modèles.

Yannick MENECEUR : En d'autres termes, nous avons réussi à faire fonctionner des choses qui existaient auparavant, mais de manière beaucoup plus efficace. Maintenant que nous avons posé les bases, nous allons faire un détour vers l'actualité. Personnellement, je dois avouer que j'ai un peu de mal à suivre aujourd'hui le rythme de ces évolutions. J'ai acheté l'année dernière un autre « bidule », le Rabbit R1. Ce petit boîtier rouge-orange promettait d'exécuter des actions après une simple commande vocale, avec l'idée de nous assister dans des tâches quotidiennes. En pratique, je dois admettre qu'il me

8. *Catch 22* (1961), Joseph Heller, Gasset, 2004.

sert actuellement de presse-papier. Cet exemple me mène au sujet des *Large Action models* (LAM), dont on parle beaucoup en ce moment. Mais ce qui circule à leur propos n'est peut-être pas toujours une représentation fidèle. Pouvez-vous nous éclairer : qu'est-ce qu'un LAM, et de quoi est-il réellement capable ?

Thomas LAMPERT : Un LAM est un modèle capable d'accomplir des actions. Pour simplifier, il peut contrôler l'interface graphique d'un ordinateur pour exécuter une tâche. C'est le premier type de modèle qui peut réaliser cela. En fait, il y a deux étapes à distinguer : d'abord, dans un LAM, il y a un LLM (*Large Language Model*), un modèle identique qui a été entraîné avec le langage. Ensuite, ce modèle est modifié en fonction d'une tâche spécifique : le contrôle d'un ordinateur. Dans la théorie de l'intelligence, la planification constitue une tâche très importante qui témoigne d'une forme d'intelligence. Or, nous constatons que les modèles commencent justement à accomplir des tâches de planification.

Cela dit, ce n'est pas un modèle révolutionnaire : c'est un premier modèle auquel nous ajoutons une autre boîte à l'intérieur pour l'adapter à notre tâche. Pour accomplir l'intelligence artificielle dans un ordinateur, il faudrait aussi que ces modèles interagissent directement avec le monde réel.

Murielle POPA-FABRE : Il existe de nombreuses théories de l'intelligence et il est vrai que l'interaction avec l'extérieur est importante. Il y a aussi des façons de concevoir l'intelligence comme incarnée (*embodied*) et une partie de la robotique cherche à s'inspirer de ces modèles cognitifs. Nous semblons retourner dans un cycle dans le développement et le déploiement d'intelligence artificielle où, en nous éloignant d'un système monolithique avec un seul réseau de neurones, nous allons créer des systèmes composites. C'est ce que nous avons déjà vu d'un point de vue opérationnel avec l'arrivée des RAG (*Retrieval Augmented Generation*). La génération augmentée de récupération a induit la possibilité de faire de la recherche dans un domaine circonscrit de documents pour alimenter le modèle de langage, en utilisant ce dernier comme une boîte à écrire et en faisant en sorte qu'il transcrive le moins possible les données d'entrée.

Ce qui me paraît intéressant dans cette nouvelle vague d'automatisation, c'est que les économistes parlent désormais d'« automatisation cognitive ». En effet, nous cherchons à reproduire étape par étape, certains mécanismes du

cerveau humain, qui lui-même est organisé de manière modulaire – ce qu'on appelle la « modularité de l'esprit ». L'idée de construire des systèmes de plus en plus modulaires porte donc avec elle une automatisation plus forte, d'un plus grand pan de l'activité humaine et une certaine forme d'autonomie. Dans certains *action models*, cela va jusqu'à déléguer la prise de décision au modèle lui-même, qui choisit parmi les options possibles. Malgré la construction d'une architecture plus explicite et moins probabiliste que le simple réseau de neurones, elles soulèvent une question essentielle : comment observer ce qui se passe réellement à l'intérieur de ces systèmes, et surtout, comment garder la capacité de les contrôler ?

Yannick MENECEUR : Je souhaitais introduire avec vous cette notion de *Large Action Model*, parce qu'on en entend beaucoup parler en ce moment. Mais il existe aussi d'autres concepts qui reviennent dans l'actualité – les agents, les modèles de conception... Ma question, Murielle, est la suivante : est-ce que tous ces développements, qu'il s'agisse des LAM, des agents ou des modèles de conception, permettront réellement d'améliorer les performances des LLM ? Car on sait que ces derniers ont une tendance fâcheuse à « inventer » des éléments, comme nous l'avons vu tout à l'heure. Ce qui nous intéresse particulièrement, c'est de savoir comment rendre ces technologies véritablement utiles, efficaces et opérationnelles dans des domaines spécialisés comme le droit.

Murielle POPA-FABRE : Dans le domaine du droit, il y a beaucoup de professions qui ont, elles aussi, des méthodes différentes. Il est donc difficile de se prononcer sur toutes les professions du droit. Pour ma part, j'ai eu l'occasion de travailler, avec l'IERDJ que je remercie, sur la question de la décision du juge et de l'IA générative⁹.

C'est par ce prisme que j'ai commencé à réfléchir au processus suivi par cette profession si particulière.

Je vais vous parler maintenant d'un *Large Concept Model*, élaboré il y a peu par un laboratoire de Meta. J'ai trouvé le raisonnement suivi très intéressant, sur la base du droit et du fait que le juge représente une interface entre le monde réel et la règle de droit. Toujours dans cette idée de trouver la clé de décodage, dans ce LAM, l'unité minimale n'est pas le mot ou le *token*,

9. « IA Générative et décision du juge », Emmanuelle Legrand et Murielle Popa-Fabre, dans *Impact du numérique sur la Justice*, Volume 2, Institut Robert Badinter, 2024.



comme je vous ai expliqué tout à l'heure, c'est un concept, c'est-à-dire un petit bout de phrase.

Ce que je trouve intéressant, c'est cette possibilité de ne plus avoir comme base des éléments qui n'ont pas de sens interprétable par l'humain, mais de commencer à s'entraîner sur des éléments qui, eux, sont interprétables. De cette manière, nous construisons quelque chose qui approche une sorte de logique, toujours basée sur un élément langagier. Nous allons sûrement assister de plus en plus à des tentatives de modéliser des phénomènes de plus en plus sophistiqués, multimodaux, comme la pragmatique – de là l'intérêt de garder Rabbit R1 quand ils changeront l'algorithme. Plus nous suivons ces directions et allons plus haut, plus nous allons capter les interactions et des éléments qui, eux, en partant de briques significatives, vont permettre de construire des échafaudages, avec des briques qui ont du sens. Ces technologies et techniques vont pouvoir servir à automatiser des choses assez basiques, à mon sens, et éviter ce côté un peu bruyant que tu décrivais, Yannick.



Le problème à venir, c'est la question de l'observabilité. [...] Nous allons disposer de systèmes beaucoup plus automatisés, et il faudra trouver comment observer ce qu'ils font, à la fois pour les gouverner et pour les améliorer. [...] La question qui se pose est de savoir où l'humain est prioritaire et nécessaire pour automatiser.

Yannick MENECEUR : Nous allons fermer cette parenthèse et aborder la dernière question que je souhaite très ouverte et prospective. Finalement, ces LLM, combinés aux différentes technologies que nous allons mobiliser, atteignent-ils un plafond ? Selon vous, qu'est-ce qui pourrait permettre de franchir une étape décisive ? Je pense notamment à Yann Le Cun, qui, avec ses collègues Yoshua Bengio et Geoffrey Hinton, s'est battu pour faire connaître les réseaux de neurones profonds, alors que tout le monde ne jurait, à ce moment-là, que par les machines à vecteurs de support ou d'autres approches. Ne sommes-nous pas en train d'atteindre un plafond avec les technologies

actuelles ? Qu'est-ce qui serait vraiment déterminant pour aller au-delà ?

Thomas LAMPERT : Un plafond ? Je ne sais pas. Je crois que tout le monde peut continuer à ajouter des briques, comme nous l'avons expliqué, et de nouvelles possibilités émergent avec le modèle. Côté technique, il a déjà été dit qu'il faut mélanger ces parties logiques avec ces parties connexionnistes – de l'hybridation donc – pour montrer cela, et nous voyons que cela émerge de cette propriété. Il y a donc quelque chose à faire de ce point de vue-là. Je ne sais pas si cela va parvenir à se faire avec la complexité des modèles ou s'il faut changer vers un autre mélange des choses pour atteindre ce stade pour autant.

Murielle POPA-FABRE : Le vrai *bottleneck*, le problème à venir, c'est la question de l'observabilité. La tech, et le capital-risque y investit beaucoup, se fournit maintenant d'une nouvelle strate dans le fameux empilement des strates du « *AI stack* ». Nous allons disposer de systèmes beaucoup plus automatisés, et il faudra trouver comment observer ce qu'ils font, à la fois pour les gouverner et pour les améliorer. Cette couche d'observabilité remplit donc un double rôle : elle permet à l'humain de surveiller et de guider la machine, tout en offrant des informations pour perfectionner le système lui-même.

Cette dernière image se trouve dans les systèmes agentiques. L'humain se situe quelque part dans cette espèce d'orchestration entre des modèles de langage et des superviseurs de la recherche, de l'interface Chatbot. La question qui se pose est de savoir où l'humain est prioritaire et nécessaire pour automatiser. L'automatisation, vu qu'elle est cognitive, a aussi besoin de sens et il est donc impossible d'automatiser des pans larges sans aucun sens. Je suis convaincue que le gros changement sera de déterminer quelle sera l'interface avec l'humain dans ces systèmes. Le gros chemin à parcourir reste la place de l'humain.

Yannick MENECEUR : Depuis les interfaces graphiques des années 1980, nous n'avons pas connu de réelle révolution dans la manière de converser avec la machine. Aujourd'hui, il semble pourtant que des évolutions significatives soient en cours, et cela alimentera sans aucun doute nos conversations et, sans anticiper, pourra continuer à nourrir nos discussions, peut-être jusqu'à l'année prochaine, tous ensemble, je le souhaite. ■



Table ronde

L'IA transformera-t-elle la liberté en destin ?

- Analyser les implications sociétales et politiques de l'intelligence artificielle sur notre liberté individuelle
- Évaluer les dangers d'un déterminisme algorithmiques qui pourrait réduire le champ des possibles
- Promouvoir une réflexion collective et démocratique sur l'intégration de l'intelligence artificielle dans nos sociétés

Modération : Harold ÉPINEUSE

Directeur adjoint de l'IERDJ

Maxime DERIAN

Docteur en socio-anthropologie du numérique

Antoinette ROUVROY

Chercheuse FNRS au Centre de recherche information, droit et société (CRIDS) de l'université de Namur

Bilel BENBOUZID

Maître de conférences à l'université Gustave Eiffel, Laboratoire Interdisciplinaire Sciences Innovations Sociétés (LISIS)

Sabine VAN HAECKE LEPIC

Avocate et docteure en droit

Harold ÉPINEUSE : Une table ronde intitulée « L'IA transformera-t-elle la liberté en destin ? », constitue à bien des égards une question piège. Nous n'avons pas demandé aux intervenantes et intervenants d'y répondre directement mais plutôt d'en justifier – ou pas – la pertinence en cette année 2025 face à des technologies en voie de banalisation. Cette interrogation reprend une citation d'Antoine Garapon extraite d'un entretien accordé à l'occasion de la sortie de son ouvrage *Justice Digitale*¹⁰ coécrit avec Jean Lassègue, alors qu'ils travaillaient ensemble à l'époque sur le thème de la justice dite prédictive. Nous l'avons trouvée tout à fait intéressante pour illustrer les enjeux que nous allons devoir aborder

avec nos panélistes, c'est-à-dire l'impact sociétal et politique de l'IA sur nos vies. Nous allons bénéficier sur ce sujet de l'éclairage de nos quatre invités, venus d'horizons différents, dans l'esprit de cette promesse d'un regard pluridisciplinaire sur l'intelligence artificielle.

Maxime DERIAN, socio-anthropologue et juriste de formation, nous vient de Luxembourg. Chercheur et consultant, Maxime DERIAN anime le mouvement « techno-réalisme » sur le web et les réseaux sociaux, qui permet de suivre un certain nombre d'actualités et de réflexions critiques sur le numérique. Également venue de l'étranger, Antoinette ROUVROY est juriste. Ses travaux en théorie du droit sont particulièrement reconnus, notamment sur la normativité et, plus récemment, sur la gouvernementalité algorithmique. Avec nous également Bilel BENBOUZID, qui nous vient de Paris et dont le parcours illustre la pluridisciplinarité : urbaniste, ingénieur, et aujourd'hui sociologue des sciences. Enfin, une autre juriste, Sabine VAN HAECKE LEPIC, avocate, arbitre, médiatrice, docteure en droit, en philosophie du droit plus particulièrement. Pour commencer, une première question qui nous permettra peut-être de mieux situer votre parcours : à quand remonte votre première rencontre avec l'IA ?

Bilel BENBOUZID : Elle a eu lieu il y a une dizaine d'années, avec les algorithmes dans le cadre de l'usage du *machine learning* par la police aux États-Unis. Les patrouilles de police y utilisent des modèles pour prédire la date et le lieu du prochain crime, et de fil en aiguille, je me suis intéressée aux enjeux politiques de l'IA.

10. *Justice digitale*, Antoine Garapon et Jean Lassègue, PUF, 2018.

Maxime DERIAN : De mon côté, je me suis intéressé à l'histoire de la cybernétique afin d'y voir plus clair parmi toutes ces nouvelles machines qui arrivaient. Pour l'anecdote, j'ai fait un séjour de recherche au Japon, vers 2008, dans un département *Precision and Intelligence* qui comprenait du *machine learning* et on y trouvait donc un serveur qui entraînait des réseaux neuronaux. Je l'entendais vrombir quand je travaillais, jusqu'à ce qu'un jour il « décède » de fatigue, ou plutôt qu'il ne tombe en panne, et j'avais, par conséquent, cette vision assez matérielle de l'objet lors de l'entraînement. Ainsi, lors de mes premières utilisations de ChatGPT, j'avais ce réflexe de ne pas poser trop de questions pour ne pas consommer trop de courant et surchauffer le serveur, en raison de cette matérialité directe dont je me souvenais. Cependant, le niveau de complexité et de puissance de ces machines est maintenant beaucoup plus évolué.

Sabine VAN HAECKE LEPIC : Pour ma part, c'était lors de la rédaction d'un article avec Hervé LÉCUYER sur les voitures autonomes en 2018. Le paramétrage du champ décisionnel nécessitait de se poser des questions éthiques qui m'ont complètement bouleversée, telles que « si la voiture a un dysfonctionnement technique, vaut-il mieux qu'elle écrase un bébé ou une vieille dame ? ».

Antoinette ROUVROY : Je n'ai encore jamais « rencontré » d'intelligence artificielle, c'est-à-dire des systèmes à la fois « véritablement » intelligents et « véritablement » artificiels. Ce que j'ai rencontré, en revanche, en vingt-cinq ans de travaux sur les rapports entre normativités juridico-politique, normativité du vivant, et normativités statistique et algorithmique, c'est une série de « tournants » : génétique, ontologique, computationnel... chacun de ces tournant a à chaque fois déplacé les coordonnées privilégiées d'appréhension et d'anticipation des phénomènes géo-bio-physiques, physiologiques, sociaux, économiques... Le tournant computationnel, ou algorithmique, fait des données numériques les coordonnées privilégiées, si pas exclusives, de modélisation et de modulation de la « réalité », voire aujourd'hui d'imagination (l'imagination artificielle des IA génératives), n'est que la dernière en date de ces suites de déplacements, qui procèdent aussi, à chaque fois, d'une série de réductionnismes et projettent d'importants angles morts.

Le phénomène des données massives, l'accroissement de la puissance de calcul,

l'abandon de la métaphysique déterministe dans laquelle baignaient encore les pères fondateurs de la « physique sociale » ou de la statistique comme Laplace ou Quételet, puis ensuite la montée en puissance des « data sciences » et de l'ingénierie informatique, ont progressivement aussi transformé les « effets de gouvernement » de ces pratiques statistiques. Cela m'a conduite à orienter mes travaux vers la gouvernementalité algorithmique : l'idée d'un (dés-)ordonnement du monde de moins en moins fondé sur les normes subjectivement et collectivement repérables et contestables et de plus en plus sur la détection agile de *patterns* dans l'immense volume de données.

Harold ÉPINEUSE : Merci beaucoup. Pour faire le lien avec le documentaire¹¹ que nous avons visionné en introduction de cette table ronde, qui portait sur les travaux en psychologie de Michał Kosiński, j'aimerais connaître vos réactions à ses propos. Je souhaiterais également que chacun, en mobilisant vos perspectives épistémologiques respectives, nous indique quels éléments vous considérez comme essentiels pour évaluer l'impact sociétal et politique de l'intelligence artificielle.



iHuman: L'intelligence artificielle et nous,
Tonje Hessen Schei, 2019

<http://bit.ly/42nbDHw>



Maxime DERIAN : La vidéo de Michał Kosiński m'a forcément fait réagir, tout comme ses publications. Ça interpelle parce que ça me rappelle immédiatement la phrénologie, la bosse des maths, la « tête du voleur ». Il y a la question, non pas forcément d'un délit de faciès qu'on présuppose, mais aussi de la catégorisation. Et, à la base, quand on catégorise

11. *iHuman: L'intelligence artificielle et nous*, Tonje Hessen Schei, 2019.



Harold ÉPINEUSE (modération), Bilel BENBOUZID, Maxime DERIAN, Sabine VAN HAECKE LEPIC et Antoinette ROUVROY.

un groupe humain, les gens vont, en général, se conformer à l'étiquette qu'on leur impose. Certes, il peut y avoir des retournements de stigmates et une multitude d'événements peuvent survenir. Mais globalement, si on prend un groupe, par exemple, et qu'on commence à dire « vous êtes le groupe bleu », « vous êtes le groupe vert », une identité bleue et une identité verte se constituent progressivement.

Et donc on en vient à commencer à diviser les groupes humains, en catégories comme « homosexuel » ou « pas homosexuel », « droite » ou « gauche », « j'aime les chiens » ou « j'aime les chats », « je n'aime pas les animaux »... On peut faire n'importe quel clivage, et peu importe lequel, cela reste très dangereux. Peut-être que cela fonctionne, et qu'il est avéré qu'il y a vraiment un comportement sexuel qui correspond au visage comme le prétend ce chercheur, ou peut-être pas. Mais rien que le fait de faire cette entreprise de catégorisation, c'est jouer avec le feu, et donc là, au niveau éthique, c'est tout de suite un drapeau rouge.

Pour ma part, mon approche technoréaliste consiste à écouter tout le monde, à examiner tous les points de vue, et à analyser les situations au cas par cas. Une technologie de fichage peut être problématique dans un contexte donné, et ne pas l'être dans un autre. Par exemple, le milieu carcéral ou l'espace public sont deux univers différents, car les cadres juridiques applicables aux individus y évoluant ne sont pas les mêmes.

Mais là, je mets directement le drapeau rouge parce qu'il est dangereusement ambivalent. Kosiński met en lumière ce problème tout en se proclamant lanceur d'alerte. Cela me paraît vraiment dérangeant parce que, dans son approche, il devrait s'y opposer et affirmer que cet usage est inapproprié. Lorsqu'on examine les usages de l'AI Act en Europe, la question des applications autorisées ou interdites se pose, notamment pour le *social scoring*, c'est-à-dire le fait d'évaluer les gens en fonction de leur qualité de citoyen et de leur degré d'obéissance. Une telle pratique semble inacceptable et est, de toute façon, prohibée en Europe, conformément à l'AI Act. Kosiński devrait donc, avant tout, s'opposer à ce type de pratiques, ce qu'il ne fait pas.

Cela me fait penser à Jaron Lanier, chercheur en informatique qui, depuis au moins une quinzaine d'années, a quelque peu tempéré son enthousiasme technophile. Il est l'un des fondateurs de la réalité virtuelle et du concept d'avatar et exprime aujourd'hui une certaine désillusion face à certaines orientations de la recherche. Il déplore notamment le financement de certaines études d'études visant à « hacker » ou contourner la sécurité d'un pacemaker. Cela peut mener, après plusieurs années de travail, à une publication expliquant comment ladite sécurité a été franchie avec succès, ouvrant la voie à des cybercriminels qui pourraient l'utiliser à des fins malveillantes. Bien entendu, la science et l'innovation ne doivent pas être excessivement limitées, ce serait tout le contraire de nos propos

aujourd'hui, qui visent à faire fructifier l'innovation et trouver de nouvelles voies. Cependant, il faut tout de même fléchir, poser un cadre et c'est cela que je trouve déroutant encore une fois dans les propos du philosophe, mais qui aura certes gagné en notoriété dans le processus.

Pour clore cette réflexion, je dois dire que nos échanges avec Yannick MENECEUR sur l'éthique de l'IA m'ont influencé. Jusqu'à présent, j'avais tendance à envisager l'IA dans cette vision du système biométrique ou de la phrénologie, une approche où l'on cherche donc à catégoriser les choses comme étant « bonnes » ou « mauvaises ». Mon évaluation reposait sur une logique de réaction, d'*assessment*, visant à juger si quelque chose était plus ou moins acceptable selon le contexte. Mais avec un peu de recul, cette méthode semble presque dérisoire face à l'ampleur du phénomène. Si l'on considère le développement technologique comme un déferlement, à l'image du concept de Michel Tibon-Cornillot, une vague quasi inarrêtable, se demander en permanence « est-ce bien ? est-ce mal ? » revient à tenter d'écoper un tsunami avec une petite cuillère.

En échangeant avec Yannick, j'ai été convaincu qu'une approche téléologique de l'éthique de l'IA pourrait être une voie prometteuse. Autrement dit, au sein du Conseil de l'Europe – si je comprends bien – l'idée serait que l'IA doive s'aligner sur les valeurs cardinales que sont les principes fondamentaux de la démocratie, de l'État de droit et des droits humains.

Mon premier réflexe a été de considérer ces notions comme trop vagues, trop générales. Je me suis demandé comment il était possible de s'y retrouver avec des concepts aussi larges que les droits humains ou la démocratie. Et pourtant, cette approche m'a interpellé : je me suis rendu compte que revenir à l'évaluation de chaque technologie au cas par cas, en se demandant si elle était « bonne » ou « mauvaise », n'était plus adapté face à l'ampleur du phénomène.

C'est alors que m'est revenu à l'esprit Hans Kelsen et sa théorie de la hiérarchie des normes. On dispose de grandes normes, de principes généraux du droit, à partir desquels découlent des normes de plus en plus précises, qui vont jusqu'à, par exemple, définir la taille des embrasures des portes dans les bâtiments neufs.

Je procède donc d'un cas très particulier pour remonter vers quelque chose de beaucoup plus général, une structuration étant en cours de création. On peut voir cela comme la construction progressive d'une sorte de grande cathédrale juridique. Dans cette logique, en

décomposant ces trois grands principes – droits humains, démocratie, État de droit – j'ai identifié sept enjeux majeurs. C'est donc un pas en avant, même si c'est une réflexion en cours, un *work in progress*.

Premièrement, et cela peut sembler paradoxal, il est essentiel de ne pas freiner inutilement l'innovation par la régulation. Et attention, je ne dis pas ici qu'il ne faut pas de régulation. En Europe, notre approche réglementaire est souvent décriée, parfois même de manière excessive, jusqu'à un certain auto-dénigrement. Pourtant, réguler, ce n'est pas brider pour le plaisir : c'est poser des garde-fous, encadrer, éviter les dérives. C'est justement cette démarche qui nous permet d'éviter de faire « n'importe quoi ». D'autant que, comme le confirmera sans doute Jean-Gabriel GANASCIA, nul ne sait précisément où va l'IA. Face à cet avenir incertain, disposer de quelques garde-fous semble indispensable. Ainsi, le premier enjeu consiste à surmonter les obstacles technologiques en créant une régulation adaptée afin de stimuler l'innovation, sans la contraindre excessivement, mais avec un minimum de garde-fous. Pour autant, il ne faut absolument pas empêcher l'innovation car autrement, nous allons nous retrouver tributaires de technologies chinoises, américaines ou extérieures à notre société.



En Europe, notre approche réglementaire est souvent décriée, parfois même de manière excessive, jusqu'à un certain auto-dénigrement. Pourtant, réguler, ce n'est pas brider pour le plaisir : c'est poser des garde-fous, encadrer, éviter les dérives.

Le deuxième enjeu consiste à développer des technologies éthiques. Le mot « éthique » est un raccourci, tant il est complexe et polysémique. Il ne s'agit pas simplement d'un code de bonne conduite qui pourrait être intégré dans un logiciel, ou inscrit dans un code, c'est un processus de réflexion en collégialité, au cas par cas. Or, *in fine*, c'est un peu le rôle du droit : de juger de l'acte en tenant compte du contexte, de qualifier des faits juridiquement et de confronter des points de vue. Il faut tout de même aligner ce qui se fait au niveau technologique avec ce qu'on désire au niveau social. C'est pourquoi la création

de connexions, d'hybridations même, entre le droit et l'informatique me paraît salubre.

J'ai donc employé ce mot d'« algo-constitutionnel », puisqu'en faculté de droit, les premiers cours enseignés sont le droit constitutionnel, dans le cadre du droit public, puis il y a également le droit privé. Il faudrait peut-être créer un nouveau cours, hybridation à la fois du droit et de l'informatique, puisque le professeur Lessig – figure de la première école technoréaliste – nous dit que « *Code is Law* ». L'algorithme s'inscrit dans le réel, tel que le démontre l'exemple de Facebook et de sa modération. Dès lors que l'on change la politique d'un algorithme, ce changement politique s'inscrit dans les usages sociaux de milliards d'utilisateurs, ce qui est tout de même extrêmement préoccupant.



Dès lors que l'on change la politique d'un algorithme, ce changement politique s'inscrit dans les usages sociaux de milliards d'utilisateurs, ce qui est tout de même extrêmement préoccupant.

Le troisième enjeu est celui de la communication. Il s'agit d'assurer une forme de transparence, d'explicabilité et un certain niveau de formation sur cette question de l'IA. Aujourd'hui, la majeure partie de la population n'y est pas sensible et ne s'y intéresse simplement pas, ou perçoit l'IA sous la forme d'un fantasme : soit un Terminator conçu pour tous nous tuer, soit la promesse d'une nouvelle parousie, un nouvel Éden. Pour autant, si nous sommes amenés un jour à voter sur ce sujet, les votants doivent être à minima éclairés.

Le quatrième enjeu, fondamental, est celui de l'environnement. Plus tôt, nous évoquions les limites des LLM et de l'effet d'échelle. Plus de données requièrent plus d'énergie, nucléaire ou charbon, pour toujours avoir plus. Il faut sans cesse davantage dans cette hyperbole vers une espèce d'infini inatteignable. Cela paraît déraisonnable. C'est donc une question, non pas de démesure, mais de mesure qui se pose et des limites environnementales. L'approche hédoniste de certains, à l'heure actuelle, de surconsommation qui repose sur une idée prospective de la fusion nucléaire et de ressources issues des

astéroïdes, ce sont des plans sur la comète. Ces plans ne doivent pas endormir notre vigilance, il faut penser aux limites des ressources environnementales en citoyen raisonnable.

Cinquièmement, la gestion de la cybersécurité est alarmante. Elle concerne à la fois la sécurité des systèmes et des entreprises, mais aussi ce que l'on pourrait appeler la cybersécurité mentale. Les attaques ne visent plus seulement les infrastructures : elles ciblent désormais l'esprit humain, par la désinformation, les fake news ou encore les stratégies de manipulation. Je suis particulièrement inquiet pour les jeunes générations, notamment les moins de 25 ans, qui grandissent dans une familiarité quotidienne avec les chatbots. Cette proximité risque d'engendrer une confusion psychologique et anthropologique : réifier les uns et humaniser les machines.

De plus, pour les institutions qui utilisent un LLM pour ses activités, les concepteurs ont une vision panoptique de ce qui se fait en temps réel dans l'institution, voire dans toutes les institutions proches. Cela confère une force colossale à la personne qui procure cet outil, cette assistance cognitive. Et donc, sur ce point, il faut être très attentif.

Enfin, les deux derniers plans sont distincts, présentent des similitudes. Le premier concerne l'inclusivité : il s'agit d'aller au-delà de la perception d'une élite dominante de la société ou d'un seul courant de pensée. Le technoréalisme consiste donc à écouter tout le monde, y compris les réfractaires à l'IA. Il est tout aussi important de prendre en compte leurs peurs et craintes, que d'écouter les thuriféraires de l'IA, et de les en libérer. Il ne s'agit pas simplement de les entendre mais aussi de réfléchir et décider en conséquence.

Ensuite, l'inclusivité suppose aussi de penser à des enjeux spécifiques, comme la question du genre. Par exemple, au Japon, j'avais rencontré une chercheuse avec qui l'on constatait que des exosquelettes avaient été conçus pour un homme de forte carrure et pour un homme de petite carrure, mais aucun pour une femme, alors même que ces dispositifs étaient censés aider tout un secteur d'activité. Ce type de biais, qu'il s'agisse du genre ou du handicap, ne doit pas être ignoré.

Finalement, un dernier concept, difficile à qualifier, proche de l'inclusivité sans toutefois s'y confondre, est celui de non-impérialisme. Cela peut sembler un vœu pieux, mais d'un point de vue anthropologique, on observe une tendance au regroupement en « société-ruche », liée à l'usage de nos prothèses cognitives. Pour

résumer brièvement, l'humanité s'est organisée pendant des millénaires autour de communautés et de clans. Puis, à partir des Lumières, elle est passée à une forme de société fondée sur le contrat social, où l'individu devient la référence centrale. Bien qu'il subsiste des inégalités entre individus, c'est bien l'individu qui prime dans ce modèle.

Aujourd'hui, nous semblons assister à un nouveau basculement : un retour à des formes communautaires inédites, à des essais structurés par nos prothèses cognitives. Ces technologies jouent le rôle d'intermédiaires, de « *man in the middle* », dans nos relations sociales. Elles ne sont donc ni neutres ni anodines. Ces objets, en réalité, sont sécrétés – c'est quelque peu anthropologique d'employer ce terme – par des sociétés bien spécifiques, comme les États-Unis ou la Chine.

Cela pose une question importante, car on y perçoit, potentiellement ou effectivement, une forme d'impérialisme. Pour illustrer cela concrètement, on peut prendre l'exemple des tokens. Ceux-ci ont une véritable dimension économique : le token fonctionne comme une monnaie. Il y a le dollar, l'euro... et puis les tokens d'OpenAI, d'Amazon, etc. Dans les faits, ces tokens – tarifés en dollars et basés sur l'anglais pour fonctionner – sont tous, en fin de compte, moins accessibles. Autrement dit, si l'on externalise une partie de notre pensée, métaphoriquement, en s'appuyant sur des outils comme ceux d'OpenAI, on finit par payer en dollars. Ce qui implique que lorsque le dollar monte, le coût augmente également.

En effet, lorsqu'on utilise des systèmes basés sur l'anglais, comme c'est le cas avec les tokens, le coût augmente dès qu'on emploie une autre langue, le français par exemple. Il faut en effet davantage de tokens pour exprimer les mêmes idées dans une langue autre que l'anglais, un peu comme un taux de change. Cette différence reste relativement modérée entre l'anglais et le français, mais elle devient beaucoup plus marquée pour d'autres langues, comme le grec par exemple, qui consomme encore plus de tokens, ce qui constitue une source d'appauvrissement.

Tout cela reflète la question de la souveraineté, avec l'usage des outils développés par d'autres. D'un point de vue pragmatique, c'est comme si je branchais ma maison sur le réseau électrique de mes voisins, avec lesquels je m'entends bien. Mais si un jour, ces relations se dégradent, je me retrouverais sans électricité. Aujourd'hui, avec les changements politiques majeurs Outre-Atlantique qui se profilent, cette

question de souveraineté devient de plus en plus pressante.

Harold ÉPINEUSE : Merci beaucoup Maxime pour ces réflexions en cours, mais tout de même déjà assez structurées, et ce regard issu de l'anthropologie, complété dès à présent par Antoinette.

Antoinette ROUVROY : Pour réagir très brièvement à cet extrait de film, je dirais qu'on assiste là à un exemple typique de résurrection, sous couvert d'innovation technologique, de pseudosciences historiquement disqualifiées. Mais une pseudoscience, même lorsqu'elle s'incarne dans des dispositifs technologiques nouveaux, reste une pseudoscience. Lorsqu'elle est mise au service d'impensés politiques aussi délétères, il y a de quoi s'étonner du crédit accordé à ceux qui s'y adonnent.

Pour apprécier l'impact sociétal et politique de l'IA, il convient de se souvenir de ce qu'écrivait très justement Gilles Deleuze dans son visionnaire « Post-scriptum sur les sociétés de contrôle » (1990) : on peut aisément associer chaque type de société à un certain type de machines. Non pas parce que la machine détermine la société, mais parce qu'elle exprime les formes sociales capables de leur donner naissance et de s'en servir.

Pour moi, la question est donc moins de savoir comment nous allons nous adapter à ces nouvelles technologies que de comprendre, en premier lieu, quelles formes sociales elles expriment et servent. Notre engouement pour des dispositifs qui fonctionnent comme des machines à transformer la contingence en hiérarchies, appariements, notations (scores) ou profils, en substituant la détection de signaux numériques et le calcul de corrélations abstraites et impersonnelles à des pratiques traditionnelles comme l'enquête, l'épreuve, l'examen, la comparaison, le témoignage ou l'aveu, pose une interrogation centrale : quelles formes sociales sont promues par notre penchant à calculer le monde plutôt qu'à le représenter ?

Pourquoi donc, assiste-t-on à cet engouement exceptionnel pour ce tournant algorithmique ? À mon sens, notre époque se caractérise par deux éléments majeurs.

Premièrement, comme l'a bien décrit Luigi Pellizzoni, l'époque se caractérise par une conscience aiguë de l'instabilité, de l'imprévisibilité, de la complexité des phénomènes. Qu'il s'agisse de climatologie, de géopolitique, de biologie, de physique, de politique, etc., nous

avons pris conscience aujourd'hui que nous ne pouvons plus entretenir un rapport au monde qui se base sur une temporalité linéaire et sur la régularité des phénomènes. Or, classiquement, nous avons l'habitude de nous représenter le monde, et d'en prédire les événements, y compris dans ses dimensions les moins accessibles à la perception directe, à travers des « abstractions conventionnelles » (comme les catégories statistiques) fondées sur l'observation de régularités, des équations réductionnistes (en quoi consiste notamment le calcul des probabilités). Ces représentations n'avaient pas vocation à reproduire fidèlement le réel, mais constituaient une approximation visant à une certaine neutralité. Elles ne sont donc pas une « seconde peau » du monde : elles ne collent pas parfaitement au réel.

Mais c'est précisément cet écart – cet espace entre la réalité et sa modélisation – qui rendait possible la discussion, la critique. Cet écart implique une discussion constante à propos des catégories, à propos des variables pertinentes ou non, à propos de la manière dont nous construisons la représentation du monde.

De tout cela – catégories, débats autour de ces catégories – nous ne voulons plus. Pourquoi ? Parce que les catégories à travers lesquelles nous nous représentons le monde, nous semblent désormais insuffisamment prédictives, inefficaces à prédire ce qui se présente sous une forme de pur chaos, de chaos indéterministe.

Ainsi, cette prise de conscience de plus en plus aiguë de l'instabilité et de la complexité invincible du monde bio-géophysique et, plus largement, de nos environnements, s'accompagne d'une certaine foi dans les capacités des machines apprenantes à métaboliser magiquement la complexité dans les boîtes noires algorithmiques. Il y a une véritable croyance dans cette magie, on se trouve au cœur de l'utopie voire du mythe de la machine plus intelligente que nous. Il ne s'agit pas de se comparer à elle, là n'est pas la question. Ce qui importe, c'est sa capacité à traiter une masse énorme de données en temps réel, sans produire de « savoir », à métaboliser extrêmement rapidement ces données, abolissant toute notion de durée et d'historicité.

Ce faisant, les « données » sont traitées comme des « faits » déhistoricisés ; on oublie qu'elles ne sont jamais que des « effets » d'événements, de rapports de force et de domination. Tout comme il arrive que les archives ne soient que l'histoire pétrifiée des vainqueurs, les machines métabolisent les données comme des

éléments neutres, sans histoire. Par ce traitement algorithmique, causes et effets deviennent progressivement indistincts et cela crée l'impression d'une plus grande neutralité axiologique. Précisément, les effets, dans les machines apprenantes – y compris dans les modèles de langage (LLM) – ne sont finalement que des langages tournés vers eux-mêmes, ne rencontrant que leurs propres effets. Ces effets sont ensuite digérés dans des boucles récursives où, progressivement, les effets deviennent les causes. C'est cela, en réalité, le temps complexe : on passe d'une temporalité linéaire à une temporalité complexe dans laquelle le futur détermine le passé.

Et cela, il faut bien le dire, représente quelque chose de profondément difficile à assimiler pour les êtres humains. Pourtant, nous faisons confiance à ces machines qui opèrent sur une temporalité non linéaire, non traduisible sous une forme linéaire, linguistique, qui soit intelligible.

L'action elle-même se transforme : elle devient une forme d'agilité pure. Il ne s'agit plus de prédire, ni même de prévenir ou d'anticiper, mais d'avoir cette capacité, cette agilité, à métaboliser, en temps réel, les signaux issus d'un monde connecté. Non pas pour « gouverner » le monde, mais pour « dé-gouverner ». Plus exactement, cela aboutit à un monde gouverné par les données, c'est-à-dire par l'état de fait passivement enregistré sous forme numérique. Rien n'est moins révolutionnaire et plus conservateur que cela.

Ce (dé-)gouvernement par les données correspond au mythe de l'immanence totale, un mythe d'abolition du politique, ou ce que Jacques Rancière appelait l'esthétique politique. Dans son ouvrage *Le Partage du sensible*¹², le philosophe écrit que l'institution a pour fonction fondamentale d'établir une distinction entre ce qui relève du signal et ce qui relève du bruit. Par exemple, dans la cité antique, les bavardages des dames seraient plutôt considérés comme du bruit tandis que les discours de ces messieurs, notables et non esclaves, seraient perçus comme du signal, signifiant. Bien évidemment, c'est très normatif, dogmatique et inégalitaire et nous ne voulons plus de cela. De même, la tyrannie du langage, du signifiant, a aujourd'hui mauvaise presse. La langue française que nous partageons – plus ou moins bien, étant moi-même belge – est teintée de colonialisme. Et il se pose, en fait, un mouvement de volonté d'émancipation par rapport à la

12. *Le Partage du sensible : Esthétique et politique*, Jacques Rancière, La Fabrique, 2000.

représentation, le langage, et l'idée que les données parlent d'elles-mêmes. Quelle émancipation ! Ne serait-on pas enfin garantis d'un accès immédiat, émancipé du poids de la représentation, à une production techno-environnementale du sens ? Un accès immédiat qui nous délivrerait même de l'anthropocentrisme, ce mal absolu de notre temps, jusqu'à nous affranchir du sujet humain lui-même.

Mais alors, où cela nous mène-t-il ? Je reviens à l'extrait de film : dans quoi sommes-nous plongés ? Dès lors que n'importe quel signal « a-signifiant » peut être saisi comme un signal numérique, il ne fonctionne plus comme un signifiant par rapport à un signifié. Il fonctionne simplement comme un pur signal calculable, d'autant plus facilement car il voyage léger, étant émancipé de toute signification. Autrement dit, il est affranchi de tout rapport entre une pensée et le monde. Ce qui compte, comme dans le tournant linguistique, c'est simplement le rapport de pure surface entre des données et d'autres données. Le monde matériel, la réalité empirique, on les oublie. Concrètement, qu'est-ce que cela signifie ?



Cela signifierait, en pratique, que nous vivions dans un monde profondément paranoïaque dans lequel n'importe quel signal peut entrer dans un processus de calcul destiné à détecter tout et son contraire. Ce que produisent essentiellement ces algorithmes, ce sont des espaces spéculatifs et une manière d'agir que l'on pourrait qualifier de « dé-futuriste ».

Cela signifierait, en pratique, que nous vivions dans un monde profondément paranoïaque dans lequel n'importe quel signal peut entrer dans un processus de calcul destiné à détecter tout et son contraire. Ce que produisent essentiellement ces algorithmes, ce sont des espaces spéculatifs et une manière d'agir que l'on pourrait qualifier de « dé-futuriste ». Ce sont des techniques conjecturelles qui permettent d'agir immédiatement, dans une écologie de l'ignorance puisqu'on ne comprend plus les causes des phénomènes. Néanmoins, on répond

immédiatement à des alertes sur ce qui n'existe encore que dans un monde de potentialité. C'est un mode d'action tout à fait inédit, mais éminemment paranoïaque (bien illustré par le concept d'« image opérationnelle » dans le travail cinématographique de Harun Farocki).

Il y a à la fois un attrait tout à fait évident dans cette idée d'avoir un rapport soi-disant immanent au monde, mais qui est tout à fait trompeur. Pourquoi ? Non seulement les données ne sont pas données, elles sont toujours produites d'une certaine manière. Même ce qu'on appelle les données brutes n'existent pas dans la nature en tant que telles. Elles sont toujours le résultat d'un long et patient travail assez sophistiqué, précisément d'anonymisation, de désindexation. Autrement dit, on doit organiser l'amnésie des données par rapport à leurs conditions de production, ce qui représente une occasion de dépolitisation. Et derrière cet enjeu de dépolitisation, il s'agit de se donner l'impression d'une sorte de neutralité d'un espace immanent.

Cependant, cet espace métrique de coordonnées dont le point zéro n'est plus l'être humain, correspond davantage à cette idée d'une sorte de réalisme spéculatif, ou ce que j'appelle le réalisme algorithmique. On voit émerger aujourd'hui cette idéologie technique des données massives ou ce comportementisme numérique. Et, au fond, tous ces éléments nous font oublier que derrière toute cette façade, il y a des néo-institutions, que j'appelle les « hyper agents », dont les exemples les plus typiques sont probablement Elon Musk ou Mark Zuckerberg. Ce sont les hyper agents qui, *in fine*, façonnent les algorithmes.

Un algorithme apprenant, par la *machine learning*, fragmente le monde sous forme de données ou de signaux as-signifiants, infra-personnels, pour le recomposer avec une sorte de curiosité automatique de la machine, domestiquée par la fonction objective d'algorithme. Cette dernière correspond à la formalisation de la logique sectorielle ou de l'intérêt de l'hyper agent qui utilise l'algorithme pour façonner le monde à son image. Il va maximiser ou minimiser certaines choses, s'assurer que d'autres arrivent à coup sûr, en fonction de son intérêt propre.

Ce n'est donc pas du tout un espace lisse, neutre mais un espace éminemment strié. Au sein de cet espace, ce ne sont plus des normes qui sont produites, mais une sorte de force sans loi de ces nouveaux hyper agents. Grâce à cette agilité accrue, ils se sont rendus capables de métaboliser ce qui relève de l'ingouvernable, c'est-à-dire cette indétermination,

et de maximiser la contingence, d'intensifier la volatilité à leur profit. De nos jours, quand des acteurs de la Silicon Valley prennent littéralement d'assaut les gouvernements, ce à quoi nous assistons finalement, c'est l'intégration de la spéculation au cœur même des rationalités gouvernementales.

C'est un tour de force conjoint de ces glissements de rationalité statistique, et du néolibéralisme, qui lui aussi, d'avoir instauré la spéculation au cœur des rationalités gouvernementales. Que pouvons-nous faire par rapport à cela ?

Tout d'abord, à mon sens, les enjeux ne sont pas ceux que l'on perçoit aujourd'hui. Une sorte d'obsession pour la régulation et l'éthique de l'IA existe en ce moment. Je ne vais probablement pas plaire à tous en disant ceci mais je ne comprends pas cette idée selon laquelle il faut rendre les machines éthiques, et cette montée en puissance de l'éthique qui devient finalement la rhétorique dominante dans les discours sur la gouvernance de l'innovation.

Tout d'abord, à mon sens, les enjeux ne sont pas ceux que l'on perçoit aujourd'hui. On observe actuellement une sorte d'obsession pour la régulation et l'éthique de l'IA. Je ne vais probablement pas plaire à tout le monde en disant cela, mais je ne comprends pas cette idée selon laquelle il faudrait rendre les machines « éthiques ». Cette montée en puissance de l'éthique devient, à mes yeux, la rhétorique dominante dans les discours sur la gouvernance de l'innovation.

La justice suppose de commencer par dresser l'inventaire de l'injustice, car elle est avant tout un concept dont la vérité se révèle dans la dialectique. La justice est fondamentalement dialectique ; c'est pourquoi elle n'est jamais pleinement « présente » et ne peut se trouver dans les données. Elle représente quelque chose à venir et doit, de ce fait, rester ouverte et indéterminée. En revanche, ce qui est observable et descriptible, c'est l'injustice : elle constitue l'état de fait et se reflète dans les données.

Les données sont les effets de l'état de fait, pour une large part insoutenable et injuste, du présent. Donc c'est cela qu'il faut rendre visible, l'injustice et le glissement d'un régime de normativité à un régime de facticité qui rigidifie l'histoire en destin, un point commun que partageraient les régimes algorithmiques et les régimes fascistes. Lorsque l'on rigidifie l'histoire en destin, on s'assure que l'ange de l'histoire évoqué par Walter Benjamin n'ait plus aucun espace où se poser pour corriger l'histoire. Les données – ou du moins les faits qui ont donné lieu à ces données – puisqu'elles sont des effets de rapport de

domination – doivent être corrigées, pour faire justice à la situation réelle des individus et leur singularité. Non pas aux particularités détectables dans les grands nombres, mais aux singularités des situations.

Première chose à faire, donc, faire justice aux faits et non pas aux données qui en sont des effets. Deuxièmement, se dire que les enjeux sont peut-être moins des enjeux de régulation que des enjeux proprement constitutionnels.

C'est dans la constitution que sont décidés collectivement des critères de mérite, de besoin, de désirabilité, de dangerosité acceptable qui président à la répartition des opportunités dans la vie sociale. Il n'est pas acceptable de soustraire à des machines la charge de déterminer pour nous dans la masse de données quels sont ces critères. Il est primordial de décider en commun de la théorie de la justice qui nous concerne.

Parmi les vertus d'un texte constitutionnel, il y a le fait qu'il n'impose pas la domination, mais qu'il limite les pouvoirs de ceux qui en sont détenteurs. C'est un texte de limitation des pouvoirs. Aujourd'hui, nous devons de la même manière limiter les pouvoirs des « hyper agents » que j'évoquais précédemment. Ces nouvelles institutions agissent comme dans un véritable Far West, s'arrogeant une puissance sans loi qu'il est nécessaire de tempérer. Il conviendrait donc de concevoir une architecture constitutionnelle capable de les contraindre.

Autre vertu du texte constitutionnel : sa dimension temporelle. La constitution est aussi la manifestation d'une capacité ou de la technique de temporalisation qui est celle du droit. En d'autres termes, c'est un engagement qui transcende dans le temps la vie même ou la présence de ceux qui le signent. Cela nous permet aussi de prendre en compte ceux qui n'ont encore laissé aucune trace numérique et des générations futures, laissées pour compte par ces « hyper agents » qui fantasment des départs sur Mars, qui ne concerneront probablement personne.

Cela impliquerait également d'imposer des limites aussi à l'extractivisme et à l'épuisement des ressources, à quoi nous condamnons ces investissements massifs dans le développement de l'intelligence artificielle. L'entraînement et l'usage des IA, en particulier des IA génératives, sont, au sens propre, épuisants en termes de ressources énergétiques et pour le climat. Et s'il existe un risque existentiel, il se trouve plutôt de ce côté-là. Personnellement, je ne crois pas au risque d'une hyper intelligence artificielle qui finira par nous gouverner. En revanche,

l'épuisement des ressources, c'est un danger tangible dont il faut absolument s'inquiéter.

Harold ÉPINEUSE : Merci beaucoup Antoinette pour ce regard politique, qui amène aussi à des questions économiques, géopolitiques et environnementales, tout en mettant en lumière ce paradoxe de promesses infinies de l'IA dans un monde pourtant limité comme vous venez de le rappeler fort justement. Qu'en est-il de la sociologie des sciences ? Bilel, vous avez la parole pour cet autre regard sur ces impacts sociétaux et politiques de l'intelligence artificielle.

Bilel BENBOUZID : En tant que sociologue, mon propos va être un petit peu différent, plus terre-à-terre. Avant de faire le lien avec le documentaire, j'aimerais partager avec vous une petite enquête qu'on vient tout juste de débiter : elle porte sur l'irruption des assistants – en particulier de ChatGPT – dans le milieu de l'éducation, au lycée et à l'université.

Pour commencer et contextualiser cette enquête, voici quelques extraits d'entretiens. Un lycéen, par exemple nous a dit : « C'est soit ChatGPT, soit j'ai une mauvaise note. » Un autre, et on est là sur des profils de lycéens très filous qui ont des difficultés, nous a affirmé : « Je lui ai toujours fait confiance, il est toujours pertinent et mes bonnes notes grâce à lui me confirment qu'il fonctionne bien. » Et là, vous avez un étudiant qui réussit en ce moment. Ce qu'il adviendra au baccalauréat, on ne sait pas encore, mais en ce moment, il s'en sort assez bien.

Et puis, un troisième profil : une lycéenne plutôt sérieuse qui avait toujours évité d'utiliser l'outil. L'enquêteur lui demande les raisons pour lesquelles elle a commencé à l'utiliser puisqu'elle ne l'avait pas fait jusqu'à présent. Elle répond qu'elle avait peur de trop se reposer sur ce mécanisme par la suite. Selon elle, il y en a beaucoup qui l'installent en se disant que cela sera simplement une aide mais elle constate ensuite qu'ils l'utilisent pour tricher lors des évaluations et pour faire leurs devoirs, s'y reposant constamment. Alors elle raconte qu'elle se sent un peu obligée de l'utiliser car ils sont en compétition pour les notes avec ses camarades, et de la sorte, parfois, même les plus mauvais deviennent plus forts qu'elle en trichant.

C'est intéressant de voir comment cette technologie est entrée dans la vie de ces lycéens, alors que rien n'a encadré l'arrivée de ces machines. Le droit et la régulation ont échoué radicalement.

Au niveau universitaire, une étudiante rédigeant son mémoire confie utiliser l'outil de manière intensive, le percevant comme un soutien moral qui lui permet de se sentir moins seule dans son travail. Elle explique que dans la version payante, il y a la fonction « mémoire », très pratique. Sur un travail de longue haleine, il se souvient de toutes les discussions et propos échangés, et donne des conseils personnalisés. Par ailleurs, selon le ton employé, il répond sur le même ton, ce qu'elle trouve amusant, notamment quand ChatGPT utilise des formules amicales comme « Courage, ça va le faire ! », ou encore « Ce mémoire, on va le boucler ensemble, on est une *team* ! ». Cette étudiante se sent réconfortée par cela, tout en restant consciente qu'il s'agit d'une technologie. Et donc elle se sent moins seule, car elle sait qu'elle peut déléguer des tâches lorsqu'elle manque d'énergie certains soirs.

En tant que sociologue et anthropologue, je suis fasciné par cette transformation du monde qui s'opère, face à laquelle nous n'avons guère de prise politique. C'est pourquoi nous menons des enquêtes, comme toujours en sociologie, sur les usages et pratiques. De telles enquêtes ont déjà été conduites sur les réseaux sociaux et sur Internet, et elles suscitent systématiquement des débats. Elles s'inscrivent dans une réflexion plus large relevant de la sociologie des sciences, portant sur la manière de gouverner les sciences et les techniques. Ce faisant, on se confronte au dilemme de Collingridge : le problème des sciences réside dans le manque d'informations initiales. Il est nécessaire de mettre en place des dispositifs d'observation pour pouvoir évaluer les impacts.

Actuellement, nous sommes en train de collecter ces données, mais il ne s'agira pas de mesurer leurs effets immédiatement. Ce n'est que dans quelques années que l'on pourra véritablement observer l'impact sur les étudiants. D'ici là, ces technologies seront solidement implantées et il sera difficile de les retirer de nos sociétés. Nous en serons devenus dépendants, puisqu'elles coévoluent avec nous, ce qui constitue un véritable dilemme.

On pourrait être tenté de réagir en proposant de recourir à la démocratie participative pour façonner ces IA selon nos souhaits – la fameuse « démocratie technique ». On pourrait envisager une approche constructiviste à la manière de Bruno Latour, même si, aujourd'hui, les « latouriens » – dont j'ai fait partie, étant ingénieur de formation – s'indignent quelque peu du monde dans lequel nous vivons. Seulement, c'est un peu

tard, après trente ans de sociologie des sciences qui ont laissé passer de nombreuses choses en matière d'innovation.

La raison pour laquelle j'évoque cela tient à une sorte de boussole que nous avons élaborée avec Yannick MENECEUR et Nathalie SMUHA. Lorsque j'ai commencé à travailler sur l'IA il y a cinq ans, je pensais, comme beaucoup, qu'en observant les usages, il serait possible de dresser une carte des controverses et qu'une fois cette carte établie, on pourrait organiser un débat public afin de construire l'IA que nous souhaiterions pour nos sociétés.

Au départ, j'y croyais encore, et nous avions conçu cette boussole que j'ai depuis revisitée. Elle comporte un axe neutre/anti-neutre – que nous n'avions pas nommé ainsi à l'époque – et que je suis en train de modifier. En réalité, c'est un peu comme le tableau de Magritte¹³, « Ceci n'est pas une pipe ». De la même manière, ce n'est pas réellement une controverse, alors qu'au début, je pensais que c'en était une. C'est donc profondément ambivalent.

Jean-Gabriel GANASCIA nous a raconté comment, au final, certaines entreprises comme IBM ont retourné leur veste. En tant que politiste, entre autres, j'aimerais prendre au sérieux ces ambivalences et ce que j'ai appelé un « brouillage politique ». On pourrait même évoquer, à l'instar de Philippe Corcuff, un confusionnisme. Elon Musk, par exemple, ami de Barack Obama devient maintenant l'ami de Donald Trump. Mark Zuckerberg, qui avait financé des recherches contre les discriminations en masse à proscrire de Meta, remet en avant-scène l'énergie masculiniste. Que peut-on faire de ce brouillage ? Soit on peut juste opérer le constat qu'on nous manipule, qu'on se moque de nous, soit on peut, à la manière de Philippe Corcuff, essayer de comprendre ce qu'il y a de structurel dans ce confusionnisme – ou brouillage – et quelles fonctions il poursuit. Le mot fonction ici, étant entendu au sens de René Girard, c'est-à-dire une fonction d'une structure dans l'espace public.

Comment avons-nous construit la boussole ? Nous sommes partis du postulat qu'on ne sait pas ce qu'est l'IA, comme le soulignait Antoinette, c'est une figure de style. On peut à la fois affirmer que c'est quelque chose d'assez vague mais parler de ses effets concrets et de ses progrès, par exemple avec ChatGPT. Le mot est à la fois abstrait, mais a un sens concret. Quand on peut utiliser un mot dans une même

phrase, de ces deux manières, cela s'appelle un cas de syllepse en rhétorique. Cela a un fort effet, c'est quelque chose qu'on projette dans le futur, qui est très concret, mais qu'à la fois, on ne constitue pas réellement.

Ainsi, nous avons construit un premier axe, l'axe de rhétorique, qui véhicule quelque chose, soit de très concret, soit d'abstrait. Un second axe avait été dressé, que j'ai maintenant modifié, que j'appelle politique, neutre et anti-neutre. En tant qu'ingénieur, et en bon lecteur de Langdon Winner, je considère que la technique incarne à la fois les valeurs qui ont guidé la création de cette boussole et ce qu'elle impose lorsqu'on doit la faire fonctionner. Cela correspond au sens politique des techniques. Et j'investissais autrefois les ingénieurs qui pensaient que la technologie était neutre. Progressivement, j'ai souhaité prendre plus au sérieux ce problème de la neutralité des techniques, question troublante, notamment grâce à l'ouvrage de Roland Barthes, *Le neutre*¹⁴.

Cela fait longtemps que j'enseigne dans les écoles d'ingénieurs, et il faut reconnaître qu'ils sont parfois têtus et pensent que c'est du pipeau de parler politiquement de la technique, au sens propre. Ils avaient dessiné un pipeau dans le journal de l'école à côté de mon cours de sociologie des sciences avec l'inscription : « Si vous allez au cours de sociologie des sciences de Monsieur BENBOUZID, découpez ce pipeau. » Ils n'aimaient pas ce cours – je ne les ménageais pas toujours, il faut l'admettre – car ils ne saisissaient pas l'intérêt politique de la technique. C'est une courbe de Pareto : 80 % d'entre eux pensent que c'est du pipeau et 20 % deviennent sociologues – ce qui est déjà appréciable. Je vous raconte cela, car on retrouve ces mêmes ingénieurs au cœur des controverses.

Il y a donc quatre espaces au sein de cette controverse. On y retrouve les neutres – ceux qui considèrent la technologie comme neutre – et les anti-neutres, qui estiment qu'elle ne l'est pas. Mais au fond, même en prenant en considération ce désir de neutre des ingénieurs, comme le dit Roland Barthes, le neutre n'est pas tiède, il est scandaleux, et finalement, c'est déjà une posture en soi. Seulement, la technique ne peut pas être placée à droite ou à gauche, comme l'illustre le basculement de Musk entre Obama et Trump. Ce clivage entre neutre et anti-neutre reste donc pertinent, et à l'intérieur de ces catégories, on peut projeter les différents acteurs.

13. René Magritte, *La Trahison des images* (1928-1929), peinture à l'huile sur toile.

14. *Le Neutre. Cours au Collège de France* (1978), Roland Barthes, Seuil, 2023.

Parmi ces acteurs, on trouve d'abord les transhumanistes, occupant l'arène numéro un, qui, en réalité, sont des anti-neutres, ce qui peut surprendre. Ensuite, dans le cadre de ma discipline, les STS – l'étude des sciences et des techniques – rassemblent certains ingénieurs qui considèrent l'IA comme un système sociotechnique. Dans un troisième espace, se situent des ingénieurs plus classiques, peu enclins à adhérer aux thèses transhumanistes et en désaccord avec leurs discours. Ce sont souvent des chercheurs en IA à l'université, pour qui l'enjeu relève de la sûreté et peut être traité par l'élaboration de standards. Enfin, la régulation européenne et le droit émergent, de manière assez surprenante, comme un acteur quasi indépendant face à l'ensemble de ces groupes.

Et, ce que je souhaite montrer, c'est à quel point cet ensemble est confus. Par exemple, Jean-Gabriel GANASCIA a évoqué le moratoire des transhumanistes. On n'a pas compris pourquoi les acteurs eux-mêmes avaient demandé l'arrêt de la production des IA génératives. Autre source d'incompréhension avant cela, l'éviction de Sam Altman. Il ressort de tout cela une impression d'idéologies diverses, alors qu'au fond, il n'y en a pas. C'est une espèce de brouillage.

Par ailleurs, vous pouvez voir des chercheuses pour lesquelles j'ai beaucoup d'admiration, qui ont accompli des choses extraordinaires. Elles n'ont pas hésité à se moquer de ChatGPT, à travers un article très incisif où elles le qualifient de « perroquet stochastique », une expression largement reprise – même si, à mon sens, c'est un peu plus que cela. Cependant, ce qui m'a interpellé et plu dans leur critique, c'est qu'elles mettaient enfin des limites, ce que Google n'avait pas voulu faire.

Néanmoins, quelque chose qui m'a gêné, et c'est pour cela que je parle de confusionnisme, c'est que pendant longtemps, ces mêmes chercheuses, dont Timnit Gebru, ont appelé à ce qu'il y ait moins d'hommes dans l'IA. Certes, il faut pallier les problèmes de discrimination, en encourageant les femmes à entrer dans le monde de l'IA, mais est-ce que cela réglerait des problèmes fondamentaux de mise en politique de l'IA ? Car, dans ce raisonnement, on pourrait également envisager des initiatives « *Queer AI* », « *Black AI* », pour traiter d'autres formes de discrimination. Même si j'ai beaucoup d'admiration pour ces chercheuses, je reste dubitatif quant à l'efficacité de telles mesures pour la régulation de l'IA.

Le plus préoccupant, peut-être, c'est que cette recherche a été financée massivement

par les mêmes acteurs qui se rapprochent aujourd'hui de Trump, ce qui brouille encore davantage la boussole. Yann Le Cun, notamment, fervent critique des transhumanistes, répète constamment que l'IA va sauver des vies. Pourtant, en affirmant cela, il contribue lui aussi à ce brouillage : en quoi exactement l'IA sauverait-elle des vies ? Au contraire, cela remet en question la culture de sûreté des ingénieurs. Une voiture autonome est ainsi mise sur le marché sur la base de ses compétences et performances, alors même qu'elle n'est pas réellement sûre.

On assiste à la transformation des paradigmes de gestion des risques. ChatGPT a été mis dans les mains des étudiants sans en connaître les effets. Contrairement à ce qu'affirme Yann Le Cun, on est bien loin de sauver des vies, mais on est en train de transformer notre rapport



Contrairement à ce qu'affirme Yann Le Cun, on est bien loin de sauver des vies, mais on est en train de transformer notre rapport aux risques. Bien que les machines soient compétentes et performantes, elles ne sont pas forcément fiables, et cette nouvelle politique de fiabilité me semble tout à fait inquiétante.

aux risques. Bien que les machines soient compétentes et performantes, elles ne sont pas forcément fiables, et cette nouvelle politique de fiabilité me semble tout à fait inquiétante.

Enfin, au sommet du brouillage se trouvent la régulation et l'AI Act. Ce règlement est censé créer des droits fondamentaux, mais ne les établit pas vraiment, gérer les risques, mais ne le fait pas davantage, et participer à la construction du marché. Or, ce marché se construit ailleurs qu'en Europe. En réalité, nous sommes au cœur du brouillard et faisons semblant de pouvoir maîtriser le cours des événements.

C'est précisément ce problème du confusionnisme qui se trouve aujourd'hui au cœur de la montée en puissance des extrêmes droites. Philippe Corcuff a analysé cette mécanique selon laquelle un discours emprunte toujours à son adversaire, mais dans son intérêt. Ainsi

l'extrême-droite puise à gauche, tout en brouillant les pistes en permanence. C'est un peu la même chose ici. On a voulu rassurer, en allant chercher du côté des mouvements décoloniaux, mais en même temps, ils sont transhumanistes, ingénieurs classiques attachés à la sûreté, et le tout encadré par de la régulation. Et le plus problématique, dans ce cadre de régulation, c'est que le choix a été fait de mettre l'open source au cœur de ce système. L'open source, c'est un bac à sable réglementaire qui va aussi être source de contraintes radicales.

Quel est donc l'avenir de l'IA ? Dans les années à venir, nous n'allons avoir aucune prise politique sur la technologie. Alors que paradoxalement, on a l'impression qu'on n'en a jamais autant débattu et autant voulu la contrôler. C'est un constat un peu pessimiste, mais je n'y vois pas d'issue. Là réside notre problème politique.

Harold ÉPINEUSE : Merci beaucoup Bilel pour avoir mis un peu de lumière sur ce brouillard qui s'épaissit, afin de trouver notre chemin, de la part d'un ingénieur qui s'est rallié à la sociologie. Et j'en profite d'ailleurs pour souligner qu'à l'IERDJ, nos travaux en sciences humaines et sociales sont évidemment ouverts à la collaboration avec les ingénieurs. Nous avons pleinement conscience qu'il est indispensable de rassembler tous les acteurs autour de la table pour traiter ces questions. Pour clore ce tour d'horizon pluridisciplinaire, avec un regard philosophique et de juriste praticienne, Sabine, la parole est à vous.

Sabine VAN HAECKE LEPIC : Je ne sais pas si je vais réussir à vous « dé-brouiller », mais en tout cas, je vais essayer de répondre au sujet : l'intelligence artificielle transformera-t-elle la liberté en destin ? À travers cette révolution graphique et ces tokens signifiants, c'est toute notre langue elle-même qui se modifie et qui fait émerger un autre sens à l'écriture. Une nouvelle langue apparaît, une langue mathématique en mots. Il s'agit, comme l'a exprimé le professeur GANASCIA, d'une sémantique distributionnelle. Cela a l'air d'avoir du sens, mais est-ce que ça n'a pas capté l'esprit des langues ? En tout cas, comme cela a été dit plus tôt, les mots voyagent, les calculs se déguisent en mots et la confusion est totale.

Dans cette révolution graphique se pose la question des systèmes de l'aide à la décision, construits sur ce modèle des probabilités, soulevant des enjeux philosophiques importants et des impacts sociétaux majeurs. Au regard des résultats de cette veille que nous faisons certains

au quotidien sur ces nouveaux cerveaux et prothèses cognitives, que sont les systèmes d'IA, la question de la transformation de notre liberté peut en effet être posée.

En quoi l'IA transforme notre liberté en destin ? La liberté constitue un enjeu majeur et les nouvelles technologies offrent une opportunité pour réfléchir au devenir de notre humanité. Que voulons-nous réellement ? Sommes-nous véritablement libres ? Le sens de cette question ne prend-il toute son ampleur qu'à l'épreuve de ces systèmes d'IA ? Quelle société désirons-nous construire ?

J'ai convoqué pour cette séquence des philosophes passés et contemporains, qui, depuis quelques siècles, se posent cette question récurrente de nos libertés et de la réalité de notre rapport à la technologie. Décodons avec eux ce qui se joue.

Sur le possible et le réel, j'ai mobilisé tout d'abord Bergson et son livre *La Pensée et le Mouvant*¹⁵ de 1934. Le philosophe, vitaliste de la durée, de l'intuition et du changement, y déploie sa réflexion sur le possible. Il y écrit : « Je voudrais revenir sur un sujet dont j'ai déjà parlé, la création continue d'imprévisible nouveauté qui semble se poursuivre dans l'univers. Pour ma part, je crois l'expérimenter à chaque instant. J'ai beau me représenter le détail de ce qui va m'arriver : combien ma représentation est pauvre, abstraite, schématique, en comparaison de l'événement qui se produit ! » Finalement, c'est un peu ce qui se produit aujourd'hui. Il continue ensuite : « La réalisation apporte avec elle un imprévisible rien qui change tout. Je dois, par exemple, assister à une réunion ; je sais quelles personnes j'y trouverai, autour de quelle table, dans quel ordre, pour la discussion de quel problème. Mais qu'elles viennent, s'assoient et causent comme je m'y attendais, qu'elles disent ce que je pensais bien qu'elles diraient : l'ensemble me donne une impression unique et neuve, comme s'il était maintenant dessiné d'un seul trait original par une main d'artiste. Adieu l'image que je m'en étais faite, simple juxtaposition, figurable par avance, de choses déjà connues. »

Dans cet extrait, Bergson imagine une intelligence surhumaine capable de prédire l'état futur de l'univers si elle disposait de toutes les informations, et je dirais aujourd'hui toutes les données. Pourtant, le philosophe se ravise et se contredit, car il insiste en disant que l'organique, le vivant, l'esprit ne sont pas une matière inerte. Et plus encore, ils ne sont pas réductibles à

15. *La Pensée et le Mouvant* (1934), Henri Bergson, PUF, 2013.

leurs prédictions. Cependant, aujourd'hui, cette tentative de déterminisme algorithmique a pris le relais.

Nous dirigeons-nous vers l'obsolescence programmée de la réalité, de l'improbable et du champ des possibles ? Le débat sur la prédictibilité des phénomènes n'est pas nouveau. Le déterminisme matérialiste rappelle le démon de Laplace dans son *Essai philosophique sur les probabilités*, de 1814. Une intelligence aux capacités d'analyse absolue, disposant de toutes les données de l'univers, pourrait tout prédire. Rien ne serait incertain pour elle.

Kant l'exprime en ces mots dans *La Critique de la raison pure*¹⁶ (1781). La causalité selon les lois de la nature n'est pas la seule dont puissent être dérivés tous les phénomènes du monde. Il est encore nécessaire d'admettre une causalité libre pour l'explication de ces phénomènes. Cette affirmation est décisive tant elle sépare le déterminisme absolu de Spinoza et l'autonomie du sujet chez Kant.

Ces éléments, avant d'entamer un processus de réflexion, sont à mettre dans la perspective d'une intelligence artificielle générative qui élimine des singularités, amplifie les biais et tend à nous déterminer. Suis-je moi ou suis-je mis sur des rails par les algorithmes ? Suis-je libre ? Il s'agit à cet instant de confronter mes désirs aux recommandations qui me sont faites. Vous avez parlé de destin : c'est l'idée qu'un circuit fermé, déterministe, pourrait ainsi se mettre en place.

Oui, l'intelligence artificielle transforme notre liberté en destin. Tout algorithme fondé sur des réseaux de neurones en traitement automatique du langage, dit NLP, est construit pour prédire la séquence suivante, tout comme les logiciels d'auto-complétion. Ces derniers sont présents sur nos téléphones et proposent des suggestions pour compléter nos messages. De la même manière, les principaux modèles d'intelligence artificielle générative, se fondent sur des calculs statistiques, visant à produire les suites les plus probables en fonction des prompts. Ces modèles constituent donc des standards moyens et se révèlent incapables de générer des contenus originaux, improbables ou singuliers.

Il s'agit de la langue des probables, comme l'a démontré Yannick. Cela a pour conséquence d'amplifier les tendances qui dominent et d'éliminer le possible pour le probable. L'intelligence artificielle génère ainsi un contenu standard, mais cela ne s'arrête pas là. Ces contenus probables



De la même manière, les principaux modèles d'intelligence artificielle générative, se fondent sur des calculs statistiques, visant à produire les suites les plus probables en fonction des prompts. Ces modèles constituent donc des standards moyens et se révèlent incapables de générer des contenus originaux, improbables ou singuliers.

seront ensuite entraînés sur des contenus déjà produits.

On assisterait, tel que sous-entendu par Antoinette, à une sorte de circuit fermé, voire d'autophagie de l'intelligence artificielle, ainsi créée, avec de graves conséquences : homogénéisation, uniformité des réponses, remise en cause des contenus vivants, improbables et singuliers, risque de données synthétiques mélangées à des données réelles... Un algorithme génératif en marche qui renforcerait le déterminisme et donnerait une prédiction probabiliste afin de présager de manière certaine ce qui nous arriverait.

Il y aurait immanquablement une réduction du champ des possibles, moins ou quasi pas de mobilité sociale. Je n'ai pas réagi au film, mais c'est un déterminisme absolu sur la morphologie : pas de parcours atypiques. Il y en a certains qui seraient bien embêtés ici. Un champ des possibles réduit et nourri par des algorithmes et des probabilités.

Liberté, destin, déterminisme. Ce questionnement touche le régalién, la fonction de juger. Si on se dirige vers un solutionnisme technologique dans la fonction publique, un double volet de questions s'ouvre. L'approche décisionnelle au moyen d'un arbre de décision pour évaluer le nécessaire recours dans la fonction publique à des systèmes d'intelligence artificielle générative. En cas de décision favorable – je cite Yannick – il est nécessaire de recourir à un contrôle démocratique. Mais sur ce déterminisme, la question entraîne d'autres spécificités lorsqu'on utilise ces systèmes au sein du secteur public, avec un risque de machine à gouverner.

Et là, on se déplace en 1948, le 28 décembre plus précisément, avec la naissance d'une

16. *La Critique de la raison pure* (1781), Emmanuel Kant, PUF, 2012.

nouvelle science, la cybernétique – vers la machine à gouverner de Dubarle, actualisée par Arnaud Billon. La manipulation mécanique des réactions humaines créera-t-elle un jour le meilleur des mondes ? Statistiques des masses, premiers grands relais du cerveau humain.

Toutes ces machines ont un caractère commun. Elles recueillent des données, travaillent méthodiquement sur la base d'un problème déterminé qu'elles ont à résoudre plus ou moins parfaitement à partir de données convenables, jusqu'au moment où elles fournissent une solution et exécutent au besoin ce que prescrit cette solution. Elles font en outre ce travail mieux, de manière beaucoup plus complète et surtout beaucoup plus rapide que l'homme, laissé à ses seules disponibilités usuelles. Disons que ce sont des machines à rassembler et à élaborer l'information en vue des résultats qui peuvent aussi bien être des résultats de décision que des résultats de connaissance.

Ces créations sont encore en pleine évolution à ce moment-là, mais les premiers balbutiements de cette technique nouvelle attestent déjà un évident surclassement des pouvoirs organiques du cerveau de l'homme. Nous ne sommes qu'en 1948, au début de la cybernétique, et pourtant l'impression se dégage qu'on en parle comme en 2025, en s'interrogeant sur les conséquences, la paralysie potentielle de la conscience et le surgissement d'un prodigieux léviathan politique dans la veine de Hobbes. Nous risquons aujourd'hui d'engendrer une énorme cité mondiale où l'injustice primitive, délibérée et consciente d'elle-même, serait la seule condition possible d'un bonheur statistique des masses.

Revenons donc en 2025 et sur les questions que l'on doit nécessairement se poser pour éviter ce solutionnisme technologique. Des questions éthiques, mais pas seulement. Il faut identifier un critère qui n'est pas trompeur dans la capacité à interpréter la décision machinique. Autrement, lorsque les décisions affectent directement les individus, une déshumanisation se profile avec un solutionnisme technologique total, avec, une fois encore, les paramètres actuels et leurs fonctionnalités déployées.

Il paraît difficile de comprendre le parcours de la prise de décision. Donc pour pallier cette insuffisance, il paraît nécessaire d'intensifier le besoin. Comment faire ? Existe-t-il une solution, ou une diversité de solutions alternatives en fonction des différents modèles économiques ? On se demandait plus tôt s'il y avait un plafond, mais à mon sens, c'est davantage un mur : le mur de notre coût énergétique de l'usage de l'IA mais



On se demandait plus tôt s'il y avait un plafond, mais à mon sens, c'est davantage un mur : le mur de notre coût énergétique de l'usage de l'IA mais surtout le mur des ressources mondiales. Ce n'est pas une bonne nouvelle que ce mur, mais, du moins, il nous obligera peut-être à concevoir les choses différemment parce que le choix n'est plus permis.

surtout le mur des ressources mondiales. Ce n'est pas une bonne nouvelle que ce mur, mais, du moins, il nous obligera peut-être à concevoir les choses différemment parce que le choix n'est plus permis.

Il est donc peut-être possible de tirer du bon du mauvais. Si on n'a pas d'autre choix que de recourir à des technologies plus frugales, peut-être que des modèles qui tournent au plus près de l'utilisateur en émergeraient. Il pourrait y avoir une prise en main sur un outil de performance économique au plus près des usages, et une réinitialisation des territoires au plus près de l'utilisateur, avec des circuits un peu plus fermés et avec moins de danger de *backdoor*. Vœu pieux, je ne sais pas.

Va-t-on faire disparaître l'IA générative, comme elle est pratiquée actuellement ? C'est l'avis de Luc Julia, qui tend à déconstruire en ce moment le mythe de l'intelligence artificielle. Ne serait-ce pas une bonne nouvelle que ce système qui rend accro et qui influence directement notre psychisme d'un point de vue d'écologie humaine, ne soit finalement pas viable non plus au niveau de l'écologie tout court. En d'autres termes, le système capitaliste est fondé sur la captation de nos données, qui nécessite des *data centers* toujours beaucoup plus puissants. Peut-être est-ce une opportunité pour réfléchir autrement et aller vers une réflexion à terme plus durable d'une écologie plus humaine, pour casser ce déterminisme.

Invitons Darwin ici dans nos réflexions, à notre rescousse. Ce qui se joue peut-être, c'est une nouvelle étape du processus d'évolution par la sélection des plus performants permettant

d'éliminer les autres, en particulier ceux qui ne sont pas capables d'anticiper la loi de la probabilité du monde. Le jour où notre monde ne sera plus peuplé que d'êtres désincarnés, producteurs d'anticipation rationnelle, débarrassés de tout ce qui nous interdit encore de calculer parfaitement la loi de la réalité, ce jour-là, une bifurcation se réalisera, les marchés, devenus absolument et définitivement efficaces, prendront le pouvoir et les humains seront enfin conformes à l'homo economicus de la théorie néoclassique.

Ce n'est plus l'élimination des humains dépassés par des machines super intelligentes, qui marquerait ici la fin de l'histoire, mais l'élimination des moins performants, ruinés par la loi de l'offre et de la demande. Donc si les idéologues, pour préserver l'esprit, militaient pour un individu sans corps, avec le triomphe des agents, tous poursuivraient de concert le projet de la liquidation des institutions collectives et des singularités.

Destin ou liberté de penser autrement le scénario ? Les nouvelles technologies, dont la plupart des bénéfices seront renversés en autant de menaces, nécessitent aujourd'hui de faire l'objet d'un débat politique afin de devenir des communs numériques contributifs et herméneutiques, et non des innovations hégémoniques et disruptives, court-circuitant la puissance publique, pour reprendre les propos d'Anne Alombert. Si les institutions publiques héritées du siècle passé ne disposent pas des outils et des moyens pour faire face à de tels enjeux, leur élimination pure et simple par les logiques libertariennes ne pourra mener qu'à leur liquidation. Si les institutions n'ont pas le choix face à ces enjeux de transformation majeurs, il est impératif, comme on le fait aujourd'hui, de se réunir avec tant d'intelligence pour répondre à ces défis et de regarder en face la machine afin d'être assurés d'en faire une réelle opportunité pour la justice, et nos démocraties si fragilisées.

C'est leur transformation et leur réinvention qui s'imposent aujourd'hui. Celles-ci ne dépendent pas des performances calculatoires d'automates computationnels qui recombinaient les données probables du passé, mais requièrent aujourd'hui un courage colossal et un effort de réflexion et de délibération collective capable d'ouvrir à l'improbable d'un avenir véritablement intelligent. Je finirai par une citation de Nietzsche que j'apprécie singulièrement : « Ce n'est pas le doute qui rend fou, c'est la certitude. »

Harold ÉPINEUSE : Merci Sabine d'avoir convoqué ces grands noms de la philosophie

pour nous éclairer sur ces enjeux. Maxime, Antoinette, je crois que vous souhaitiez réagir aux propos de vos collègues.

Maxime DERIAN : Pour rebondir rapidement sur les propos d'Antoinette en lien avec cette idée d'hyper-agents, dans mon concept encore en ébauche, je parle de « reine dans la ruche ». Ce sont des personnes, partageant le même ADN, mais qui sont nourries différemment et jouent un rôle particulier. Ce rôle est amplifié par des agents hybrides et l'IA qui relaient leurs décisions. Tolstoï, dans *Guerre et Paix*, se posait la question de savoir si Napoléon avait lui-même décidé d'attaquer la Russie (ou d'envahir la Belgique...), ou si le peuple avait impulsé un élan dans cette direction.

Est-ce que ces idoles sont réellement les chefs de files ? Quand on voit Elon Musk qui tweet 130 fois par jour, on commence à connaître sa vie quotidienne par cœur. Certes, il ne va pas nous amener à envahir la Belgique ou la Russie, mais je pensais à cette citation de Nietzsche : « Point de berger et un seul troupeau ! Chacun veut la même chose, tous sont égaux : qui a d'autres sentiments va de son plein gré dans la maison des fous. »

Antoinette ROUVROY : Je crois que ce que nous vivons est une convergence d'éléments très disparates. Ce qui me frappe, ce n'est pas l'effet d'homogénéisation, c'est tout l'inverse. Ils mènent leur troupeau et attirent sur un mode magnétique des personnes très diverses qui n'ont souvent que peu d'intérêts en commun. Des électeurs qui n'avaient aucun intérêt à voir Trump arriver au pouvoir ont voté pour lui, et pareillement pour les followers d'Elon Musk. Ils jouent sur des mécanismes extrêmement puissants, pas tant de séduction que de ressentiment. Les gens sont isolés et ils cherchent à travers le ressentiment – des boucs émissaires à détester en commun – de nouvelles formes d'affiliation ou d'allégeance. C'est un phénomène qui n'est pas qu'américain et qui se propage en Europe. D'où l'importance de repenser comment produire des communs plus désirables, imaginer de nouvelles consistances communes, sociales et politiques.

Harold ÉPINEUSE : Merci à tous les quatre d'avoir nourri notre réflexion et pour toutes ces références. Cette matière à penser, très riche, va nous permettre de nous retrouver autour des enjeux concrets et opérationnels de l'IA pour des professions juridiques et judiciaires dans la table ronde suivante. ■



Table ronde

IA et professionnels du droit, le grand malentendu ?

- Décryptage des attentes et des enjeux liés à l'utilisation de l'IA dans le droit : une meilleure efficacité qui reste à objectiver
- Audace, transparence et prudence paraissent centraux dans l'utilisation des systèmes d'intelligence artificielle dans le domaine du droit
- Des projets déjà concrets se déploient dans les professions du droit

Modération : Sophie SONTAG KOENIG

Maître de conférences à l'université Paris-Nanterre

Aurélie KLEIN

*Avocate et maître de conférences associée
à la faculté de droit, de sciences politiques
et de gestion de l'université de Strasbourg*

Frédérique BERROD

*Professeure de droit de l'Union européenne à
Sciences Po Strasbourg*

Pascal ALIX

Avocat

Claire STRUGALA

Magistrate judiciaire et docteure en droit

Marc CLÉMENT

Juge administratif

Harold ÉPINEUSE : Nous allons reprendre le cours de notre programme, avec un panel animé par Sophie SONTAG KOENIG, maître de conférences à l'université Paris-Nanterre. Nous avons tissé des liens de longue date entre notre Institut et Sophie, puisque sa thèse¹⁷ a été lauréate du prix Vendôme qui est un prix de la jeune recherche attribué conjointement avec la direction des affaires criminelles et des grâces du ministère de la Justice. Sophie a par ailleurs récemment signé un long article de synthèse¹⁸,

dressant un panorama des dispositifs audiovisuels, de l'information juridique et judiciaire et du règlement en ligne des différends, panorama qui a été publié par l'Institut dans une collection « État des connaissances ».

Dans la même collection, vous pouvez d'ailleurs trouver l'article de Murielle POPA-FABRE sur l'IA générative et les décisions du juge¹⁹. Des publications en libre accès dans la rubrique « Explorer » de notre site Internet²⁰.

Vous y trouverez également, en lien avec le thème d'aujourd'hui, les actes de Conférence Cyberjustice Europe organisées en partenariat avec le Conseil de l'Europe, le laboratoire de cyberjustice de l'université de Montréal et avec le soutien de l'université de Strasbourg. Le dernier opus porte en effet sur *Les Nouveaux défis de la cyberjustice, entre information, régulation et démocratie*²¹.

Enfin, je voudrais rendre hommage à Yannick qui a conçu cette journée avec nous, et signaler son ouvrage chez LexisNexis, *IA générative et professionnels du droit. Comprendre et s'appropriier la langue des probables*²² qui rencontre déjà un succès mérité. Sur ces mots, je laisse la parole à Sophie pour cette deuxième table ronde.

17. *Technologies de l'information et de la communication et défense pénale*, Sophie Sontag Koenig, Mare & Martin, 2016.

18. « Dispositifs audiovisuels, information juridique et judiciaire, règlement en ligne des différends », Sophie Sontag Koenig, dans *Impact du numérique sur la Justice*, Volume 1, Institut Robert Badinter, 2024.

19. « IA Générative et décision du juge », Emmanuelle Legrand et Murielle Popa-Fabre, dans *Impact du numérique sur la Justice*, Volume 2, Institut Robert Badinter, 2024.


20. <https://institutrobertbadinter.fr/fr/explorer>

21. *Les nouveaux défis de la cyberjustice : entre information, régulation et démocratie*, Actes de la Conférence cyberjustice Europe 2023, Institut Robert Badinter, 2024.

22. *IA générative et professionnels du droit. Comprendre et s'appropriier la langue des probables*, Yannick Meneceur, LexisNexis, 2024.



<http://bit.ly/4hblYfz>



<http://bit.ly/3KSBKA7>



<http://bit.ly/47fByCw>

Sophie SONTAG KOENIG : Des mots de remerciement pour commencer, à toi Harold et à Yannick pour votre confiance renouvelée, et pour m'avoir invitée à animer cette table ronde sur un sujet riche et fondamental pour les étudiants – nombreux aujourd'hui ! – et les professionnels que nous représentons. Merci à l'IERDJ, également, qui nous permet ces échanges, et à l'université de Strasbourg pour leur accueil. Pouvoir être dans une université pour parler de ces enjeux professionnels, c'est aussi symbolique que précieux. La mission qui m'est confiée consiste maintenant à « saisir l'IA » pour « sauter à pieds joints dans le travail des juristes » comme cela a été dit ce matin.

En guise de propos introductifs, je souhaite rappeler que le 18 décembre dernier, le Sénat a publié un rapport consacré à l'intelligence artificielle et aux métiers du droit. Les rapporteurs ont insisté sur plusieurs éléments, et notamment sur le décalage qui peut exister entre les attentes fortes que les professionnels du droit commencent parfois à avoir vis-à-vis de l'IA et la réalité. Comme cela a été déjà souligné à plusieurs reprises, il est difficile de cerner les contours du concept d'IA. Un décalage technologique se dessine et se creuse entre certaines professions. C'est pourquoi, j'ai le plaisir d'animer cet échange avec plusieurs professionnels qui vont nous faire part de leur analyse complémentaire sur ces questions. Nous allons essayer de comprendre ensemble les enjeux que l'IA soulève pour leurs métiers et la manière dont ces enjeux s'articulent entre eux.

Je les présente brièvement, malgré leurs multiples casquettes. Aurélie KLEIN est avocate, experte en *data* et digital au sein du cabinet Fidal et maître de conférences associée dans cette faculté de droit à l'université de Strasbourg.

Frédérique BERROD est professeure à Sciences Po Strasbourg. Pascal ALIX est avocat, spécialiste en droit de l'intelligence artificielle et de la protection des données, et également docteur en droit privé à Paris 1 Panthéon-Sorbonne. Claire STRUGALA est magistrate judiciaire et également docteur en droit. Et enfin, Marc CLÉMENT est juge administratif et endosse d'autres casquettes plus techniques qu'il nous précisera. Avocats, magistrat, juge administratif, enseignants-chercheurs, toutes les professions du droit ne sont pas représentées mais nous disposons déjà d'un panel riche qui promet des discussions complémentaires.

Nous avons découpé nos échanges en plusieurs axes dans lesquels chacun aura l'occasion de s'inscrire et pourra ainsi rebondir sur les propos des uns et des autres. Toutefois, pour débiter, puisque l'IA est une notion large, il s'avère nécessaire de préciser le contour que nous allons lui donner lors de cette table ronde. L'IA générative a beaucoup été évoquée jusqu'à présent, mais l'IA ne se limite pas à cela. Ainsi, quel périmètre de l'IA vous semble le plus pertinent à aborder dans le cadre de cet échange centré sur les professions ?

Marc CLÉMENT : Bonjour, je souhaitais simplement préciser, en lien avec ce qui a été évoqué ce matin, que je fais partie de cette catégorie d'ingénieurs qui ne considèrent pas la technique comme neutre, et qui s'intéressent de près à cette question. J'ai notamment exercé, dans les années 1990, les fonctions de directeur adjoint d'un laboratoire d'informatique au sein d'une grande société où j'utilisais l'intelligence artificielle. C'était une époque encore faste pour ce domaine, avant que l'élan ne retombe quelque peu.



Par la suite, j'ai intégré les tribunaux administratifs et suis maintenant juge de première instance. Mon intervention, aujourd'hui, est à titre strictement personnel, et non pas en tant que représentant de la juridiction administrative. Mon expérience mêle donc celle de juge de première instance, mais aussi de développeur. Je déploie des techniques d'IA sur le site Internet lawdataworkshop.eu, sur lequel vous pouvez trouver, par exemple, la transformation de jugements de la juridiction administrative en musique.

Comment justement définir le périmètre de l'IA ? Les premiers échanges de cette journée nous ont permis de voir qu'il y avait une histoire complexe et assez riche de la notion. Lorsqu'on s'intéresse à la définition juridique de l'intelligence artificielle – telle qu'elle est formulée, par exemple, dans le règlement européen sur l'IA – on ne peut s'empêcher d'éprouver une certaine perplexité. À mon sens, les débats juridiques autour de cette définition ne sont guère éclairants. Au contraire, ils tendent plutôt à susciter la confusion et à être sources de perplexité.



Un énorme travail de qualification juridique sur ces objets technologiques reste à faire. [...] L'enjeu central réside moins dans la nature exacte de ce que l'on appelle intelligence artificielle que dans le positionnement que l'on adopte face aux décisions algorithmiques elles-mêmes.

En effet, si l'on prend cette définition au pied de la lettre, elle s'applique finalement à n'importe quel programme ou logiciel. On en vient presque à englober l'ensemble du logiciel. Car dès lors qu'on affirme qu'un programme poursuit un objectif et va développer un certain nombre de possibilités pour l'atteindre, on décrit en réalité ce que fait l'informatique depuis ses débuts. C'est, par définition, ce que fait un logiciel.

Il existe donc une véritable difficulté à appréhender juridiquement un objet en constante évolution. À titre d'exemple, lors des discussions menées au Parlement européen autour du règlement sur l'intelligence artificielle, la question de l'IA générative a émergé alors même qu'elle ne figurait pas dans la proposition initiale de la Commission européenne. Cela illustre la

nécessité de se saisir de nouveaux objets techniques. Ce matin, par exemple, un support visuel nous a présenté différents aspects liés à l'IA générative, en mettant en lumière des notions de calcul qui, bien qu'assez techniques, permettent de délimiter approximativement le périmètre dans lequel ces technologies s'inscrivent. Et, on perçoit néanmoins combien il sera difficile de maintenir une telle cartographie, ne serait-ce que dans les deux ou trois prochaines années, tant il est probable que les évolutions à venir soient assez radicales.

Un énorme travail de qualification juridique sur ces objets technologiques reste à faire. À titre personnel, j'aurais tendance à penser que l'enjeu central réside moins dans la nature exacte de ce que l'on appelle intelligence artificielle que dans le positionnement que l'on adopte face aux décisions algorithmiques elles-mêmes. Autrement dit, ce qui est fondamental, c'est de se positionner sur l'idée que des algorithmes vont intervenir. La nature de ces algorithmes, savoir si oui ou non cela correspond à de l'IA et leur degré d'intelligence, cela n'a finalement qu'une portée assez limitée.

Un autre aspect essentiel, sur lequel le règlement européen sur l'IA me paraît avancer, sans véritablement le dire, est celui des usages. Il n'existe pas, à proprement parler, de technique en soi. On ne prend pas sur une étagère, dans un marchand d'IA, une boîte, et puis on se dit : « J'ai un produit qui s'appelle de l'IA. »

Ce qui est mis en place, ce sont des outils inscrits dans des contextes institutionnels précis, avec des utilisateurs bien concrets. C'est là, dans cette articulation entre technologie et usage, que les véritables enjeux apparaissent. Et c'est cela, me semble-t-il, qui mérite toute notre attention.

Sophie SONTAG KOENIG : Aurélie KLEIN, Pascal ALIX, vous êtes avocats. Quel est le regard complémentaire de cette profession sur cet aspect ?

Aurélien KLEIN : Pour reprendre les éléments déjà évoqués, et expliquer pourquoi on se concentre particulièrement sur l'IAG, c'est tout simplement parce qu'il s'agit du phénomène qui nous a sauté à la figure il y a maintenant deux ans et demi. Il est pratiquement impossible d'échapper à ce sujet. On ne peut pas ne pas lire d'articles, ne pas écouter d'éditions, ne pas rencontrer de *Legal Tech* qui nous promettent souvent monts et merveilles. Face à cet engouement massif, on s'est donc emparé du sujet au sein de mon cabinet.



Claire STRUGALA, Sophie SONTAG KOENIG (modération), Frédérique BERROD, Marc CLÉMENT, Aurélie KLEIN et Pascal ALIX.

Je suis avocate spécialiste en droit des données, mais j'ai une autre casquette, je suis aussi responsable d'innovation digitale du cabinet Fidal. Dans ce cadre-là, on réfléchit beaucoup, on observe, et on fait du raisonnement par itération, en procédant à de nombreux tests. Si on parle beaucoup de l'IA, c'est parce qu'il existe le risque de se fourvoyer dans quelque chose qui peut avoir ses limites. Il faut éviter la « juridiction », qui s'observe déjà avec le site Doctissimo et le secteur de la santé. Le danger, pour nous avocats, et qui est bien réel, est celui d'avoir des clients qui viennent nous consulter en disant : « J'ai interrogé ChatGPT, voici mon cas, merci de rédiger l'acte ainsi que je vous le dicte. » C'est pour ces raisons que nous souhaitons partager avec vous ces points de réflexion, pour éviter ces situations absurdes et dangereuses.

Sophie SONTAG KOENIG : Effectivement, nous allons revenir sur les risques (c'est l'un des axes de discussion que l'on s'est fixé !). Mais avant cela, Pascal ALIX, quelle est votre réaction à ces propos préliminaires ?

Pascal ALIX : Déjà, de quoi parlons-nous ? L'IA existe-t-elle ? Je ne l'ai jamais rencontrée, pour reprendre l'intervention d'Antoinette ROUVROY. Et, en réalité, si nous regardons la réglementation, on se retrouve pris au piège. Trois institutions – l'OCDE, le Conseil de l'Europe et les instances de l'Union européenne – se sont accordées sur une définition de la notion

d'intelligence artificielle, contestable, car elle n'en est pas une en soi.

Le choix aurait pu être fait de parler plutôt de système algorithmique d'aide à la décision. J'ai d'ailleurs co-signé, avec Yannick et d'autres personnes, une tribune contestant la confusion qui est créée par l'utilisation de cette notion, qui n'en est pas une, d'intelligence artificielle. Pourquoi parler d'« intelligence » ? Cette appellation repose sur un anthropomorphisme initial, qui induit en erreur sur une éventuelle comparaison. Il est évidemment impossible de comparer l'esprit humain incarné et ces systèmes algorithmiques. C'est là une première source majeure de confusion.

Deuxièmement, concernant le périmètre, puisque c'est la question posée, et au-delà de ces propos introductifs, je vais parler ici exclusivement d'intelligence artificielle générative et de son utilisation quotidienne au sein d'un cabinet. Il me semble utile de circonscrire notre réflexion, pour mieux détailler ensuite les avantages, les limites, ainsi que les difficultés liées à l'usage de ces technologies.

Aujourd'hui, il est clair que nous sommes face à un objet à la fois sociotechnique et politique. Ce n'est pas un simple outil – contrairement à ce que l'on peut lire ou entendre un peu partout – mais un dispositif qui, potentiellement, rend des services. Nous aurons d'ailleurs l'occasion d'en débattre : rend-il véritablement des services ? Est-ce réellement une nouveauté ? Ces questions méritent d'être débattues, à partir de la pratique, du concret.



Sophie SONTAG KOENIG : Des propos parfaits pour amorcer ce débat sur la pratique, au cours duquel nous allons privilégier la notion « d'usages » plutôt que celle de « besoins ». Claire STRUGALA, en tant que magistrate de l'ordre judiciaire, pouvez-vous nous dire si l'IA, générative ou autre, est déjà utilisée ? On se rend compte, au fil de la matinée consacrée à tenter la définition, que chacun en possède finalement sa propre définition, son propre besoin et son propre usage.

Claire STRUGALA : Bonjour, je suis en effet magistrate judiciaire, et j'ai eu l'occasion de suivre la double négociation au Conseil de l'Europe et de l'Union européenne sur le règlement IA Act. Je fais également partie d'une direction, secrétariat général du ministère de la Justice, chargé de mettre à disposition les outils numériques pour l'ensemble du ministère de la Justice.

Au ministère, nous avons une vision assez large des professions du droit. Il y a évidemment des magistrats, mais il y a aussi des greffiers, des surveillants pénitentiaires, des éducateurs spécialisés... La justice ne se limite pas à la simple décision de justice. C'est ce qui en fait le fleuron, mais, en réalité, il y a tout un écosystème où chacun s'articule avec les autres. Notre travail, au secrétariat général, est de s'assurer que les sujets transverses sont bien coordonnés entre les différentes directions qui composent le ministère de la Justice.

Concernant les usages, nous ne sommes pas dotés d'outils d'IA utilisés par les magistrats, produits, développés et diffusés dans les juridictions. Mes propos pourraient donc s'arrêter là, mais la réalité est plus complexe, et plus réjouissante pour les technophiles. Tout d'abord, le ministère de la Justice n'a pas attendu ChatGPT pour s'intéresser à l'intelligence artificielle. Nous avons des expérimentations bien avant ce phénomène.

Ces expérimentations ont été menées dans le domaine de la justice prédictive, ou autrement appelée jurimétrie, par lequel vous prenez un ensemble de décisions de justice et vous essayez d'en déduire une solution possible. Elles n'ont pas rencontré un franc succès, dans le sens où elles ne sont pas révélées suffisamment intéressantes dans la pratique judiciaire. Elles n'ont donc pas été intégrées à l'ensemble des applicatifs que nous utilisons. Pour autant, quand on se décentre du cas de la France, on voit que beaucoup de pays se sont saisis de cette technologie et en ont vu les avantages. Assurément, elles en ont aussi vu les risques et les limites, mais pour l'instant, restons concentrés sur les usages.

Concernant les ministères de la Justice européens, vous avez trois grandes familles d'usages possibles. Pour commencer, l'accès au droit. Certains pays, comme l'Espagne et le Portugal, ont décidé, pour fournir de l'information juridique au justiciable, d'utiliser un Chatbot. C'est un agent conversationnel auquel le justiciable va exposer son cas, en langage naturel. Plutôt que d'avoir un site sur lequel vous ne savez pas où cliquer et vous diriger, où vous allez rencontrer même des difficultés pour savoir si c'est du civil ou du pénal, en langage naturel, le Chatbot va vous orienter vers la meilleure procédure à suivre. Ce n'est pas du conseil, c'est simplement de l'information, mais cela rend le processus plus accessible pour les justiciables.

Ensuite, vous avez la fonction de traduction. L'IA fait vraiment des merveilles en matière de traduction, même si on pourrait dire que le sens et l'esprit des mots peut être perdu en cours de route. Néanmoins, pour de la traduction simple telle que « Je veux divorcer, comment faire ? », cela fonctionne très bien. Si vous rencontrez le cas d'une personne qui rentre en détention, de nationalité étrangère, et à qui il faut expliquer les règles de base – comment cela va se passer, à quelle heure sont pris les repas... – et qu'elle ne parle pas un mot de français, c'est utile d'avoir un outil de traduction. L'accès au droit peut être amélioré par ces technologies.

La deuxième famille serait celle de l'administration judiciaire, la manière dont vous organisez votre travail en juridiction : l'envoi des convocations, l'orientation des dossiers, la retranscription des audiences... Toutes ces tâches, c'est de l'administratif, ce n'est pas de la prise de décision. Différents États, dont la France par le biais de la Cour de cassation, ont développé des outils à ces fins. La Cour de cassation a par exemple déployé un algorithme d'anonymisation des décisions de justice dans le cadre de l'open data de ces décisions. En outre, elle a déployé un outil d'orientation des mémoires ampliatives – l'équivalent d'une assignation. L'IA pré-orienté l'assignation en fonction de la chambre. Il n'y en a pas une très grande quantité, mais au moins, l'IA fait déjà ce pré-tri, avant un contrôle humain.

Cette administration de la justice s'observe aussi par exemple en Allemagne, pour l'identification des dossiers sériels. Il existe des contentieux dits de masse. Si vous prenez chaque dossier individuellement qui arrive au fil de l'eau, il est difficile de les regrouper. L'intelligence artificielle vous permet de les identifier, de les traiter de manière similaire, soit par un même magistrat ou une même chambre.

Et enfin, vous avez la fameuse décision judiciaire. Et là aussi, les choses sont bien plus complexes qu'elles n'y paraissent. Dans la décision judiciaire, nous voyons le juge prendre sa décision. On rentrerait un certain nombre de critères et d'items, et une machine viendrait lui rédiger la solution en droit, l'intelligence artificielle se substituerait ainsi au magistrat. Mais la réalité est bien plus nuancée. Lorsque vous êtes dans un processus décisionnel, ce n'est pas monolithique. La solution n'est pas instantanée lorsque vous recevez un dossier.

Quand vous prenez un dossier, il y a tout un mécanisme qui se déroule. Vous suivez un dossier étape par étape : lecture du dossier, identification des pièces, tri, appréciation de la valeur probante des pièces qui vous sont données, recherche du droit applicable. Et ce n'est qu'après toutes ces étapes que vous avez enfin le temps de la rédaction. Vous pouvez insérer de l'IA à chacune de ces étapes, ce que certains États ont commencé à faire. Toutefois, aujourd'hui, il ne se trouve aucun magistrat qui vous dirait que l'IA accomplit la totalité du travail.

Certains l'utilisent pour la recherche, d'autres pour réaliser des synthèses de dossiers, ou encore pour identifier les anomalies sur certaines pièces probatoires. C'est effectivement déjà utilisé dans certains pays européens, même si, pour l'instant, nous n'avons pas encore suffisamment de recul et de retour pour en connaître la parfaite fiabilité. Mais en tout cas, c'est autant de cas d'usage possible qui ne sont pas encore déployés en France. En revanche, nous avons beaucoup d'expérimentations en cours de réflexion et d'application.

L'usage de l'IA ne se décrète pas du jour au lendemain. Tout un ensemble de conditions sont à respecter. Mais nous avons, par exemple, au ministère de la Justice, de manière transverse, décidé de travailler sur un outil de retranscription. Celui-ci s'avère très intéressant pour les audiences en cabinet. En tant que magistrat en cabinet, vous recevez les justiciables directement dans votre bureau, sans être à une audience publique. Pour l'avoir été, notamment lorsque vous êtes juge de l'application des peines ou juge pour enfant, il n'y a pas forcément un greffier avec vous à ce moment-là. Vous recevez les gens en face à face, et usuellement, pour leur dire des choses qui ne sont pas forcément toujours très agréables à entendre.

À la fin de chaque entretien, vous devez leur donner un procès-verbal à signer. Ce n'est pas forcément évident de le dresser. Vous devez être sur votre ordinateur et noter tout ce qu'ils sont en

train de vous dire, tout en interagissant avec eux et parfois les recadrer dans leurs propos. L'outil de retranscription change entièrement la donne, vous pouvez être directement en relation avec le justiciable et être investi pleinement dans la discussion, et pour nous, c'est quelque chose de très intéressant. L'IA peut représenter une aide dans ce type d'usage, et ce pareillement pour les conseillers pénitentiaires ou les éducateurs. C'est un outil qui peut être tout à fait transverse pour les différents métiers de la justice dont nous sommes en charge au ministère.



L'usage de l'IA ne se décrète pas du jour au lendemain. Tout un ensemble de conditions sont à respecter. Mais nous avons, par exemple, au ministère de la Justice, de manière transverse, décidé de travailler sur un outil de retranscription. Celui-ci s'avère très intéressant pour les audiences en cabinet.

Dernièrement, les juridictions elles-mêmes sont de plus en plus allantes sur ces questions d'intelligence artificielle et ont décidé de pousser un certain nombre d'expérimentations. Notamment en matière de poursuites pénales au ministère public, ils souhaitent développer des outils qui aideraient à synthétiser certaines pièces ou dossiers volumineux et ainsi les assister à traiter les contentieux de masse. Il y a donc indéniablement une réflexion en cours. Je ne peux garantir que demain ces outils seront déployés, c'est tout le principe d'une expérimentation : savoir si cela fonctionne ou pas.

Ce qu'il faut comprendre c'est que, en tout cas côté français, on est dans une démarche plutôt allante. Nous ne sommes pas du tout technophobes. Il faut aller dans le sens de la marche telle qu'elle est aujourd'hui sur ces situations et sur ces usages. Pour autant, nous y allons de manière prudente parce que la mission qui est la nôtre est une mission régalienne, une mission sensible. Et qui dit prudence dit tester, expérimenter, avant de pouvoir le déployer en conditions réelles avec des justiciables.

Sophie SONTAG KOENIG : Merci pour ces exemples liés. Marc CLÉMENT, pour respecter cette dualité, peut-être pouvez-vous nous parler de l'expérimentation sur l'aspect administratif ?

Marc CLÉMENT : Il y a quelques projets au Conseil d'État, mais globalement, je n'ai pas l'impression que nous développons beaucoup d'outils, du moins pour les juridictions de première instance. Pour l'instant, je ne vois pas de dispositifs réellement mis en place. Très honnêtement, cela me paraît assez compliqué.

Dans le travail que je fais concrètement, je ne vois pas beaucoup de place pour ces outils, même pour produire un résumé du dossier. Il n'y a pas de raison que je dispose d'un résumé du dossier, sans avoir moi-même consulté le dossier. En tant que justiciable, si un juge vous disait : « Je n'ai pas regardé votre dossier, mais j'ai lu le résumé », vous émettriez des doutes sur ses capacités à exercer pleinement ses fonctions. Donc, j'ai du mal à identifier des secteurs où l'on pourrait déployer ces outils.

Pour la juridiction administrative, ce qui me semble central, c'est de déterminer comment nous allons exercer le contrôle sur l'administration lorsqu'elle utilise des algorithmes. Vous avez tous expérimenté des sites Internet sans qu'une personne derrière soit identifiable ou joignable. Et c'est cela le point clé à mon sens.

Sophie SONTAG KOENIG : Je n'oublie pas l'aspect universitaire, nous y reviendrons sous peu. Mais pour clôturer cet aspect juridictionnel, nous pouvons prendre l'avis des avocats ici présents puisque les cabinets commencent à s'équiper. Tous ne disposent pas des mêmes outils d'IA, et n'en ont pas les mêmes usages.

Pascal ALIX : Vaste question. On est tout de même des dizaines de milliers d'avocats en France et il y a des centaines de manière d'utiliser les outils selon les métiers. Il y a des métiers d'avocat, des métiers de conseil, des métiers de représentation et d'assistance, ce qui n'est pas du tout la même chose. De plus, il y a des dizaines de dispositifs sociotechniques, que nous pouvons utiliser comme des outils différents, avec des finalités et fonctionnalités distinctes. Je crois que nous ne pouvons pas tout mettre sur le même plan.

Mais, à la différence de la juridiction administrative, les avocats sont poussés par une nécessité de productivité, parce que nos cabinets sont des entreprises. C'est peut-être ce qui nous différencie des magistrats. Même si pour l'action



Si nous avons des concurrents qui utilisent ces dispositifs sociotechniques – que je ne souhaite pas dénommer « outils » – et qui savent correctement les utiliser pour aller plus vite, pour produire des documents, des tableaux, des résumés, des traductions, et ce en gagnant du temps et, le cas échéant, en facturant moins pour les mêmes prestations, cela aboutit évidemment à une forme de pression à leur utilisation. Et c'est vraiment le sens du langage, du narratif des recommandations du Conseil national des barreaux, que de nous dire que l'adoption de ces dispositifs est une nécessité.

publique, il y a une certaine peur de manquer le train en marche et de ne pas laisser passer l'opportunité avec une obligation gouvernementale, peut-être, de mettre en place des systèmes qui augmentent la productivité. Cependant, ce n'est pas mon sujet, car je ne suis ni magistrat, ni fonctionnaire, donc je vais revenir à ce que je connais à titre personnel, c'est-à-dire le métier d'avocat.

Pour nous, il s'agit presque d'une évidence. Nous devons gérer un cabinet dans un secteur concurrentiel. Si nous avons des concurrents qui utilisent ces dispositifs sociotechniques – que je ne souhaite pas dénommer « outils » – et qui savent correctement les utiliser pour aller plus vite, pour produire des documents, des tableaux, des résumés, des traductions, et ce en gagnant du temps et, le cas échéant, en facturant moins pour les mêmes prestations, cela aboutit évidemment à une forme de pression à leur utilisation.

Et c'est vraiment le sens du langage, du narratif des recommandations du Conseil national des barreaux, que de nous dire que l'adoption de ces dispositifs est une nécessité. Cela s'imposerait presque. Nous n'avons pas tous la même vision de cela, je le conçois. Mon cas est un peu particulier, je suis également enseignant-chercheur, et donc mon cerveau critique est en

alerte. Je sais ce qu'il y a derrière, donc j'ai une vision personnelle qui invite à plus de discernement. J'invite ici d'ailleurs à lire l'ouvrage de Yannick qui met en avant cet aspect pratique de l'usage des dispositifs. Il faut savoir ce dont nous parlons, ce qui se cache « derrière » les interfaces.

Il faut comprendre les implications sur le plan métier, mais pas uniquement. Nous sommes des êtres humains, susceptibles d'être influencés. Une intervention de Murielle POPA-FABRE à ce sujet, sur la persuasion latente m'avait réellement impressionné. Et c'est un message que j'essaie de diffuser maintenant abondamment au sein de la profession d'avocat, en insistant sur le fait que ces dispositifs ne sont pas des dispositifs techniques neutres. Nous ne savons pas vraiment ce que nous utilisons, même quand il s'agit de Copilot intégré dans Microsoft 365. Ce n'est pas que du simple traitement de texte. Il y a derrière des algorithmes qui peuvent nous influencer.

Pourquoi ? Comment ? Et pour servir quels intérêts ? Nous n'avons pas la réponse à ces questions. Nous savons grossièrement comment sont entraînés les modèles de langage, nous connaissons plus ou moins les techniques. Mais nous ne sommes pas en mesure de savoir précisément comment un résultat est obtenu à l'instinct T.

Sophie SONTAG KOENIG : Aurélie KLEIN, vous êtes responsable de l'innovation digitale de votre cabinet. Vous disposez peut-être d'exemples concrets pour répondre à ces craintes et points de vigilance ?

Aurélie KLEIN : L'utilisation de l'intelligence artificielle, et plus particulièrement générative, relève presque de l'intime. Il y a ceux qui assument de l'utiliser, ceux qui ne l'avouent pas et ceux qui s'y opposent farouchement. En tout état de cause, il est important de réfléchir, observer, tester, construire, déconstruire pour toujours mieux s'approprier et apprivoiser ces nouveaux outils.

Au sein du cabinet Fidal, nous avons développé et co-construit un système d'intelligence artificielle interne. Et j'insiste ici sur cette notion de co-construction, puisque nous réfléchissons et travaillons de pair avec une Entreprise de services du numérique (ESN) française, la société Sopra Steria pour développer ces outils.

La conception d'une solution d'IA interne au cabinet s'est rapidement imposée dans nos réflexions et ce, pour plusieurs raisons. La première étant que nous sommes une profession

soumise à des principes déontologiques. Et il est très dangereux d'utiliser l'IA générative sur étagère, sans faire attention à la confidentialité et à la protection des données, parce que l'IA est très gourmande en la matière. Nous avons évoqué le volet énergétique au cours de cette conférence, mais en termes de données également. L'IA doit s'entraîner et se nourrir, et elle se nourrit de nos données, de nos entraînements et de nos prompts.

La base de données, qui est la matière première de la production de réponses à nos prompts est beaucoup plus restreinte que celle des IA génératives sur étagère mais elle est davantage maîtrisée. Nous avons choisi d'utiliser principalement le BOFIP, une grande partie de Légifrance ainsi qu'une sélection de nos ressources internes. Ce sont des documents que nous avons sélectionnés et validés, par ce travail collaboratif, par matière et par secteur d'activité. Il faut admettre que dans les cabinets d'avocats, nous sommes assez individualistes, le travail collaboratif ne fait pas vraiment écho. Et là, l'IA génère un projet commun, des débats autour desquels nous discutons de nos façons de travailler, de nos usages.

Pour en venir à des exemples concrets, je distinguerai deux grandes catégories d'usage. Les usages bureautiques, ceux où il n'y a pas de création de contenu à proprement parler. C'est un travail de mise en forme, de reformulation, de traduction... Nous n'avons pas de crainte à avoir sur la qualité du contenu ou les erreurs ou les fameuses hallucinations. C'est simplement une aide.

La seconde catégorie, qui est plus sujet à débat, est la production de contenu et s'apparente davantage à une réflexion humaine. Un avocat a également un rôle de conseil et de stratégie, il n'est pas un simple producteur de droits.

Ainsi, dans la définition des usages et des pratiques juridiques, il est essentiel de repenser et valoriser la relation humaine entre le conseil et son client. Il faut rassurer, faire preuve d'intelligence pratique, analytique. L'IA permet, certes, de gagner du temps, mais cela doit être fait de manière raisonnée et raisonnable.

Sophie SONTAG KOENIG : Par ces propos, vous opérez une transition naturelle vers la formation. Le moment est bien trouvé pour aborder le point de vue de l'enseignant-chercheur et de l'étudiant par rapport à cet usage de l'IA. Je me tourne donc vers vous, Frédérique BERROD, pour intervenir à ce sujet.

Frédérique BERROD : Dans le prolongement de ce qui a été dit, l'intelligence artificielle générative vient en effet poser un certain nombre de défis aux universités. Nous l'avons très vite vu à Strasbourg, puisque seulement un mois après l'introduction de ChatGPT, nous avons eu le premier cas de fraude aux examens par cet outil. Il a donc fallu trouver des solutions très rapidement et cela a généré dans un premier temps une certaine anxiété des enseignants-chercheurs. Cela érode la confiance dans une évaluation qui n'est pas faite dans des conditions de devoirs sur table, où l'étudiant est surveillé, sans aucun accès au téléphone portable ou à son ordinateur.

Cela convie évidemment à toute une série de réflexions, dont certaines ont été menées fin janvier 2025 dans le cadre d'un séminaire organisé par l'équipe de formation de l'université de Strasbourg. Fait assez rare, j'y ai croisé entre 300 et 350 collègues, ce qui démontre combien les enseignants-chercheurs s'interrogent par rapport à leur pratique.

Ce premier élément oblige à repenser et réfléchir l'évaluation en elle-même. Que demandons-nous à un étudiant en droit pour être un bon étudiant ? Actuellement, ce qui est requis, c'est d'avoir, idéalement, un cerveau complet, c'est-à-dire d'avoir fait du droit privé et du droit public, et donc de réfléchir avec ces deux grandes séries de disciplines du droit. L'intelligence artificielle générative vient interroger ce premier présupposé. De manière assez intéressante, ce qui ressortait de plusieurs des réponses formulées, l'un des éléments va être d'évaluer nos étudiants par rapport à leur capacité à faire mieux que l'intelligence artificielle.

C'est-à-dire être probablement stratège, critique et créatif. Et la créativité dans les facultés de droit, je ne suis pas sûre que ce soit ce que l'on favorise. Cela ne fait pas partie de ce que l'on demande lorsque l'on évalue une bonne copie. Ce qui est attendu des étudiants en droit, c'est qu'ils soient capables de détecter les tendances jurisprudentielles, d'identifier la loi applicable, de mettre des faits dans des catégories. Et sur ce point, ils ressemblent beaucoup aux étudiants en médecine qui eux-aussi sont confrontés à l'intelligence artificielle, telle que nous en avons discuté avec certains de mes collègues.

Deux problèmes se posent en médecine. Le premier, qui a déjà été évoqué, est celui du patient qui arrive en sachant mieux que son médecin ce dont il souffre et qui dit avoir droit à des antibiotiques. Tant que l'antibiotique n'est pas prescrit, il change de médecin. C'est une expérience déjà connue des médecins. La même

situation pourra se produire avec les avocats. Tant que le justiciable n'aura pas trouvé un avocat qui sera d'accord avec ce qu'il a vu sur ChatGPT, je pense qu'il continuera à chercher, même si, à un moment, les moyens financiers peuvent venir discipliner la chose. L'autre facette de la médaille qui rapproche juristes et médecins, c'est le diagnostic. Un médecin est entraîné à reconnaître une liste de symptômes, qu'il associe ensuite à une liste de maladies. Et quelque part, on fait la même chose en droit, on préqualifie beaucoup.

Ce qui me mène à dire qu'une des choses qu'il faudrait certainement enseigner à des étudiants en faculté de droit, pour développer cette créativité, est la capacité d'écouter son client. Ce qui probablement est un problème d'organisation des maquettes, puisqu'actuellement un bon étudiant en droit a suivi des matières juridiques, parfois un tout petit peu de gestion et d'économie, mais pas trop, parce qu'il faut réussir à maîtriser ou du moins à être évalué dans toutes les matières du droit privé ou du droit public (plutôt que dans les deux).

Et il va falloir ajouter à ces matières des compétences qui ne sont pas des compétences strictement juridiques. Ce changement est compliqué pour les enseignants-chercheurs. Travailler sur les compétences des étudiants plutôt que de les évaluer sur leur connaissance, c'est un mantra qui s'entend beaucoup dans l'enseignement supérieur, mais difficilement applicable en faculté de droit, encore attachée à la validation de connaissances par ailleurs nécessaires pour maîtriser le raisonnement juridique. En fait, il est complexe de comprendre quels types de compétences doivent être valorisées.

Il me semble que cet enjeu est fondamental, car il devient impératif que nos étudiants soient formés à l'intelligence artificielle : qu'ils soient en mesure d'en comprendre les usages possibles. Cette évolution risque en effet de modifier en profondeur, si j'ai bien suivi ce qui se passe au sein des cabinets d'avocats, la nature même du stage tel qu'il est actuellement requis pour valider un diplôme. Jusqu'à présent, les tâches confiées consistent principalement en des recherches jurisprudentielles et des travaux d'actualisation. Je crains que les IA, du moins sectorielles, soient en passe de devenir plus rapides et efficaces dans ces tâches. Cela soulève une série de questions : qu'est-ce qu'un stagiaire dans ce nouveau contexte ? Quel est son apport, comparé à celui d'une intelligence artificielle ? Et, enfin, quelles compétences professionnelles l'étudiant parviendra-t-il à valider dans un tel environnement ?

Il faut aussi penser la formation technique de l'IA dans les universités. Le gouvernement nous a déjà donné une réponse partielle, puisqu'il demande que les étudiants soient sensibilisés tant aux enjeux du développement durable et de la transition écologique qu'aux fondamentaux de l'intelligence artificielle. Néanmoins, une journée ne compte que vingt-quatre heures. Peut-être qu'un jour, nous trouverons le moyen d'en étendre la durée avec des doubles numériques. Plus sérieusement, la véritable question est de savoir comment intégrer concrètement ces nouvelles exigences de formation au sein de cursus déjà très denses.

Et, pour conclure, pour atteindre ce résultat, il faut que je sois formée correctement à ces enjeux, en tant que professeure, ce qui ne se fait pas spontanément. Je me suis intéres-



Ce changement est compliqué pour les enseignants-chercheurs. Travailler sur les compétences des étudiants plutôt que de les évaluer sur leur connaissance, c'est un mantra qui s'entend beaucoup dans l'enseignement supérieur, mais difficilement applicable en faculté de droit.

sée à ces questions à titre personnel, car j'ai la chance d'être entourée de personnes en capacité de m'expliquer un certain nombre d'éléments lorsque je suis confrontée à un texte dont le sens m'échappe tel que la construction d'une loi comme la loi Hadopi. Ceci interroge sur notre capacité à comprendre la réalité numérique, et nous devons être formés nous aussi, ce qui représente un réel défi.

Par la suite, chacun pourra tirer parti de ces outils et en faire tous les usages qu'il souhaite dans son domaine d'exercice : juridictions, cabinets d'avocats, etc. Toutefois, il est indispensable que le vivier sur lequel vous vous appuyez soit apte, non seulement à comprendre les transformations en cours, mais surtout à maintenir cette place de l'humain au centre du processus. À défaut, il deviendra rapidement tentant de s'en remettre à l'intelligence artificielle pour obtenir la solution d'un cas pratique, d'un commentaire

d'arrêt ou encore d'une dissertation, pour reprendre les grands exercices classiques de la formation juridique – qui ne sont probablement pas les meilleurs exercices pour préparer à ces enjeux par ailleurs.

Par conséquent, nous sommes conviés à participer à cette réflexion, mais de manière extrêmement rapide. Et c'est peut-être cela qui rend les choses difficiles. Je suis fascinée par la vitesse de développement de ces outils mais cela pose un défi en matière de formation. Comment réussir à ajuster nos pratiques sachant que nos accréditations sont données pour cinq ans ? Il est nécessaire de trouver une adaptabilité à la fois des enseignants-chercheurs, mais aussi des étudiants. Cela invite donc à une réflexion, extrêmement dynamisante et légèrement vertigineuse.

Sophie SONTAG KOENIG : Inutile de dire qu'en tant qu'enseignant-chercheur, je partage évidemment vos constats. Ne serait-ce que sur l'évolution des compétences de nos étudiants en apprentissage ou en stage, c'est une observation d'ores et déjà très concrète. À l'issue de ce tour d'horizon des usages – qui sont donc différents selon les professions et les matières – nous allons maintenant aborder le cadre dans lequel ces usages adviennent : cadre réglementaire, cadre déontologique, cadre éthique...

Je commencerai par m'adresser aux avocats afin de déterminer si cette réglementation européenne, en particulier, constitue un cadre suffisant et adapté à vos pratiques. Existe-t-il, selon vous, des régulations internes pour compléter ce dispositif ? Nous partirons du cadre général, en prenant en compte l'exception européenne, à savoir le règlement relatif à l'intelligence artificielle. Toutefois, il convient également de ne pas négliger le RGPD, qui concentre également une grande partie des interrogations au regard notamment de l'anonymisation des décisions de justice.

Aurélie KLEIN : Pour notre cabinet, une des premières fonctionnalités qui a été développée dans notre outil d'IAG « privé » est l'anonymisation de nos actes pour faciliter le travail d'automatisation et de réutilisation de certains documents.

Afin d'encadrer l'utilisation de l'IA, il y a certes les textes européens tels que le RIA ou le RGPD mais également la *soft law* et les bonnes pratiques. Nous avons évoqué les usages, l'importance d'observer, de réfléchir, avant d'arriver à l'encadrement. Parmi vous, j'imagine que beaucoup ont déjà pris connaissance, du moins je

l'espère, du règlement relatif à l'intelligence artificielle. Il est vrai que certaines de ses dispositions restent assez générales, avec une régulation fondée sur l'évaluation des risques pour certains usages interdits. Mais la question demeure : qu'en est-il de l'ensemble des solutions, des pratiques et des usages que nous déployons au quotidien ? Toute organisation doit se poser la question de l'utilisation ou non de l'IA et, en cas de réponse positive, doit envisager la mise en place d'une charte de bonnes pratiques.

Il existe des risques avérés, qui soulèvent des questions de responsabilité. On observe, par exemple, des situations dans lesquelles des consultants ont prodigué des conseils entièrement fondés sur les résultats générés par une intelligence artificielle, en passant à côté d'un enjeu majeur en matière de cybersécurité. D'un point de vue réputationnel, les conséquences peuvent s'avérer particulièrement dommageables. Ce n'est pas parce qu'une réponse générée par l'IA est rédigée de manière fluide, sans fautes d'orthographe, qu'elle est nécessairement exacte. Et là, le sachant – si tant est qu'il soit sachant – s'était totalement effacé par rapport au résultat de l'IA. Nos clients nous sollicitent de plus en plus pour encadrer les conditions d'utilisation de l'IA générative afin d'en limiter les risques associés.

En partant de ce constat, si l'on se replace dans le contexte d'un cabinet d'avocat, les mêmes exigences s'appliquent. Nous sommes soumis à une obligation de confidentialité ainsi qu'à un devoir de conseil.



Si l'intelligence artificielle peut nous permettre de gagner en efficacité et faciliter la tâche, son utilisateur doit en rester le dominant et pas le dominé. L'un des « risques » liés à l'utilisation de l'IA générative par des avocats ou juristes, serait de considérer que, grâce à l'IA, ils peuvent désormais envisager des domaines d'expertises pour lesquels ils n'ont pourtant pas de formation et/ou de pratique préalable.

Tout d'abord, prendre le temps de réfléchir à ces usages, ne pas utiliser de données à caractère personnel et privilégier la préférence humaine. Ce principe consiste à considérer que si l'intelligence artificielle peut nous permettre de gagner en efficacité et faciliter la tâche, son utilisateur doit en rester le dominant et pas le dominé.

L'un des « risques » liés à l'utilisation de l'IA générative par des avocats ou juristes, serait de considérer que, grâce à l'IA, ils peuvent désormais envisager des domaines d'expertises pour lesquels ils n'ont pourtant pas de formation et/ou de pratique préalable. S'appuyant sur l'IA, certains utilisateurs pensent pouvoir investiguer ces « nouveaux » domaines, en internalisant ou couvrant un maximum de domaines juridiques dans un souci de réduction de coût ou d'accroissement d'un chiffre d'affaires.

Or, il existe de nombreux exemples où il apparaît clairement qu'il y a autant de réponses que de questions pour un même problème juridique. C'est très dangereux de raisonner ainsi. L'essentiel est donc de comprendre qu'interroger l'IA dans les métiers du droit doit se faire uniquement dans des domaines et pour des sujets sur lesquels nous disposons d'une réelle capacité de discernement. Nous devons être capable de savoir si la réponse fournie est juste ou fausse.

Cette mise en garde s'adresse notamment aux étudiants, futurs professionnels du droit, mais également à certains professionnels qui se laissent séduire par l'illusion d'une baguette magique que représenterait l'intelligence artificielle.

Sophie SONTAG KOENIG : J'évoquais tout à l'heure le récent rapport du Sénat qui souligne des distinctions entre les métiers du droit. Les professions réglementées disposent, du fait de leurs instances, de certaines lignes directrices. Je pensais, dans mes propos, au cadre offert par le Conseil national des barreaux sur l'IA générative via un guide pratique paru en septembre dernier. Il y a là une différence avec d'autres professions, qui n'en disposent pas forcément. Voulez-vous réagir ?

Aurélien KLEIN : Parmi les avocats, il existe une diversité de pratiques considérable, d'où la réticence de certains organismes du droit à définir des lignes directrices trop contraignantes. Ce qui est certain, c'est que nous sommes tous gouvernés par des principes déontologiques auxquels nous devons nous soumettre, quelle que soit notre pratique. Même si anonymiser est une contrainte en termes de temps, si tant est que

cela fait perdre du temps, il est nécessaire de le faire. La paresse n'a pas lieu d'être.

Pascal ALIX : Je vais m'attarder quelques minutes sur ce sujet de la régulation, l'apport de la *soft law* et des règles déontologiques, puisque c'est mon sujet de thèse. Première interrogation, est-il possible de réguler cet objet insaisissable ? Je n'en suis même pas sûr au bout de 100 pages du titre 1 de ma première partie de projet de thèse. Réguler cet objet temporaire, éphémère, insaisissable qu'est l'IA générative s'appuyant sur les LLM, et qui peut-être, si on en croit Yann Le Cun, n'existera plus dans quelques années, semble complexe.

Nous sommes en train de bâtir des business models, des règles déontologiques, des règles de *soft law*, des règles de *hard law* et un monument techno-scientifico-juridique qui ne règle pas tout, le règlement sur l'IA – un texte qui passe allègrement au-dessus des vrais enjeux anthropologiques cognitifs. Vous pouvez fouiller ce règlement, véritable usine à gaz, à la recherche de dispositions encadrant les enjeux cognitifs : vous n'y trouverez absolument rien. Quelques mesures de transparence ont bien été ajoutées, tardivement, après le phénomène ChatGPT, à l'article 50, mais dans les faits, elles ne résolvent que très peu de choses.

Voilà donc où nous en sommes sur le plan de la réglementation. J'espère que celles et ceux qui ont contribué à la rédaction de ce texte ne m'en tiendront pas rigueur, mais je tiens le même discours dans toutes mes interventions. Ce texte est l'héritage d'un virage opéré dans les années 1980, où l'on a privilégié une régulation *ex ante* reposant sur le principe d'*accountability*. Et je parle en tant que délégué à la protection des données depuis douze ans : je constate quotidiennement les limites de ce modèle, notamment quand il s'agit de garantir les droits humains. En vérité, cette approche ne protège pas grand-chose.

J'exerce également une activité d'auditeur en matière de certification. À ce titre, nous appuyons sur un beau référentiel, nous vérifions si telle disposition est présente, si tel document existe. Mais comment s'en servir pour contextualiser et garantir le respect des droits humains, chers à bon nombre d'entre nous dans cette salle ? Honnêtement, je ne sais pas. Et lorsque je dis « je ne sais pas », je pense que vous saisissez bien le sens réel de mes propos. En réalité, je doute fortement – et c'est un euphémisme – que la protection des citoyens, des administrés, des personnes concernées soit

véritablement garantie. Voilà l'état actuel de la réglementation.

Ce qu'il faut comprendre, c'est que la réglementation poursuit trois objectifs principaux. Et parmi eux, le premier reste la promotion de l'intelligence artificielle, ce qui s'explique par des enjeux géopolitiques et économiques très présents. C'est d'ailleurs cet objectif qui prime lorsque l'on examine les textes préparatoires. Cela dit, le préambule rappelle maintes fois, plus de cent cinquante fois, la nécessité de respecter la Charte des droits fondamentaux de l'Union européenne.

Mais si l'on se penche sur les dispositions normatives concrètes, qu'y retrouve-t-on réellement ? Il y a quelques éléments par-ci et par-là, avec des pratiques interdites à l'article 5 notamment. Mais lorsqu'on observe le quotidien et la mise en œuvre des systèmes à haut risque mentionnés à l'annexe III, il est difficile de voir en quoi ces dispositions garantissent une véritable protection des citoyens, des administrés et des personnes concernées. Les traces en sont bien minces. Je ne sais pas si je dépasse un peu du cadre ici, mais c'est le constat que j'ai dressé.

Je souhaitais simplement rappeler les enjeux essentiels. En tant qu'avocats, la défense des droits humains fait partie intégrante de notre ADN. Il me semble donc important de garder cela à l'esprit, avant de nous engager trop rapidement, et peut-être sans suffisamment de discernement, dans l'utilisation massive de ces outils algorithmiques, qui portent en eux un risque réel de déshumanisation.

Sophie SONTAG KOENIG : La transition vers la question de l'IA et de la décision de justice s'opère naturellement, avec deux regards qui peuvent se croiser grâce à vous Claire STRUGALA et Pascal ALIX.

Claire STRUGALA : Je tiens à préciser, même si j'ai moi-même participé aux négociations, que toute décision prise au nom de la France résulte d'un processus interministériel. Il ne s'agit en aucun cas d'agents individuels qui prendraient la plume pour réécrire un texte à leur guise. La négociation d'un traité ou d'un texte européen ou international est un processus d'une extrême complexité. C'est un travail de diplomatie et de politique. Le droit n'intervient ici que d'un point de vue technique. Bien sûr, ce sont les juristes qui se chargent ensuite de traduire tout cela en termes juridiques, mais au fond, il s'agit toujours de politique et de diplomatie. Cela étant dit, pour celles et ceux que le droit international intéresse, c'est un domaine absolument passionnant, par ailleurs.

Nous avons donc évoqué le fameux règlement sur l'IA. Avant même de discuter de ce texte, qui a pu – ou non – rassurer certains, et qui suscite à la fois fascination et inquiétude, j'aimerais rappeler un point essentiel : en matière de décision judiciaire, nous n'avons pas attendu ce règlement pour encadrer l'usage des algorithmes. Depuis 2016, les algorithmes utilisés dans la sphère publique sont déjà soumis à une réglementation. Cela concerne notamment ceux qui pourraient employer le ministère de la Justice ou les magistrats.

Que ce soit à travers la loi pour une République numérique de 2016, le RGPD ou encore la loi Informatique et Libertés, le cadre juridique était déjà assez clair sur le fait qu'aucune décision judiciaire ne peut être entièrement automatisée. En d'autres termes, il ne peut y avoir de remplacement du magistrat dans la prise de décision judiciaire par une prise de décision algorithmique totale. Aujourd'hui, d'ailleurs, il ne s'agit plus de parler de décision judiciaire automatisée mais d'outils d'aide à la décision. En réalité, les choses sont un peu plus subtiles. Nous verrons que, même si l'outil s'intègre dans le processus sans le remplacer entièrement, il subsiste des risques.



Il ne peut y avoir de remplacement du magistrat dans la prise de décision judiciaire par une prise de décision algorithmique totale. [...] Il convient donc de considérer le RIA comme une réglementation de produit, et non comme une mesure visant à protéger les droits fondamentaux.

Tout cela pour dire que nous avons surtout parlé du règlement sur l'IA, mais il convient de souligner que le RGPD est également un texte fondateur, tout aussi important que le RIA en matière d'intelligence artificielle. En effet, sans données, il n'y a pas d'intelligence artificielle, du moins pas dans le domaine de la justice. Les données de vos procédures et des décisions de justice constituent la matière première de l'IA dans ce secteur. Le RGPD, de ce fait, revêt une importance fondamentale. Que ce soit le RIA ou le RGPD, il faut bien comprendre qu'il existe

une double réglementation : l'une qui s'applique à la justice au sens pur du terme, c'est-à-dire à la décision judiciaire, et l'autre qui s'applique aux autres.

Lorsque je parle des « autres », je fais référence aux avocats, juristes d'entreprise, huissiers, notaires et toutes les autres professions réglementées. En ce qui concerne la prise de décision judiciaire, vous pouvez facilement l'imaginer : nos conditions d'utilisation et de traitement des données sont beaucoup plus strictement réglementées et contrôlées que celles des traitements et des IA utilisées par ce que l'on pourrait qualifier de secteur privé du monde judiciaire et juridique.

Ainsi, le RIA, effectivement, constitue une forme de réglementation, comme cela a déjà été mentionné. Les droits fondamentaux apparaissent quelque peu relégués derrière ce que le texte cherche à protéger, à savoir l'innovation. Le RIA, en réalité, est une réglementation-produit. L'objectif principal a été de s'assurer que les produits qui seraient mis sur le marché européen, comme les jouets ou les médicaments, respectent certaines normes de sécurité et offrent une traçabilité en cas de dysfonctionnement. Il convient donc de considérer le RIA comme une réglementation de produit, et non comme une mesure visant à protéger les droits fondamentaux.

Cela étant, il est clair que l'IA est aujourd'hui le nerf de la guerre en termes économiques. Cela représente un sujet économique, politique et géostratégique essentiel dans lequel l'Europe ne cesse de penser qu'elle est en retard sur la Chine et les États-Unis. C'est pour cela que l'innovation est un axe central dans ce que nous souhaitons préserver. Et là, vous entendez ce refrain qui vous dit que si vous voulez être innovant, il ne faut pas imposer de réglementation. Nous pouvons être d'accord ou pas, mais le fait est là : si nous souhaitons suivre le modèle des États-Unis, c'est ainsi qu'ils ont traduit l'encouragement à l'innovation. Et la réglementation est donc perçue comme un frein à l'innovation car vous allez instaurer des contrôles, des certificats et des autorisations préalables à la mise sur le marché du produit. En conséquence, ceux qui n'ont pas à suivre ces règles seront plus compétitifs.

Cela dit, nous sommes en Europe et nous tenons à préserver nos valeurs fondamentales. Ainsi, nous avons décidé de les rappeler et de les préserver en adoptant une approche par les risques. Ce sont donc uniquement les systèmes les plus risqués pour nos droits fondamentaux, notre santé et notre sécurité qui sont soumis à des règles et des obligations. Je ne parle pas ici

des systèmes interdits, qui par définition, sont interdits et donc non réglementés. En revanche, les systèmes qui sont réglementés sont ceux qui présentent des risques importants, et ceux-ci sont autorisés, mais sous certaines conditions.

Le cœur de réacteur du RIA, c'est de poser un certain nombre d'obligations techniques visant à sécuriser ces systèmes. Cependant, du côté du ministère de la Justice, il est important de préciser que nous ne sommes pas des experts en data science. Ce n'est pas notre cœur de métier. Ce n'est pas nous qui allons développer des algorithmes, ni devenir producteurs ou distributeurs d'intelligence artificielle. Nous pourrions le devenir si nous décidions de créer un système nous-mêmes, mais ce n'est pas là notre priorité. Ce qui nous pose davantage de questions, ce sont les obligations qui concernent les « déployeurs » au sens du RIA, c'est-à-dire les utilisateurs de ces systèmes à haut risque.

La question que l'on peut se poser est la suivante : la justice entre-t-elle dans la catégorie des systèmes à haut risque ? La réponse est à la fois oui et non. En effet, dans cette logique de protection des droits fondamentaux et de ce qui va leur être le plus attentatoire, nous avons estimé que seuls les systèmes qui servent d'aide à la décision pour le juge devaient être considérés comme à haut risque. Tout ce qui relève des avocats, des notaires, des juristes-conseils, eux, ne rentrent pas dans la catégorie à haut risque. Par conséquent, ils ne sont soumis à aucune règle spécifique et c'est pourquoi nous en revenons aux bonnes pratiques pour ces fonctions.

En réalité, il n'existe pas de réglementation dure concernant l'utilisation de l'intelligence artificielle dans le domaine du droit, à l'exception de celle qui s'applique aux systèmes utilisés par les magistrats. Pourquoi cela ? Parce qu'évidemment, la décision judiciaire a des effets directs et peut porter atteinte aux droits et libertés fondamentaux. C'est tout le principe de l'autorité de la chose jugée. C'est pourquoi nous avons décidé de nous assurer que les IA utilisées dans ce cadre soient conçues en respectant un certain nombre de normes techniques.

Pour resituer un peu le cadre du texte, le RIA impose un certain nombre d'obligations, tant au stade du développement qu'à celui de l'utilisation. Et qui est l'utilisateur, en l'occurrence ? C'est le juge. Alors, à quelles obligations devons-nous nous conformer si, demain, nous utilisons un outil d'aide à la décision ? La première exigence, c'est la capacité de compréhension. Il faut savoir comment se servir de cet outil – je trouve cela plus simple de parler d'outil, même si nous n'avons

pas tous les mêmes terminologies. Cet outil doit être compris par le magistrat qui l'utilise. Et surtout, il doit être soumis à une information du justiciable.

Et cela nous ramène à ce que prévoyait déjà la loi pour une République numérique : une obligation de transparence. Le magistrat devra donc s'y conformer, ce qui implique, au minimum, d'indiquer s'il a recours ou non à une intelligence artificielle. Je vous ai déjà expliqué ce que le ministère utilisait officiellement. La plus grande question et les plus grands risques – et c'est également vrai pour les avocats – ne résident pas tant dans l'utilisation officielle d'IA par les professionnels de justice, mais l'utilisation de manière « sauvage », faite sans jamais le dire.

Aujourd'hui, je ne peux pas vous garantir qu'aucun magistrat n'a déjà eu recours à ChatGPT ou à d'autres outils similaires, que ce soit pour effectuer des recherches juridiques ou pour de la rédaction. Or, le RIA introduit une exigence très claire. Il impose une obligation de transparence et de compréhension quant à l'utilisation de ces outils.

Un dernier point à soulever est la nécessité d'un contrôle humain. Et c'est précisément là que les interrogations se multiplient. Sur le papier, cette exigence semble relativement simple. Mais concrètement, comment le magistrat pourra-t-il expliquer le fonctionnement de l'algorithme qu'il a utilisé ? De quelle manière devra-t-il informer le justiciable de son recours à un outil algorithmique ? Devra-t-il le faire à l'audience, dans sa décision motivée, ou par un renvoi à un site Internet indiquant que le ministère utilise des algorithmes ? *Quid* du contrôle humain ?

Parce qu'on le sait bien, même si l'on nous répète que l'intelligence artificielle n'est qu'un outil d'aide à la décision, le droit est très complexe. Lorsqu'on effectue une recherche juridique, on est inévitablement influencé par les résultats qui nous sont proposés. Et si l'on a recours à une IA, ce n'est généralement pas pour revérifier chaque élément qu'elle produit, on le fait pour gagner du temps. À un moment donné, un choix va s'imposer. Il est impossible de tout contrôler. Qu'attendons-nous donc de ce contrôle humain, en quoi consiste-t-il ? Et est-ce que nous en aurons les capacités ?

Nous savons également que l'humain, dans ce type de situation, aura tendance à être conditionné par ce qu'on appelle un biais d'ancrage. Et cela vaut encore plus pour les jeunes étudiants comme vous, jeunes professionnels en devenir. Lorsqu'on vous demandera, pour la première fois, de rédiger une décision ou des conclusions,



vous ne serez pas forcément sûrs de vous. Et si vous avez utilisé une IA qui vous affirme que c'est bien la solution, alors que vous doutiez de vous, il y a de fortes chances que vous finissiez par vous ranger à l'avis de la machine. C'est tout à fait logique et normal, c'est humain.

Et lorsque vous serez magistrat – si tel est votre choix – vous vous retrouverez avec une pile de dossiers à traiter dans un délai très contraint. Dans ces conditions, même avec la meilleure volonté du monde, vous aurez tendance à suivre ce que vous dit la machine. Et c'est bien là tout l'enjeu du fameux contrôle humain. Comment faire en sorte que l'outil soit utile, nous fasse gagner du temps – car autrement quel intérêt d'y recourir – mais tout en gardant la main dessus ?

C'est dans cette optique que le règlement sur l'IA pose déjà un certain nombre de règles essentielles. Pour ma part, je crois à la nécessité d'une régulation et en la place du droit, parfois plus qu'à l'éthique d'ailleurs. Mais elle soulève aussi de nombreuses questions. Il y a beaucoup d'inconnus sur la mise en application de ces principes et règles, et sur la manière de concrètement assurer ces notions de contrôle humain, de transparence et d'explicabilité.

Aurélie KLEIN : S'agissant de l'encadrement juridique de l'IA, il est essentiel de se pencher sur les conditions générales d'utilisation des solutions d'IA que nous employons au quotidien.

Pascal ALIX : Juste pour illustrer rapidement ce qui vient d'être dit, les conditions générales de Bard en 2024 résumaient très bien la situation. Elles qualifiaient cet objet de ludique et insistaient sur sa dimension exploratoire et inachevée. C'est la seule fois, je pense, où j'avais sous les yeux des CGU vraiment honnêtes qui admettaient que c'était un objet exploratoire, utile à des fins ludiques. Elles préconisaient, et je n'invente rien, de ne pas l'utiliser à des fins professionnelles car l'outil peut commettre des erreurs et qu'il fallait donc s'abstenir de l'utiliser pour générer des résultats ayant un impact significatif.

Sophie SONTAG KOENIG : Marc CLÉMENT, partagez-vous cet avis sur la réglementation au niveau administratif ?

Marc CLÉMENT : Pour commencer, je crois qu'il est important de rappeler, comme je l'ai déjà évoqué, qu'à l'heure actuelle, je ne vois pas véritablement d'usage concret de l'intelligence artificielle. Nous imaginons vite un scénario un peu fantasmé dans lequel le juge dispose d'un

outil dans lequel il entre son dossier et qui sort ensuite un jugement que le juge n'aurait plus qu'à signer. Mais cela, soyons clairs, n'existe pas. Et cela a très peu de chances d'exister si nous maintenons l'idée que faire du droit ne se résume pas à rechercher de la jurisprudence.

Je comprends parfaitement que, dans une logique de formation, ce soit un enjeu. C'est une vraie question à considérer. Si, par exemple, je demande à Gemini : « Qu'est-ce que l'abus de droit en matière fiscale ? », je vais obtenir une réponse qui, dans l'ensemble, tient la route, n'est pas absurde. Mais si je vais plus loin et que je lui demande des références jurisprudentielles précises, alors là, ça part complètement en vrille, avec des réponses qui n'ont rien à voir, des réponses fausses. Et pour moi, en tant que magistrat dans une chambre fiscale, la question n'est pas simplement de savoir ce que signifie, en théorie, l'abus de droit. Ce qui importe vraiment, c'est d'analyser la situation concrète de l'entreprise, de comprendre ce qui s'est réellement passé, comptablement, avec les actes qui ont été passés. Tout ce travail d'analyse concrète, je ne le vois pas aujourd'hui réalisé par une machine. Certes, quand on pose des questions générales, on obtient des réponses générales, mais absolument pas de réponses précises. Nous ne sommes donc absolument pas à ce stade-là encore.

Je pense qu'il faut vraiment repartir de ce point-là, car comme Antoinette ROUVROY l'a souligné, le droit opère toujours à partir d'une abstraction du monde réel. Nous ne saisissons jamais directement le monde tel qu'il est, nous le transformons en catégories juridiques, en concepts, sur lesquels nous allons ensuite raisonner. Donc, si nous nous en tenons à une mécanique purement jurisprudentielle, alors oui, il est possible de concevoir des outils capables d'identifier les jurisprudences. Mais, si nous prenons les exemples, dont celui du cabinet Fidal, nous voyons que ce sont des outils beaucoup plus ciblés et précis dans leurs usages. Ils ne vont donc pas soulever un problème lié à la généralité de l'usage d'une machine plus ou moins intelligente, mais de l'usage spécifique que l'on est en train d'en faire.

Et c'est là que réside la grande difficulté du Règlement sur l'IA. La Commission européenne a construit ce texte sur une base juridique « marché intérieur », avec les concepts d'innovation, de produits, etc. Et cela ne peut pas fonctionner car nous ne sommes pas face à des produits que nous allons utiliser. La justice, les cabinets d'avocats ne vont pas prendre un outil produit par

OpenAI ou autre et l'installer directement. Nous allons développer des applicatifs, et ce n'est pas spécifique à l'IA. Si vous regardez l'informatique et ses développements dans les juridictions, nous ne disposons pas des mêmes systèmes entre systèmes judiciaires et administratifs.

Le système de gestion des dossiers dans la juridiction administrative est développé par la juridiction administrative. La police et la gendarmerie n'ont pas les mêmes systèmes. Ils ont essayé, à coup de dépenses considérables, d'harmoniser des choses mais sans y parvenir. Nous n'imaginons pas une IA, police, qui serait sur le marché européen, fabriquée, par exemple par des Estoniens, où la police française se dirait : « Cela tombe très bien, c'est exactement ce qu'il nous faut, prenons-le et mettons-le en place. » Nous ne sommes pas dans une logique de produit mais dans une logique d'usage.

Et c'est dans le contexte de ces usages qu'il faut arriver à définir les questions éthiques, au sens de comment je vais produire mes décisions. Et cela rejoint la question centrale de l'aide à la décision. Et encore une fois, je ne le conçois pas trop pour les juges, mais plus pour la décision administrative. Que signifie qu'un être humain est intervenu dans le processus de fabrication de cette décision ? Il y a des habitudes qui se construisent et progressivement, nous faisons confiance ou non à ce processus.

Nous nous retrouvons face à une complexité assez grande, qui est celle de devoir essayer d'apprécier, si oui ou non, il faut que l'être humain intervienne. Et si tel est le cas, que doit-il faire et comment s'assurer qu'il le fait correctement ? Supposons qu'on instaure une règle de droit administratif qui imposerait que la personne qui prend la décision et la signe ait regardé le dossier. Comment garantir que cela a vraiment été fait ? La règle éthique ne va pas concerner la qualité de la décision, le résultat ou le fait que cette décision soit juste, légale ou non. Cela sera simplement de s'assurer que l'administrateur, le fonctionnaire, a véritablement accompli son travail. Cela fait partie des enjeux et des questions qui doivent être posées.

Sophie SONTAG KOENIG : En complément de ce qui a été dit – même si l'on sort ici du strict champ juridictionnel ou de l'exercice professionnel du droit – sur un plan universitaire nous avons l'équivalent en termes de réflexion sur la réglementation. Nous connaissons des enjeux en termes de formation, déjà soulevés, et sur l'encadrement, dont nous avons déjà conscience dans le milieu de l'enseignement et de la recherche.

Frédérique BERROD : Alors peut-être pour reprendre – mais c'est probablement ma spécialité en droit européen qui ressort – je pense que nous faisons dire au règlement sur l'IA plus qu'il n'en dit, et qui ne sont pas exactement de son ressort. Ce règlement n'a pas pour objet de réguler l'intelligence artificielle en tant que telle, ni même les produits qui seraient directement les applications utilisant l'intelligence artificielle. Son objectif premier, c'est la prévention des risques. C'est une réglementation qui s'inscrit dans un contexte post-Covid. L'idée est donc de d'abord prévenir les risques en matière de santé et de sécurité par rapport aux droits de l'Homme. C'est pourquoi nous avons construit cette fameuse pyramide du risque qui se trouve dans le règlement.

Pourquoi est-ce que je dis cela ? Parce qu'en réalité, cela soulève une vraie question du côté de la recherche, qui est exclue du champ d'application du règlement. Cela signifie que dans le cadre de la recherche, il est possible d'utiliser et de produire n'importe quelle IA, sans être soumis à aucune règle. Et cette exclusion a un sens puisque pour faire de la recherche correcte-



[...] pour faire de la recherche correctement, il ne faut pas être contraint par des règles trop strictes qui viendraient impacter le contenu de ces recherches.

ment, il ne faut pas être contraint par des règles trop strictes qui viendraient impacter le contenu de ces recherches. Néanmoins, cela pose un problème, car pour respecter les valeurs européennes, nous demandons aux chercheurs d'effectuer une recherche éthique et basée sur des principes éthiques. L'un des éléments va être de savoir comment nous nous y prenons.

Et il faudrait que nous fassions mieux avec le règlement IA que ce que nous avons fait avec le RGPD. Aujourd'hui, le RGPD produit un certain nombre de conséquences extrêmement négatives sur des disciplines des sciences sociales, car il est appliqué sans utiliser toutes ses potentialités. Tout est perçu comme contraire au RGPD avant même de se poser la question

du champ d'application et des définitions. Je crains que la même chose se produise avec le règlement sur l'IA, avec une frontière difficile entre ce qui relève de la recherche et de la recherche-développement.

Au sujet de la recherche-développement, dès lors qu'il y a une commercialisation de ce qui a été produit par la recherche à base d'IA ou de la recherche qui va produire de l'IA, il faudra appliquer la pyramide des risques. Il faudra dès lors, en termes de responsabilité du chercheur, voire de l'université, se poser la question de savoir si nous avons développé un système, qui, par exemple, relève de l'IA interdite. Il s'agit d'un vrai problème en termes d'encadrement ou de non-encadrement de cette recherche et de la viabilité du modèle économique nécessaire à son développement.

Nous voyons se développer une double réflexion dans l'enseignement. Tout d'abord, une réflexion par université probablement due à ce que l'on appelle – improprement – l'autonomie des universités. Chaque université est en train de réfléchir à ses propres réglementations, que cela aille de l'évaluation, que j'évoquais plus tôt, à la réforme d'un certain nombre d'enseignements ou à l'utilisation de l'IA. L'une des questions qui devra être traitée, que je trouve extrêmement difficile, est que nous devons enseigner en termes d'esprit critique. Cela paraît comme une évidence mais, à titre personnel, je n'ai pas toutes les réponses pour dire ce que doivent être les compétences à mettre en œuvre pour avoir un esprit critique en droit, du moins pour les compétences en dehors des compétences strictement juridiques.

Un autre débat est celui de savoir si nous pouvons faire confiance aux données publiques pour faire de la recherche en droit ? Allons-nous devoir sécuriser un certain nombre d'éléments, comme nous le faisons, par exemple, sur les données de santé ? Qui plus est, nous savons qu'aujourd'hui, la recherche sur ces données de santé n'est globalement pas très bonne, particulièrement en France, car justement la recherche n'est pas suffisamment encadrée, ou ne respecte pas suffisamment les cadres réglementaires. C'est un problème fondamental en termes de contenu et de géopolitique de la recherche, saillant en matière de santé.

Nous voyons donc se développer des chartes d'utilisation de l'IA, par exemple – pour sortir de la France – à l'université de Genève. Puis, il se trouve une réflexion plus collégiale au niveau européen, menée dans les cadres d'alliances universitaires. Je pense notamment à la LERU

(*League of European Research Universities*), une association qui rassemble les universités afin de réfléchir conjointement à des enjeux européens qui dépassent strictement les enjeux français et devront certainement être pris en compte.

L'impression que j'ai, en écoutant mes propres besoins et ceux de mes collègues, est que nous avons besoin de bonnes pratiques pour nous repérer davantage. Autrement, la tendance est de rejeter l'IA car nous n'en percevons que les dangers potentiels. Ce qui, à mon avis, serait une erreur, mais c'est un des risques aujourd'hui. Ce guide de bonnes pratiques, que vous avez évoqué dans le cadre des professions réglementées, pourrait être une idée judicieuse à développer dans les universités, tout comme ces retours sur expérience qui pourraient guider efficacement les interrogations.



Ce guide de bonnes pratiques, que vous avez évoqué dans le cadre des professions réglementées, pourrait être une idée judicieuse à développer dans les universités, tout comme ces retours sur expérience qui pourraient guider efficacement les interrogations.

Je crois que, face à ChatGPT, nous sommes passés de la période de sidération – qui nous a poussés à l'interdiction – à une période d'excitation autour de l'utilisation et de l'enseignement de l'IA, avec une forte appétence d'expérimentation et d'expérience. Cela tient effectivement aux enjeux importants que j'ai essayé de schématiser tout à l'heure, et qui continuent de susciter des interrogations chez nombre de collègues. C'est, en tout cas, comme cela que je le ressentirais à ce stade.

Sophie SONTAG KOENIG : Nous glissons vers le dernier moment de cette table ronde. Un certain nombre de points ont été abordés qui touchent à la question du malentendu. C'était le thème cardinal que nous avons convenu d'aborder, ce que vous avez spontanément fait. Il était prévu de le traiter dans les derniers temps, mais vous l'avez finalement rapidement intégré, car le « malentendu » est palpable. Vous l'avez évoqué

en termes de déception par rapport aux attentes initiales envers l'intelligence artificielle, mais aussi du point de vue des risques tangibles.

D'autres points n'ont pas encore été appréhendés et nous allons ainsi pouvoir nous concentrer dessus pour cette ouverture. Nous nous étions promis d'aborder trois questions, dont la question de la preuve dans l'utilisation qui en sera faite par les magistrats. Qu'advient-il de la preuve si nous utilisons des IA à titre probatoire, pour la décision judiciaire, que ce soit pour en renforcer la force probante ou pour la remettre en question ?

Claire STRUGALA : Puisque nous en sommes aux malentendus, je pense qu'en ce qui concerne l'IA, il est très compliqué d'arriver à se faire une idée claire, car il existe de nombreuses technologies, de nombreux usages, ainsi que des craintes et des attentes variées. C'est un sujet passionnant, mais difficile à appréhender, et lors d'une table ronde, encore plus. Je vais donc brièvement aborder la question de la preuve, car cela me semble être un sujet assez peu discuté en lien avec les thématiques d'IA et de justice. Ensuite, je mentionnerai deux malentendus que j'identifie à mon niveau.

Concernant la question de la preuve, lorsque nous parlons d'IA et de justice, nous revenons toujours à la prise de décision judiciaire. Le risque est que l'IA capte la volonté décisionnelle du magistrat et nous nous arrêtons beaucoup là-dessus. Cependant, il y a tout un enjeu qui est peu discuté. Aujourd'hui, et vous en êtes tous conscients, parmi ce que vous consultez sur Internet, ce que vous recevez sur vos téléphones, nous parlons beaucoup de *deepfake*. En réalité, nous savons que toutes les données dont nous sommes récepteurs peuvent avoir été générées en partie ou totalement par une IA. Nous savons que les données peuvent avoir été augmentées par intelligence artificielle. Par exemple, les caméras de vidéosurveillance de mauvaise qualité peuvent être améliorées grâce à des technologies d'intelligence artificielle.

Nous savons qu'en médecine ou dans de nombreuses autres disciplines, les experts judiciaires utilisent l'intelligence artificielle dans leurs pratiques professionnelles et dans leur expertise. Par conséquent, à court et moyen terme, nous allons voir arriver des pièces de procédure qui nous auront été fournies par les parties elles-mêmes au soutien de leurs demandes et dont nous ne saurons plus la valeur probante ou, en tout cas, leur origine, ce qui risque de poser des difficultés majeures.

Si nous ne sommes pas informés, nous pouvons être trompés par une technologie qui aurait été utilisée. Par exemple, une personne peut vous fournir un faux enregistrement sonore de la voix de son ex-femme ou de son ex-mari dans le cadre d'une procédure de divorce, ou quelqu'un pourrait vous soumettre une fausse image de son voisin en train de danser nu dans son jardin, en affirmant que c'est une atteinte à sa vie privée. Ce sont des situations qui vont se présenter et auxquelles nous ne sommes pas du tout préparés.

Les avocats n'y sont pas préparés, car ils devront interroger le client sur l'origine de la pièce que celui-ci leur fournit. Les experts n'y sont pas préparés non plus car nous ne leur avons pas indiqué qu'il pourrait être nécessaire, dans leur expertise, de préciser qu'ils ont utilisé l'IA et de potentiellement mentionner quelle IA a été utilisée. Le contradictoire devrait nous permettre de contester cette IA. Enfin, les magistrats n'y sont pas préparés également, car jusqu'à présent, cela ne s'est jamais présenté, et ils devront eux-mêmes décider quelle force probante ils attribueront à cet élément de preuve versé au dossier. Et si nous, magistrats, ne sommes pas encore prêts à faire le grand saut, les justiciables et les citoyens le sont déjà. C'est donc un enjeu majeur car nous devons mesurer notre capacité à réceptionner ces nouvelles pièces.



S'agissant des bonnes pratiques, nous devrions collectivement en élaborer, en nous appuyant sur un principe simple mais éprouvé : la transparence.

S'agissant des bonnes pratiques, nous devrions collectivement en élaborer, en nous appuyant sur un principe simple mais éprouvé : la transparence. Si vous en parlez, si nous en avons connaissance, c'est déjà le meilleur moyen de questionner et éventuellement de remettre en question les informations qui vous sont fournies.

En ce qui concerne les deux autres grands malentendus que j'identifie, le premier concerne plus particulièrement le ministère de la Justice, même si je ne parle pas en son nom. Ce qu'on appelle le solutionnisme technologique, c'est cette idée selon laquelle si vous intégrez de l'IA



dans une structure en souffrance qui manque de moyens, cela résoudra tous les problèmes. Aujourd'hui, l'IA est présentée comme un outil de productivité. Ce n'est rien d'autre que cela. On ne vous parle pas de miracle humain, ni du fait que cela va changer la vie des gens ou que les gens seront beaucoup plus protégés et heureux. Non, on vous dit que l'IA sert à gagner du temps. C'est l'objectif.

Le rapport des états généraux de la justice, le rapport du Sénat récemment rendu sur l'IA et l'audience solennelle de rentrée du premier procureur et du premier président de la Cour de cassation dressent le même constat : la justice va mal et elle manque de moyens. Dans ce contexte, l'IA pourrait être une solution pour améliorer le travail des greffes, ou pour rendre le travail des magistrats plus efficace. Néanmoins, à mon sens, il s'agit d'un mythe solutionniste et technologique, même si je ne vais pas anticiper sur ce que dira certainement Maître ALIX concernant les biais, les difficultés et les risques.

Nous avons conscience que l'IA n'est pas un outil miraculeux. En tant qu'administration, il faut d'abord prendre conscience que le ministère de la Justice doit rattraper son retard numérique. L'IA est une Ferrari. Mais si vous partez d'une Citroën 2 CV, le chemin à parcourir est immense. Nous avons véritablement des moyens substantiels à investir dans nos juridictions pour être en mesure d'accueillir ces technologies, et nous ne sommes pas encore tout à fait prêts, car tout cela demande beaucoup de moyens.

De plus, pour faire de l'IA, il faut avoir accès aux données et garantir la sécurité des hébergements. Étant un ministère régalien, nous sommes soumis à des exigences de cybersécurité et nous nous devons d'offrir un hébergement sécurisé en conformité avec les règles très strictes du RGPD.

Ensuite, il faut former et accompagner les professionnels. Il est facile de conseiller de

recourir à l'IA, mais si vous ne savez pas comment l'utiliser et que vous ne comprenez pas comment conclure à partir de l'information qui vous est fournie, vous n'en tirerez rien. Enfin, il est nécessaire de disposer de moyens budgétaires et d'une certaine forme de proportionnalité entre les objectifs que vous souhaitez atteindre et les ressources que vous êtes prêts à allouer. Tout cela fait que l'IA peut constituer une opportunité, mais ne saurait être une solution à tous nos problèmes de moyens, que ce soit pour le ministère de la Justice ou pour toute autre administration, d'ailleurs.

Le dernier mythe que je souhaiterais déconstruire, est celui selon lequel l'utilisation de l'IA par les juges conduirait à une justice inhumaine et uniformisée. Je ne partage pas cet avis, à condition, bien évidemment, de ne pas substituer purement et simplement une décision judiciaire humaine à une décision entièrement automatisée. Pour commencer, l'IA n'est pas nécessairement inhumaine dans ses interactions. Cela a été démontré plus tôt de manière assez humoristique avec l'étudiante qui rédigeait son mémoire et était encouragée par l'IA qui lui disait : « Vas-y, tu vas y arriver, ne te décourage pas aujourd'hui. » Les IA, selon la façon dont vous interagissez avec elles, peuvent se montrer plus bienveillantes que votre professeur ou vos proches. C'est donc un premier point.

Le deuxième point est, qu'en réalité, si demain l'IA est utilisée comme base de décision, c'est-à-dire qu'elle va vous proposer une solution médiane, je dirais qu'elle nous poussera, nous, humains, à nous améliorer. Comment ? Dans un litige, vous avez toujours deux avocats : celui qui sera d'accord avec ce que dit l'IA et celui qui sera en désaccord. Et tout l'intérêt réside ici dans le fait que l'avocat en désaccord devra démontrer au juge que la solution proposée n'est pas la bonne pour son client. Ainsi, il devra faire preuve de plus de créativité et aller puiser dans son dossier pour expliquer pourquoi la solution proposée ne convient pas. Cela obligera le juge à mieux motiver sa décision et expliquer les raisons derrière son choix.

En fin de compte, affirmer que l'IA va tout uniformiser dépend de la manière dont nous l'appréhendons. Si nous l'acceptons comme argent comptant, peut-être. Mais si nous la considérons comme un défi qui nous permet par la suite de discuter et de mieux motiver nos décisions, ce peut être bénéfique.

Par ailleurs, si je gagne du temps dans la gestion de mes dossiers, cela me permet de consacrer plus de temps à écouter le justiciable,



Il est facile de conseiller de recourir à l'IA, mais si vous ne savez pas comment l'utiliser et que vous ne comprenez pas comment conclure à partir de l'information qui vous est fournie, vous n'en tirerez rien.

Claire STUGALA

l'avocat. Ce n'est pas devant un bureau, en effectuant des recherches que les choses sont les plus puissantes et les plus résolutives des difficultés, c'est souvent à l'audience. Je remets donc en question l'idée selon laquelle l'IA va nécessairement déshumaniser notre justice. Nous devons nous adapter et veiller à ce que cela soit un véritable soutien pour mieux nous concentrer sur notre cœur de métier.

Sophie SONTAG KOENIG : La parole serait presque à la défense en dernier. Sur ces mythes appliqués, nous avons deux représentants issus de l'avocature pour recentrer les idées. Vous avez exprimé plusieurs points concernant la perte de spécialisation du point de vue de l'avocat, ainsi que la valeur ajoutée de l'avocat qu'Aurélien KLEIN a bien mise en lumière.

Pascal ALIX : Je vais endosser le rôle de techno-critique, même si cela peut sembler très simpliste, car je suis un grand utilisateur de tous ces outils, et ce même avant ChatGPT, GPT-2, GPT-3, etc. Justement, pour éviter ce premier malentendu, je précise que je ne suis pas seulement techno-critique, je suis aussi un utilisateur. D'ailleurs, j'admets que cela puisse avoir des usages extrêmement utiles pour produire des tableaux, des résumés, et même dans l'idéation, ce dont nous n'avons pas beaucoup parlé, à savoir la recherche de pistes. Mais il faut garder en tête que cela reste juste une partie du processus.

Ce n'est pas simplement en appuyant sur un bouton que nous obtenons des conclusions, un contrat ou un jugement. C'est exactement pareil dans un cabinet d'avocats. En appuyant sur un bouton, nous avons une bribe d'idées, un paragraphe, que nous pouvons éventuellement réutiliser. Je crois que nous n'avons pas suffisamment insisté sur le fonctionnement concret de ces dispositifs.

Nous disposons de différentes technologies qui puisent dans des bases de données, ce que nous appelons le RAG²³, et qui produisent des résultats assez fiables, ou du moins plus fiables que la simple génération de texte telle qu'elle a été décrite ce matin. Il peut y avoir une partie de génération de texte, et une partie de récupération, c'est-à-dire la recherche de sources. C'est ce que fait, par exemple, un outil tel que Perplexity, ou les outils des éditeurs, comme Gen-IA-L, mentionné tout à l'heure et mis à la disposition d'un certain nombre de cabinets.

Nous sommes donc confrontés à ces technologies. Concrètement, lorsque nous appuyons sur un bouton, nous n'obtenons rien. Nous avons une bribe de réponse qui peut être cohérente si nous lui posons une question telle que : « Décris-moi telle notion. » C'est une réponse générale, cohérente, mais nous n'en faisons rien dans des conclusions. Il faut recontextualiser, raisonner, qualifier et interpréter les faits. Il s'agit de toute la partie herméneutique qui n'a été évoquée que très peu jusqu'à présent. L'IA est absolument incapable d'effectuer cette herméneutique, tant pour les avocats que pour les magistrats. Elle ne peut pas plonger humainement dans un dossier en imaginant, avec de l'empathie au sens strict du terme, se mettre à la place du client, de l'adversaire, des parties.



L'IA est absolument incapable d'effectuer cette herméneutique, tant pour les avocats que pour les magistrats. Elle ne peut pas plonger humainement dans un dossier en imaginant, avec de l'empathie au sens strict du terme, se mettre à la place du client, de l'adversaire, des parties.

Nous savons très bien que ces outils, même avec les derniers développements d'Anthropic, et la *chain of thought* qui produit du pseudo-raisonnement, n'est pas qu'un perroquet stochastique, pour reprendre un des précédents discours. Nous sommes d'accord, il y a eu des évolutions et parfois extrêmement rapides. Depuis début 2023, cela a évolué, j'ai même pu soumettre des cas complexes à ces outils, entre autres, Claude 3.5. Je suis assez fasciné par ces résultats et la rapidité de ces changements, qui font que ces objets techniques deviennent de plus en plus performants. Mais il demeure cet énorme malentendu qui consiste à croire que cela fonctionne, à la manière d'un humain, même si c'est une simple simulation d'un être humain avec un véritable raisonnement.

Nous obtenons un résultat. Mais nous avons deux manières d'y parvenir. Nous arrivons à quelque chose que nous pouvons réutiliser après

23. Génération augmentée de récupération.

une pseudo « conversation ». La plupart de ces dispositifs sont, après tout, appelés agent conversationnel. Ainsi, nous parvenons à un résultat grâce à des itérations et des croisements. Pour parvenir à un brouillon à peu près satisfaisant, je croise ChatGPT version Pro avec une personnalisation, ce que nous appelons les GPTs.

Je vais l'alimenter d'un certain nombre de mes documents internes, bien évidemment anonymisés (je ne vais pas entrer dans le détail des bonnes pratiques). L'anonymisation, la documentation, la vérification *a posteriori* devraient normalement être claires pour tous. Nous pouvons arriver à quelque chose, mais qui n'est qu'un brouillon. Il est nécessaire d'arrêter de fantasmer sur le fait que cela va générer un jugement, ou des conclusions, ou un contrat. Malgré tout, ce fantasme persiste alors que cela ne génère qu'un brouillon que nous allons réécrire en effectuant des recherches complémentaires.

Ainsi, j'arrive à un deuxième malentendu. Puisqu'il faut réécrire ce brouillon, combien de temps cela nécessite-t-il ? Est-ce vraiment un gain de productivité ? Je n'en suis pas certain. Personnellement, je passe environ deux à trois heures chaque jour, depuis novembre 2022, à tester différents systèmes algorithmiques génératifs. Je ne suis absolument pas sûr qu'il y ait un gain de productivité lorsqu'il y a besoin d'itérer cinquante fois pour finalement parvenir à quelque chose de satisfaisant et le croiser avec un autre système d'IA pour vérifier, sachant toutefois qu'il existe des prompts de vérification très efficaces.

Vous pouvez établir des prompts de vérification de l'*output* qui a été produit par un autre système algorithmique pour parvenir à un résultat assez impressionnant, certes, mais qu'il faut évidemment vérifier. Donc, il est préférable de travailler avec des moteurs de résultats, avec du RAG, qui vont rechercher des sources, plutôt que de générer, de manière probabiliste. Sur ce sujet, il y a des centaines d'articles sur les hallucinations. C'est désormais intégré, nous le savons. Mais même avec du RAG, des bases de données, nous parvenons à un résultat sur lequel, finalement, avec la partie générative, nous n'avons pas la certitude à 100 % qu'il soit fiable et pertinent.

Concrètement, cela signifie-t-il que toute cette partie va permettre de gagner de la productivité ? Nous ne sommes même pas certains de cela. Le problème réside dans notre capacité de discernement. J'y parviens maintenant, mais après des milliers d'heures de test. Comment une personne qui n'a pas expérimenté comme je

l'ai fait, pendant toutes ces heures, sur différents systèmes algorithmiques qui évoluent « plus vite que la lumière », peut-elle discerner ?

J'avais initialement prévu d'établir une grille d'évaluation comparative empirique, dans le cadre de ma thèse, pour voir quels systèmes sont efficaces, lesquels ne le sont pas, et pour évaluer la fiabilité, ainsi que la possibilité d'éliminer les hallucinations. J'ai rapidement abandonné, car cela varie tout le temps. J'ai consulté de nombreux articles de recherche. Il existe effectivement des comparaisons de fiabilité, mais qui sont contestées par d'autres études. C'est sans fin. Finalement, nous sommes dans le brouillard, dans l'insaisissable. Et je demeure dans l'insaisissable, même après avoir testé tous ces modèles. Encore un mythe supplémentaire.

Un dernier mythe, celui de la neutralité, déjà discuté lors de la précédente table ronde. Il s'agit évidemment d'un objet socio-technique porteur de valeurs politiques, ce qui a été expliqué exhaustivement. En revanche, il y a quelque chose que nous n'avons pas beaucoup évoqué et qui est extrêmement intéressant sur l'utilisa-



Pour qu'un dispositif puisse nous aider dans nos recherches, il est nécessaire que nous puissions utiliser un outil qui nous donne des résultats similaires si nous le réutilisons le lendemain.

tion de ces dispositifs dans la recherche, c'est la question de la non-reproductibilité. Sauf erreur de ma part, c'est une des conditions de l'intégrité scientifique. Pour qu'un dispositif puisse nous aider dans nos recherches, il est nécessaire que nous puissions utiliser un outil qui nous donne des résultats similaires si nous le réutilisons le lendemain.

J'avais posé une question sur le texte du règlement UE sur l'IA : « combien y a-t-il d'articles ? » Une des réponses nous dit 95, l'autre 84, car il se fondait – alors que le texte adopté avait été publié – sur les anciennes versions du texte en négociation. Et, nous le savons, les hallucinations dépendent notamment de la date de

l'entraînement du modèle. Mais là, en posant la même question à un modèle au même moment, il nous donne des résultats différents. Donc, comment voulez-vous faire de la recherche scientifique sérieuse avec un objet sociotechnique, politique, qui ne garantit pas la reproductibilité ?

Sophie SONTAG KOENIG : Frédérique BERROD, en tant que professeure et pour cet aspect universitaire, nous vous laissons les propos conclusifs adressés aux étudiants, qui sont les professionnels de demain.

Frédérique BERROD : Je me permettrai simplement de formuler deux remarques. Il pourrait être pertinent de s'interroger sur ce que nous avons à perdre à utiliser trop facilement les IA génératives. Par exemple, il peut nous être demandé dans la pratique de faire de la contraction ou du résumé de texte. Être un bon juriste suppose normalement d'avoir un esprit de concision. Si nous recourrons systématiquement à l'IA pour le faire, qui, par ailleurs, peut atteindre des performances très intéressantes, perdons-nous pour autant une compétence ?

À mon sens, c'est une réflexion à mener, qui n'a toujours pas été faite. Dans le secteur de la pharmacie, nous avons basculé par exemple vers des médicaments chimiques, causant la perte d'une partie de nos connaissances des médicaments à base de plantes par exemple, et nous constatons aujourd'hui que cela cause des problèmes pour un certain nombre de pathologies. Évitions donc de commettre cette erreur en termes de compétences. À bien vous écouter depuis le début de cette conférence, je dirais que la chance formidable qu'ont les étudiants avec l'intelligence artificielle, c'est qu'elle leur redonne probablement – plus que les étudiants de ma génération – le devoir de revenir à l'humain.

Revenir à l'humain, c'est, au fond, être capable de faire essentiellement trois choses. Premièrement, être créatif et ne pas craindre cette créativité, même si cela ne correspond pas forcément au copier-coller de la réponse que nous considérons comme idéale. Deuxièmement, c'est la curiosité et regarder le monde à 45 degrés. Lorsqu'on regarde le monde à 45 degrés, nous ne le voyons pas tout à fait de la même manière. Cela représente, à mon sens, une curiosité d'esprit extrêmement importante. Et, enfin, troisièmement, ce qui est peut-être la caractéristique principale de l'humain, c'est d'être à l'écoute. Être à l'écoute de la société, de vos clients, de l'ensemble de ces éléments, qui nous aideront à conserver ce que nous appelons

– même si c'est aussi mystérieux que l'intelligence artificielle – la valeur ajoutée de l'humain par rapport à l'intelligence artificielle. Finalement, je trouve tout cela assez enthousiasmant.

Claire STRUGALA : Pour s'inscrire dans cette vision, le message que je souhaiterais transmettre est qu'il faut faire preuve d'une certaine audace dans l'utilisation de ces outils. Sans audace, la vie serait bien triste. Mais il faut également faire preuve de prudence quant à la confiance que nous accordons à ces outils. À mes yeux, audace et prudence sont les deux qualités essentielles que l'on attend d'un juge et j'en ajouterai une troisième : la transparence. Quel que soit le cadre professionnel dans lequel vous allez les utiliser, soyez transparent, parlez-en à vos collègues, à votre supérieur, aux justiciables. Ne faites pas des utilisations sauvages.

Sophie SONTAG KOENIG : Tout est dit, transparence, prudence, audace, ce sera l'optimisme du départ. ■

Conférence de clôture

L'IA, arme de destruction massive ?

- L'intelligence artificielle est un fantasme marketing, son origine ne vise pas réellement à reproduire l'intelligence humaine mais à la simuler.
- L'utilisation historique de l'intelligence artificielle depuis la Seconde Guerre mondiale jusqu'à son déploiement actuel dans des systèmes d'armement autonomes est militaire.
- Les conséquences sociales et politiques de l'automatisation sont à appréhender sous l'angle de la destruction massive d'emplois et l'instabilité des régimes politiques.



Charles THIBOUT

Docteur en science politique, membre du Centre européen de sociologie et de science politique (CNRS, EHESS, Paris 1 Panthéon-Sorbonne)

Yannick MENECEUR : J'aimerais accueillir Charles THIBOUT, à qui j'ai confié la délicate mission de traiter de la question de « l'intelligence artificielle, une arme de destruction massive ? ». Vous aurez naturellement repéré la référence à Cathy O'NEIL et son livre *Weapons of Math Destruction*²⁴, pour mettre en évidence l'impact majeur des systèmes algorithmiques sur nos sociétés, au point d'en devenir des armes de destruction massive. Le contexte géopolitique qui en découle est complexe. Charles va pouvoir nous éclairer à son tour sur ces enjeux.

Charles THIBOUT : Merci à toutes et tous d'être encore là, après une journée aussi chargée. Ce thème de l'intelligence artificielle peut être perçu comme une véritable arme de destruction massive. Pour être franc, je ne suis pas à l'origine de ce titre, mais je l'ai conservé car il incite à la réflexion. Pour conclure cette journée riche en interventions, il n'est peut-être

pas inutile d'introduire une dose de légèreté. Je ne parle pas du fond – l'IA comme arme de destruction massive –, mais plutôt de la forme racoleuse de ce titre, qui rappelle ces couvertures de magazines qui ont fleuri ces dernières années dans nos kiosques, promettant, selon l'humeur éditoriale, soit le salut, soit l'apocalypse. Tantôt un destin apothéotique pour nos civilisations, tantôt, et le plus souvent, la catastrophe d'un monde où les machines s'emparent du pouvoir.

Comme le suggère le titre de cette intervention, l'intelligence artificielle possède effectivement une forte puissance évocatoire qui convoque dans la discussion un certain nombre de démons et autres fantômes, des *fantasmas*, comme disaient les Grecs. Dès que l'on tente de circonscrire ce sujet, on se retrouve malgré soi à faire l'anamnèse collective d'un temps immémorial, où mythe et raison, où *mutos* et *logos* étaient synonymes, et où le surnaturel se fantasmaient comme un réel qui s'ignore. Il n'est peut-être pas inutile de faire la distinction entre fantasme et réalité, tout en prenant au sérieux ces expressions sensationnalistes.

Tout d'abord, je rappelle ce que beaucoup savent : le terme d'intelligence artificielle est lui-même né d'un fantasme conçu à des fins marketing. C'est bien dans l'intention de vendre un produit, d'obtenir des financements, que ce packaging sémiotique des plus séduisants a été créé par le mathématicien et cybernéticien américain

²⁴. *Weapons of Math Destruction*, Cathy O'Neil, Crown Publishing Group, 2016.

John McCarthy pour désigner ce nouveau champ de recherche qu'il prétendait fonder en 1956 avec d'autres, lors de la conférence de Dartmouth. De fait, il est parvenu à ses fins, puisque ses intentions scientifiques et techniques ont littéralement frappé plus que de raison l'imaginaire de ses contemporains. De toute évidence, ces chercheurs et ingénieurs à l'origine de l'intelligence artificielle ne pensaient pas vraiment possible, contrairement à leurs ancêtres cybernéticiens, de reproduire l'intelligence humaine dans une machine. Leur intention n'a jamais été autre que de la simuler. Dès le départ, le terme même d'intelligence artificielle a donc créé un décalage, un hiatus entre le projet technique réel et les possibilités bien plus larges qu'il laisse entendre ou espérer.

Il a donc ouvert la voie à des espérances proprement fantastiques, autrement dit à des fantasmes au sens psychanalytique, freudien, du terme. Et si ce tour de passe-passe sémantique a si bien fonctionné, c'est qu'il active les réminiscences d'une chaîne mythologique considérable de représentations qui remontent aux fondements grecs et bibliques des sociétés occidentales. Ces représentations évoquent le geste démiurgique du ou des dieux que l'homme parviendrait à reproduire pour surmonter son incomplétude, pour abolir la distance entre la créature et son créateur, et finalement réaliser à nouveau la synthèse entre le créant et le créé. C'est bien ce fantasme qui se cache derrière l'intelligence artificielle : hisser l'homme à la place de Dieu, tuer le père et s'en approprier les attributs.

Finie la chute adamique, retour au jardin d'Éden pour les monothéistes ou à l'âge d'or pour les Grecs. Sauf qu'un problème reste en suspens. Comme dans le schéma œdipien, le fantasme parricide a un double effet : celui de porter le fils au niveau du père, et de faire de ce fils, devenu père à son tour, la proie d'un nouveau fils qui cherchera à le tuer et à s'y substituer. D'où, également, cette peur enracinée dans la culture occidentale, la peur de la créature qui échappe à son créateur, depuis le monstre de Frankenstein jusqu'à *iRobot*, en passant par *2001, L'odyssée de l'espace*, les machines de *Matrix*, de *Terminator*, et j'en passe. L'accumulation pluriséculaire de ces récits a structuré nos référents culturels et, avec eux, nos chaînes de perception et de pensée qui, par défaut, classent donc la créature artificielle parmi les menaces.

La campagne internationale contre les robots tueurs lancée en 2013 par *Human Rights Watch*, tout comme les dernières déclarations de Stephen Hawking avant sa mort, qui craignait

que l'intelligence artificielle puisse mettre fin à l'humanité, ne sont que les dernières manifestations de cet effroi que suscitent *a priori* les golems et leurs avatars modernes. Non sans ambiguïté d'ailleurs, puisque dans le même temps, ces créatures émerveillent, tant par leurs qualités exceptionnelles que par l'image gratifiante sur le plan narcissique, qu'elles renvoient des êtres humains, leurs créateurs.

On comprend bien cette ambiguïté dans les propos de Poutine lorsqu'il déclare, en 2017, que celui qui sera le leader en intelligence artificielle se rendra maître du monde. Car l'intelligence artificielle véhicule effectivement le fantasme de l'instrument de la suprématie, de l'arme absolue. Mais, du même coup, cela en fait un enjeu politique de premier ordre. En effet, personne ne souhaite prendre le risque de voir un concurrent étatique s'emparer le premier de cette technologie, puisque le présupposé est que celui qui parviendra à maîtriser, passé un certain seuil, le plus haut niveau de sophistication de l'intelligence artificielle, devancera et subjuguera éternellement tous ses rivaux.

Nous constatons donc que tous ces titres racoleurs que nous affichons avec l'intelligence artificielle, afin d'attirer le chaland ici encore aujourd'hui, expriment fondamentalement un fantasme eschatologique. C'est quelque chose que nous n'avions plus vu à ce niveau d'acuité depuis la Seconde Guerre mondiale, sans doute, et la course entre les Alliés et les Allemands pour être les premiers à obtenir la bombe atomique. Lorsque nous évoquons une arme de destruction massive, nous ranimons bien quelque chose qui est de l'ordre du fantasme traditionnel au sujet de l'intelligence artificielle, un fantasme de fin des temps, de fin de l'histoire. Mais ce fantasme a des implications réelles. Et puisque le titre y invite, examinons cela sous l'angle militaire. À quand remontent les premières tentatives d'application de l'intelligence artificielle à des fins martiales ?

À la Seconde Guerre mondiale. Bien sûr, l'intelligence artificielle n'existe pas comme domaine de recherche autonome à cette époque, mais ses précurseurs, que ce soient les cybernéticiens ou les théoriciens de l'information comme Claude Shannon, qui était l'un des participants de la conférence de Dartmouth en 1956, produisent déjà des travaux scientifiques qui s'y rapportent. Ce sont deux cybernéticiens, Walter Pitts et Warren McCulloch, qui, en 1943, vont conceptualiser ce que nous appelons aujourd'hui les réseaux de neurones artificiels, qui sont au cœur des développements de l'approche

connexionniste en intelligence artificielle de nos jours, par rapport à une approche symbolique quelque peu passée de mode.

Mais ce n'est pas tout, car une grande partie de ceux qui ont participé à la fondation du champ de recherche en intelligence artificielle, ou qui en ont posé les jalons scientifiques, travaillaient pendant la Seconde Guerre mondiale au département de la Guerre américain, certains pour le projet Manhattan. D'autres, comme Norbert Wiener, qui était la figure de proue du mouvement cybernétique, ou Julian Bigelow, un ingénieur d'IBM participant à la conférence inaugurale de l'intelligence artificielle à Dartmouth, ont travaillé sur un projet d'automatisation de la défense antiaérienne américaine.

Leur projet, qu'aujourd'hui nous qualifions presque d'intelligence artificielle, consistait à prédire la trajectoire des avions ennemis à partir de traitements statistiques et probabilistes, en utilisant différentes données en entrée, telles que l'altitude, la vitesse, des données acoustiques liées aux avions, et en ajoutant des données issues d'observations antérieures pour affiner le modèle et la prédiction. On n'est pas loin, au moins sur le plan conceptuel, de ce que nous appelons aujourd'hui le *machine learning*. L'armée, en effet, est le secteur de la société qui croit le plus rapidement aux possibilités miraculeuses de l'intelligence artificielle. Dès le début des années 1960, des millions de dollars sont dépensés chaque année par l'agence de recherche et de développement du Pentagone pour financer les laboratoires d'intelligence artificielle du MIT, de Stanford, de la Carnegie-Mellon et d'IBM.

D'ailleurs, tous ces laboratoires ont été créés par certains participants de cette fameuse conférence de Dartmouth en 1956. Les laboratoires d'intelligence artificielle du MIT et de Stanford ont été fondés par John McCarthy et Marvin Minsky. Celui d'IBM comptait parmi ses membres Julian Bigelow, déjà mentionné, Nathaniel Rochester, qui a été l'architecte en chef du premier ordinateur commercialisé par IBM, qui, soit dit en passant, avait pour premiers utilisateurs la NSA et la Marine américaine. Depuis lors, l'intelligence artificielle n'a cessé d'être intégrée au programme militaire du Pentagone. Dès la guerre du Viêt Nam, Robert McNamara, secrétaire à la Défense de Kennedy et Johnson, a mis sur pied une équipe d'informaticiens chargés d'appliquer les technologies d'intelligence artificielle à la conduite de la guerre.

Il y a notamment un ordinateur qui a été développé dans ce cadre et qui avait pour but

de prodiguer des conseils opérationnels aux stratégies du Pentagone à partir de certaines données en entrée, des données assez générales, telles que des données démographiques, militaires et économiques sur la situation au Viêt Nam. Évidemment, à cette époque-là, il n'y avait pas encore la maturité technologique que nous connaissons aujourd'hui. Les données étaient manquantes et la puissance de calcul était très inférieure à ce dont nous disposons actuellement. Quand les ingénieurs du Pentagone ont demandé à l'ordinateur, en 1969, quand ils gagneraient la guerre, l'ordinateur leur a répondu : « Vous avez gagné en 1964. » Cela illustre bien jusqu'où peut conduire le fantasme d'une machine capable de singer, voire de surpasser les capacités intellectuelles humaines.



Si nous souhaitons repousser les limites des performances, atteindre l'optimum des capacités intellectuelles, fonder le meilleur gouvernement jamais instauré, un gouvernement fondé sur la science et sur la rationalité mathématique, il est évident qu'il faut se passer des hommes.

Ce fantasme d'un gouvernement scientifique est inscrit aux origines mêmes du mouvement cybernétique. Cybernétique signifie étymologiquement la science du gouvernement ou l'art de gouverner. De nos jours, l'intelligence artificielle est surtout utilisée dans le domaine militaire comme outil d'aide à la prise de décision, mais elle fournit également des armes, ce que nous appelons dans le jargon militaire des systèmes d'armes létales autonomes (SALA). Aujourd'hui, les principales armées du monde développent et déploient ce type d'armement. Dès 2021, par exemple, l'armée israélienne a utilisé des essaims de drones autonomes pour mener des opérations militaires dans la bande de Gaza. Cela a été de nouveau le cas depuis le 7 octobre. Nous avons appris hier par le *Washington Post* que Google transmet ses outils d'intelligence artificielle à Tsahal pour mener ses opérations à Gaza, ce qui pourrait constituer une possibilité

de complicité dans des crimes contre l'humanité, voire de génocide pour les entreprises qui y participeraient. En Corée du Sud, depuis 2014, il existe un programme de remplacement systématique des sentinelles humaines le long de la frontière intercoréenne par des sentinelles robotisées, conçues et fabriquées par l'entreprise Samsung. Oui, l'intelligence artificielle est effectivement une arme, elle est en circulation, et cela pose énormément de problèmes. En tant que juristes, vous savez très bien que l'usage de ces robots tueurs contrevient manifestement au moins aux principes de proportionnalité, de discrimination et de responsabilité du droit international humanitaire. Mais cela fait l'objet de discussions déjà bien connues.

Je souhaite aborder plutôt les raisons qui font de l'intelligence artificielle une arme de destruction massive par construction, et non pas nécessairement de façon métaphorique. Pour cela, il est essentiel d'examiner ce qui me semble être le point d'articulation principal du développement de l'intelligence artificielle depuis ses origines, c'est-à-dire depuis la Seconde Guerre mondiale. Ce point de coalescence, ce motif fédérateur de tous les acteurs de l'intelligence artificielle, concerne toutes ses perspectives applicatives, en mettant de côté la recherche fondamentale. Cela a toujours été la recherche de rendements croissants, d'augmentation de la productivité, quel qu'en soit le domaine d'application.

Une productivité accrue, comment l'atteindre ? En tendant vers la substitution généralisée de machines aux êtres humains. Nous pouvons retourner le problème dans tous les sens, il s'agit bien de cela : rendre la production, quelle qu'elle soit – industrielle, commerciale, financière, mais aussi intellectuelle, sociale et même politique – la plus performante possible, en postulant que, toutes choses étant égales par ailleurs, c'est le facteur humain qui grève les possibilités de surplus productif illimité. L'humain est en effet fini, limité et limitant. Si nous souhaitons repousser les limites des performances, atteindre l'optimum des capacités intellectuelles, fonder le meilleur gouvernement jamais instauré, un gouvernement fondé sur la science et sur la rationalité mathématique, il est évident qu'il faut se passer des hommes.

Ce mode de raisonnement, qui implique de penser que chaque être humain inséré dans le processus de production représente un coût marginal insupportable, sied plutôt bien à nos régimes capitalistes. Avec l'intelligence artificielle, c'est l'invalidation possible de la loi d'airain des salaires qui devient un horizon d'attente

enfin atteignable. C'est la possibilité d'accroître la productivité au-delà des capacités humaines, tout en se passant de main-d'œuvre. Une main-d'œuvre évidemment coûteuse, peu fiable, qui doit se nourrir, se soigner, et restaurer sa force de travail, etc. Nous imaginons aisément l'attrait de ce type de promesses sur des dirigeants d'entreprise, des comités de direction, des conseils d'administration, des actionnaires de plus ou moins grandes entreprises. En ligne de mire, c'est la substitution enfin achevée du capital au travail.

C'est de cette manière précise que les producteurs d'outils d'intelligence artificielle, notamment les grandes entreprises de la Silicon Valley, vendent leurs solutions aux entreprises du monde entier, mais aussi aux États. Et pour cause, nous savons très bien maintenant, et cela a été parfaitement documenté, combien l'esprit gestionnaire du capitalisme a fait son chemin, et depuis longtemps, au sein de l'État. On songe aux politiques d'austérité, qui sont devenues la norme des politiques budgétaires, ou aux aspirations rationalistes du *new public management*, aux politiques de réforme, et aux politiques de modernisation de l'administration qui ont envahi l'espace bureaucratique depuis les années 1980. Tout ceci a créé un terreau des plus fertiles pour les tentatives d'importation des technologies d'intelligence artificielle dans le processus politique et dans les circuits de fonctionnement administratifs.

Il suffit de voir ce qui se trame aux États-Unis. Elon Musk va être propulsé à la tête d'un tout nouveau département de l'efficacité gouvernementale. Quel est son programme ? Utiliser l'intelligence artificielle pour identifier les zones administratives pouvant faire l'objet, je le cite et il le dit très clairement, de réduction massive de personnel et de budget. Il s'agit aussi d'utiliser l'intelligence artificielle pour éplucher des millions de pages de réglementation afin d'identifier celles qui sont, là encore je le cite, sans fondement législatif explicite. Nous assistons ainsi à une vaste purge réglementaire dans les domaines de la fiscalité, de l'énergie, de l'environnement, de la finance, etc.

Nous avons tendance, surtout en ce moment, à nous concentrer sur Musk et Trump, mais des alliances similaires entre l'État, le gouvernement et la tech américaine existent aussi en France. Mon sujet de thèse porte sur les relations entre alliances et confrontations entre Google et le gouvernement français²⁵. Voici un exemple parmi

25. « Google : une entreprise d'influence ? Indigénisation, normalisation et politisation d'une multinationale du numérique en France », Charles Thibout, 2024.

d'autres : depuis 2019, la Direction générale des finances publiques utilise les technologies d'intelligence artificielle de Google, en l'occurrence des technologies de vision par ordinateur, pour automatiser ses opérations de contrôle fiscal. En clair, Google, qui soit dit en passant, a passé une convention judiciaire d'intérêt public avec le fisc la même année, est mis à contribution par la DGFiP pour repérer les bâtiments divers non déclarés – donc les piscines, les établis – des particuliers, grâce aux images de l'IGN, lorsque ce n'est pas directement par Google Earth ou Google Maps.

Le but de ce programme, qui s'appelle Foncier Innovant, est de réaliser 12 millions d'euros d'économies pour l'administration, et de cibler à moyen terme 50 % des contrôles fiscaux des particuliers grâce à l'intelligence artificielle, tout en supprimant 300 emplois équivalents temps plein. Feu Claude Allègre en a rêvé, Google l'a fait, il a dégraissé le mammoth. Cela ne concerne pas l'Éducation nationale, mais après tout, pourquoi l'intelligence artificielle ne ferait-elle pas mieux qu'un enseignant ? Surtout si ceux-ci sont toujours absents, comme l'a récemment déclaré un ministre.

Nous ne sommes plus du tout dans la fantasmagorie des titres racoleurs des journaux. Non seulement les promesses d'efficacité, d'efficacité, de performance de l'intelligence artificielle coïncident parfaitement avec les objectifs budgétaires de l'État et le souci de rentabilité des entreprises, mais surtout, cela se traduit directement, de manière triviale, par des suppressions d'emplois. Et nous n'en sommes sans doute qu'au début. Selon les prévisions de la Banque mondiale dans un rapport de 2019, l'automatisation et la robotisation du travail pourraient mener d'ici 2050 à la disparition nette de 47 % des emplois aux États-Unis, de 66 % des emplois en Inde et jusqu'à 77 % des emplois en Chine.

Dans un autre rapport, plus récent, publié l'an passé par le FMI, il est indiqué que 60 % des emplois des économies avancées, c'est-à-dire les économies occidentales, en moyenne, sont menacés par l'intelligence artificielle, notamment 60 % des emplois aux États-Unis et 70 % des emplois au Royaume-Uni. Il est important de préciser que nous parlons d'emplois menacés de suppression et non remplacés, non remplaçables. Autrement dit, deux des plus grandes organisations internationales, la Banque mondiale et le FMI, prédisent que la majeure partie des populations se retrouvera sans emploi à terme.

Question : si ces prévisions s'avèrent justes, qu'adviendra-t-il de ces populations ? Les États subviendront-ils à leurs besoins primaires ? La conclusion la plus probable d'une telle catastrophe sociale sera la marginalisation de ces populations. Il est entendu que les États ne seront certainement pas en mesure de réunir les ressources nécessaires pour garantir un niveau de vie convenable hors de toute activité professionnelle rémunérée. Par conséquent, c'est à la fois la survie de ces populations, mais aussi, bien évidemment, la stabilité et la survie des régimes politiques eux-mêmes qui est menacée.

Nous pouvons également envisager un exercice prospectif. Si l'explosion du chômage devient effectivement un phénomène généralisé, seuls pourront échapper à la conflagration sociopolitique qui s'ensuivra les pays dont le tissu économique générera des gains de productivité suffisants pour continuer à assurer un niveau de vie satisfaisant à leur population. Si tant est, évidemment, que des mécanismes de redistribution suffisants aient été mis en place par ailleurs. Nous commençons alors à comprendre ce que voulait dire Poutine lorsqu'il affirmait que l'intelligence artificielle serait la clé de l'hégémonie dans les relations internationales.

Si l'intelligence artificielle réalise effectivement toutes ses promesses en matière d'efficacité économique, de performance productive, et qu'un pays parvient avant les autres à un stade où sa compétitivité sera inégalable, il sera le seul capable de supporter le coût économique, social et politique d'une destruction massive de main-d'œuvre. Les autres pays ne bénéficieront pas de cet avantage compétitif qui leur permettrait de dégager et de redistribuer les gains de productivité suffisants pour garantir à leur population des conditions de vie décentes. Nous comprenons ainsi que pour les États, si on admet que ce sont des institutions sociales qui ont leurs objectifs propres, leur volonté de se perpétuer de manière autonome, la course à l'intelligence artificielle s'assimile à une course à la survie des régimes eux-mêmes.

Est-ce que l'intelligence artificielle est une arme de destruction massive ? Ce que nous pouvons dire en tout cas, c'est qu'en prêtant à l'intelligence artificielle des pouvoirs démentiels, nous ne sommes peut-être plus très loin de la prophétie autoréalisatrice, que l'on appelle d'ailleurs en psychologie l'effet Golem – encore une histoire de créature artificielle qui risque d'échapper à son créateur. Il ne faut donc pas mépriser les fantasmes, car parfois leurs effets sont plus réels que leurs causes.

Un dernier point que je voudrais soulever pour conclure cet exposé est celui de la vision politique que soutiennent les dirigeants des grandes firmes productrices de technologies d'intelligence artificielle. Nous avons récemment commencé à nous y intéresser, car avec Musk, nous avons l'exemple typique d'une dérive réactionnaire, masculiniste, raciste, une sorte de mélange entre ultranationalisme et libertarianisme qui touche une partie de la tech américaine.

Nous avons tendance à réduire cette question à deux éléments : soit à la pente extrême-droitière de la Silicon Valley, soit, selon une version psychologisante, à la structure délirante de certains individus. Or, il est crucial de prendre au sérieux ce que nous disent des per-



C'est donc le rêve, le fantasme d'un retour à une société d'ordres, ni plus ni moins, une société aristocratique au sens strict du terme, gouvernée par les meilleurs, les aristoï, c'est-à-dire ici, par ceux qui auront atteint cette supériorité intellectuelle et physique sur les hommes et sur les machines.

sonnes comme Elon Musk, Peter Thiel ou Mark Zuckerberg. Ils parlent de l'IA pas seulement d'un point de vue technologique ou économique. Prenez quelqu'un comme Ray Kurzweil qui est directeur de l'ingénierie chez Google, cofondateur de la Singularity University, un incubateur de start-ups, un think tank et un centre de formation. Dans son livre, très connu, *The Singularity is Near*²⁶, paru en 2005, Kurzweil prédit que, grâce aux progrès de l'intelligence artificielle, les machines devraient surpasser en intelligence les êtres humains d'ici à 2045.

C'est ce qu'il appelle l'avènement de la singularité technologique. Il explique que l'arrivée prochaine de cette singularité technologique, que l'on peut aussi appeler l'intelligence artificielle forte, représente un risque pour les êtres

humains de devenir les esclaves des machines, un peu à la manière de *Matrix*. Ainsi, pour éviter d'être réduits à la servilité, les humains doivent s'adapter et utiliser la technologie pour se perfectionner et donc rester compétitifs face à ces nouveaux rivaux que seront les machines.

Je reste toujours dans son optique. Son idée, que nous retrouvons chez Musk et chez d'autres, est donc d'augmenter les capacités intellectuelles et physiques humaines, voire de transférer la conscience elle-même dans une machine. Cependant, ce qui est intéressant et qu'il convient de garder à l'esprit, c'est que ces perspectives transhumanistes seraient réservées à une petite élite ploutocratique. L'avenir que ces dirigeants de la tech dessinent est celui d'un nouvel ordre social, d'une timocratie oligarchique dont ils occuperaient le sommet, pendant que le reste de la population serait condamné à errer sans but et sans ressources, incapables de rivaliser avec la force productive des intelligences artificielles.

C'est donc le rêve, le fantasme d'un retour à une société d'ordres, ni plus ni moins, une société aristocratique au sens strict du terme, gouvernée par les meilleurs, les *aristoï*, c'est-à-dire ici, par ceux qui auront atteint cette supériorité intellectuelle et physique sur les hommes et sur les machines. C'est peut-être ici qu'il faut voir dans l'intelligence artificielle une arme de destruction. Dès lors qu'elle devient le support technologique d'un projet politique de dissolution de la démocratie.

Quand nous voyons effectivement ce nouveau ministre milliardaire de l'efficacité gouvernementale de la première puissance mondiale faire sans la moindre vergogne un salut nazi, appeler à l'annexion de pays à régime démocratique, se faire le chantre de l'apartheid, il est peut-être vrai que l'idée que l'intelligence artificielle puisse devenir une arme de destruction massive n'est pas totalement dénuée de sens. Voilà, je vous remercie.

Yannick MENECEUR : Merci Charles. Et pour conclure cette conférence, parmi l'ensemble de la production de la journée, une phrase d'Antoinette ROUVROY a capté mon attention et je tente de vous la restituer : « La justice, c'est quelque chose de dialectique. Toujours quelque chose pour l'avenir. On ne la trouve pas dans les données. En revanche, l'injustice, elle, se trouve bien dans les données. »

Merci à toutes et tous de votre participation et rendez-vous dans un an pour continuer, ensemble, à « Décoder l'IA. » ■

²⁶. *The Singularity is Near*, Ray Kurzweil, Viking, 2005.



Programme de la conférence

Décoder l'IA en 2025 : actualités d'une technologie en voie de banalisation

23 janvier 2025

Centre de culture numérique, Strasbourg

9h

Accueil

9h15

Mots de bienvenue des organisateurs

- Jeanne-Marie TUFFERY-ANDRIEU, doyen de la faculté de droit, de sciences politiques et de gestion de Strasbourg
- Yannick MENECEUR, magistrat, maître de conférences associé à la faculté de droit, de sciences politiques et de gestion de Strasbourg, responsable d'études et de recherche associé à l'IERDJ, devenu Institut Robert Badinter au 30 juin 2025
- Harold ÉPINEUSE, directeur adjoint de l'IERDJ

9h30

Conférence d'ouverture

Mais où va l'IA ?

- Comprendre les fondements et les implications éthiques de l'intelligence artificielle
 - Prendre de la distance avec les idées reçues sur l'intelligence artificielle
 - Une réflexion critique sur les motivations des grands acteurs technologiques est à conduire
- Jean-Gabriel GANASCIA, professeur d'informatique à la faculté des sciences de Sorbonne Université, membre senior de l'Institut universitaire de France et président du comité d'éthique du CNRS

10h

Conversation au coin du feu

Parler la langue des IA génératives

- Quelles sont les dernières avancées dans le domaine des intelligences artificielles génératives ?
 - Comprendre les bases conceptuelles des modèles d'intelligence artificielle pour optimiser leur utilisation et garantir leur gouvernance
 - L'automatisation doit être réalisée en y donnant un sens
- Modérateur : Yannick MENECEUR, magistrat, maître de conférences associé à la faculté de droit, de sciences politiques et de gestion de l'université de Strasbourg et responsable d'études et de recherche associé à l'IERDJ.
 - Murielle POPA-FABRE, experte au Conseil de l'Europe sur les questions de réglementation d'intelligence artificielle et de protection des données
 - Thomas LAMPERT, professeur en intelligence artificielle et sciences des données à l'université de Strasbourg

10h30

Pause santé

10h50

Diffusion d'un court extrait du documentaire *iHuman* (ARTE)

11h**Table ronde****L'IA transformera-t-elle la liberté en destin ?**

- Analyser les implications sociétales et politiques de l'intelligence artificielle sur notre liberté individuelle
 - Évaluer les dangers d'un déterminisme algorithmiques qui pourrait réduire le champ des possibles
 - Promouvoir une réflexion collective et démocratique sur l'intégration de l'intelligence artificielle dans nos sociétés
- Modération : Harold ÉPINEUSE, directeur adjoint de l'IERDJ
 - Maxime DERIAN, docteur en socio-anthropologie du numérique
 - Antoinette ROUVROY, chercheuse FNRS au Centre de recherche information, droit et société (CRIDS) de l'université de Namur
 - Bilel BENBOUZID, maître de conférences à l'université Gustave Eiffel, Laboratoire Interdisciplinaire Sciences Innovations Sociétés (LISIS)
 - Sabine VAN HAECKE LEPIC, avocate et docteure en droit

12h30**Déjeuner****14h****Table ronde****IA et professionnels du droit, le grand malentendu ?**

- Décryptage des attentes et des enjeux liés à l'utilisation de l'IA dans le droit : une meilleure efficacité qui reste à objectiver
 - Audace, transparence et prudence paraissent centraux dans l'utilisation des systèmes d'intelligence artificielle dans le domaine du droit
 - Des projets déjà concrets se diffusent dans les professions du droit
- Modération : Sophie SONTAG KOENIG, maître de conférences à l'université Paris-Nanterre
 - Aurélie KLEIN, avocate et maître de conférences associée à la faculté de droit, de sciences politiques et de gestion de l'université de Strasbourg
 - Frédérique BERROD, professeure de droit de l'Union européenne à Sciences Po Strasbourg
 - Pascal ALIX, avocat
 - Claire STRUGALA, magistrate judiciaire et docteure en droit
 - Marc CLÉMENT, juge administratif

15h30**Conférence de clôture****L'IA, une arme de destruction massive ?**

- L'intelligence artificielle est un fantasme marketing, son origine ne vise pas réellement à reproduire l'intelligence humaine mais à la simuler
 - L'utilisation historique de l'intelligence artificielle depuis la Seconde Guerre mondiale jusqu'à son déploiement actuel dans des systèmes d'armement autonomes est militaire
 - Les conséquences sociales et politiques de l'automatisation sont à appréhender sous l'angle de la destruction massive d'emplois et l'instabilité des régimes politiques
- Charles THIBOUT, docteur en science politique, membre du Centre européen de sociologie et de science politique (CNRS, EHESS, Paris 1 Panthéon-Sorbonne)

16h**Fin de la diffusion en ligne****16h****Échanges entre la salle et les intervenants présents**

Animation conjointe par Sophie SONTAG KOENIG, Harold ÉPINEUSE et Yannick MENECEUR



Références

Ouvrages

- BARTHES Roland, *Le Neutre. Cours au Collège de France (1978)*, Seuil, 2023.
- BERGSON Henri, *La Pensée et le Mouvant* (1934), PUF, 2013.
- GANASCIA Jean-Gabriel, *L'Âme-machine. Les enjeux de l'intelligence artificielle*, Seuil, 1990.
- GANASCIA Jean-Gabriel, *Le Mythe de la Singularité. Faut-il craindre l'intelligence artificielle ?*, Seuil, 2017.
- GANASCIA Jean-Gabriel, *L'I.A. expliquée aux humains*, Seuil, 2024.
- GARAPON Antoine et LASSÈGUE Jean, *Justice digitale*, PUF, 2018.
- HELER Joseph, *Catch 22* (1961), Gasset, 2004.
- KANT Emmanuel, *La Critique de la raison pure* (1781), PUF, 2012.
- KURZWEIL Ray, *The Singularity is Near*, Viking, 2005.
- MENECEUR Yannick, *IA générative et professionnels du droit. Comprendre et s'approprier la langue des probables*, LexisNexis, 2024.
- O'NEIL Cathy, *Weapons of Math Destruction*, Crown Publishing Group, 2016.
- RANCIÈRE Jacques, *Le Partage du sensible : Esthétique et politique*, La Fabrique, 2000.
- SONTAG KOENIG Sophie, *Technologies de l'information et de la communication et défense pénale*, Mare & Martin, 2016.

Articles, actes et travaux de recherche

- BIGELOW Julian, ROSENBLUETH Arturo et WIENER Norbert, « Behavior, Purpose and Teleology », *Philosophy of Science*, Volume 10, Issue 1, 1943.
- LEGRAND Emmanuelle et POPA-FABRE Murielle, « IA Générative et décision du juge », dans *Impact du numérique sur la Justice*, Volume 2, Institut Robert Badinter, 2024.
- *Les nouveaux défis de la cyberjustice : entre information, régulation et démocratie*, Actes de la Conférence Cyberjustice Europe 2023, Institut Robert Badinter, 2024.
- McCULLOCH Warren et PITTS Walter, « A Logical Calculus of the Ideas Immanent in Nervous Activity », *Bulletin of Mathematical Biophysics*, Volume 5, 1943.
- SONTAG KOENIG Sophie, « Dispositifs audiovisuels, information juridique et judiciaire, règlement en ligne des différends », dans *Impact du numérique sur la Justice*, Volume 1, Institut Robert Badinter, 2024.
- THIBOUT Charles, « Google : une entreprise d'influence ? Indigénisation, normalisation et politisation d'une multinationale du numérique en France. », 2024.

Vidéographie

- Conférence Cyberjustice Europe 2023 sur YouTube : <http://bit.ly/43z2tbb>
- Conférence Cyberjustice Europe 2016 sur YouTube : <http://bit.ly/43z3a4h>
- *iHuman: L'intelligence artificielle et nous*, Tonje Hessen Schei, 2019.

Directrice de la publication : Valérie SAGANT

Auteur : Harold ÉPINEUSE

Suivi d'édition : Xavier CAYON et Léa DELION

Réalisation : Isabelle CHEMIN

Secrétariat de rédaction : Coralie MANANT

Photos : Vidéo de la conférence Décoder l'IA <http://bit.ly/3JswtyJ>

DÉCODER L'IA EN 2025

ACTUALITÉS D'UNE TECHNOLOGIE EN VOIE DE BANALISATION

Fruit d'une collaboration entre l'Institut des études et de la recherche sur le droit et la justice (devenu depuis Institut Robert Badinter) et l'université de Strasbourg, cette conférence publique organisée en début d'année 2025 marque le premier acte d'un programme de rencontres en vue de « décoder l'IA » dont les actes font l'objet d'une publication en plusieurs volumes.

Dans ce premier volume destiné à un large public de praticiens, de chercheurs et d'étudiants, il s'agit d'interroger les enjeux de la généralisation de l'usage des technologies numériques qualifiées « d'intelligence artificielle » dans ses dimensions à la fois techniques, sociales et juridiques à travers :

- le rappel de quelques bases techniques vulgarisées,
- une revue des enjeux politiques et sociétaux de l'IA en début d'année 2025,
- un état actualisé et pratique de l'emploi de l'IA dans les métiers juridiques et judiciaires.

En se fondant sur les échanges interdisciplinaires ayant nourri cette journée, ces actes partagent quelques-uns des acquis indispensables au développement d'une grammaire commune de l'IA entre juristes, informaticiens, philosophes, sociologues ou politistes.



Courrier postal

Institut Robert Badinter
Ministère de la Justice
13, place Vendôme
75042 Paris Cedex 01

Venir dans nos locaux

47 bis, rue des Vinaigriers
75010 Paris

contact@institutrobertbadinter.fr
institutrobertbadinter.fr



INSTITUT ROBERT BADINTER

Études et recherches sur le droit et la justice

L'Institut Robert Badinter (anciennement Institut des Études et de la Recherche sur le Droit et la justice - IERDJ) a pour mission de nourrir la connaissance et les échanges sur le droit et la justice en lançant des réflexions originales et prospectives, en finançant et en accompagnant des travaux de recherche et en diffusant largement les connaissances sur les normes, la régulation et le fonctionnement de la justice, toutes disciplines scientifiques confondues.

Groupement d'intérêt public créé en 2022, l'Institut Robert Badinter est issu de la fusion de l'Institut des hautes études sur la justice et de la Mission de recherche droit et justice, deux entités internationalement reconnues.